

---

Aplicación sistemática de algoritmos de aprendizaje automático y reconocimiento de patrones a señales bioeléctricas obtenidas de HUMANA y con el sistema Biopac

---

Fernando Javier Sandoval Ruballos



UNIVERSIDAD DEL VALLE DE GUATEMALA

Facultad de Ingeniería



**Aplicación sistemática de algoritmos de aprendizaje  
automático y reconocimiento de patrones a señales  
bioeléctricas obtenidas de HUMANA y con el sistema Biopac**

Trabajo de graduación presentado por Fernando Javier Sandoval  
Ruballos para optar al grado académico de Licenciado en Ingeniería  
Mecatrónica

Guatemala,

2023

Vo.Bo.:

(f) \_\_\_\_\_  
Dr. Luis Alberto Rivera Estrada

Tribunal Examinador:

(f) \_\_\_\_\_

(f) \_\_\_\_\_

(f) \_\_\_\_\_

Fecha de aprobación: Guatemala, de de 2023.

<b>Lista de figuras</b>	<b>xii</b>
<b>Resumen</b>	<b>xiii</b>
<b>Abstract</b>	<b>xiv</b>
<b>1. Introducción</b>	<b>1</b>
<b>2. Antecedentes</b>	<b>2</b>
<b>3. Justificación</b>	<b>7</b>
<b>4. Objetivos</b>	<b>8</b>
<b>5. Alcance</b>	<b>9</b>
<b>6. Marco teórico</b>	<b>10</b>
6.1. Señales bioeléctricas . . . . .	10
6.2. Biopac . . . . .	10
6.3. Señales EMG . . . . .	11
6.4. Señales ECG . . . . .	12
6.5. Señales EEG . . . . .	12
6.6. Procesamiento de señales bioeléctricas . . . . .	13
6.7. Filtrado de señales . . . . .	14
6.8. Métodos de captura de señales bioeléctricas . . . . .	14
6.9. Epilepsia . . . . .	15
6.10. Aprendizaje automático . . . . .	16
6.11. Aprendizaje no supervisado . . . . .	16
6.12. Aprendizaje supervisado . . . . .	17
6.13. Máquinas de vectores de soporte . . . . .	17
6.14. Redes Neuronales . . . . .	18
6.15. Características en el dominio del tiempo . . . . .	19
6.16. Características en el dominio de la frecuencia . . . . .	19

6.17. <i>K-Fold Cross Validation</i> . . . . .	20
6.18. Modelo Autorregresivo (AR) . . . . .	20
6.19. Criterio de Información de Akaike (AIC) . . . . .	20
6.20. Filtro de Blanqueo . . . . .	21
6.21. Sobreajuste ( <i>Overfit</i> ) . . . . .	21
6.22. Manipulador Serial . . . . .	21
6.23. <i>Denavit-Hartenberg</i> . . . . .	22
6.24. Interfaz cerebro-máquina . . . . .	23
6.25. Entropía cruzada ( <i>cross-entropy</i> ) . . . . .	24
<b>7. Recolección de señales bioeléctricas</b>	<b>25</b>
7.1. Posición de electrodos - EMG . . . . .	25
7.2. Captura de señales - EMG . . . . .	25
7.2.1. Gesto 1: Puño arriba . . . . .	27
7.2.2. Gesto 2: Puño abajo . . . . .	27
7.2.3. Gesto 3: Puño cerrado . . . . .	28
7.2.4. Gesto 4: Palma extendida . . . . .	28
7.3. Posición de electrodos - EEG . . . . .	29
7.4. Captura de señales - EEG . . . . .	30
7.4.1. Gesto 2: Cabeza hacia abajo . . . . .	30
7.4.2. Gesto 3: Cabeza hacia arriba . . . . .	31
7.4.3. Gesto 4: Cabeza inclinada . . . . .	31
7.5. Base de datos - Humana . . . . .	31
<b>8. Extracción y manipulación de datos en MATLAB</b>	<b>32</b>
8.1. Algoritmo de extracción de datos en MATLAB . . . . .	34
8.2. Almacenamiento en formato .mat . . . . .	35
<b>9. Procesamiento de señales capturadas</b>	<b>36</b>
9.1. Filtro pasa bandas - EMG . . . . .	36
9.2. Filtro pasa bandas - EEG . . . . .	36
9.3. Filtro rechaza bandas . . . . .	37
9.4. Filtro de blanqueo . . . . .	37
<b>10. Desarrollo de Algoritmos: Detección de Actividad EMG/EEG</b>	<b>40</b>
10.1. Umbral Único - EMG . . . . .	40
10.2. Umbral Doble - EMG . . . . .	41
10.3. Umbral Adaptativo - EEG . . . . .	42
10.3.1. Análisis de ondas cerebrales . . . . .	42
<b>11. Aplicación de algoritmos de extracción de características y aprendizaje automático</b>	<b>45</b>
11.1. Algoritmos de extracción de características . . . . .	45
11.1.1. Características en el dominio del tiempo - EMG/EEG . . . . .	45
11.1.2. Características en el dominio de la en el dominio de la frecuencia - EEG	46
11.2. Algoritmos de aprendizaje automático . . . . .	46
11.3. Homogeneización de segmentos detectados . . . . .	48
11.3.1. Homogeneización utilizando <i>Zero Padding</i> . . . . .	48
11.3.2. Homogeneización utilizando interpolación . . . . .	49

<b>12. Análisis estadísticos de algoritmos - Fase previa</b>	<b>52</b>
12.1. Entrenamientos inter-sujeto . . . . .	54
12.2. Entrenamientos intra-sujeto . . . . .	54
12.3. Elección de entrenamientos . . . . .	54
12.4. Identificación de mejoras . . . . .	56
<b>13. Resultados de clasificación</b>	<b>57</b>
13.1. Redes Neuronales - Señales EMG: Inter-sujeto . . . . .	57
13.2. Clasificación de características - Dominio del tiempo . . . . .	58
13.3. Redes Neuronales - Señales EMG: Intra-sujeto . . . . .	60
13.3.1. Clasificación de características - Dominio del tiempo: Sujeto P000 . . .	60
13.3.2. Clasificación de características - Dominio del tiempo: Sujeto P001 . . .	62
13.4. Redes Neuronales: Resumen resultados EMG . . . . .	64
13.5. Redes Neuronales - Señales EEG: Inter-sujeto . . . . .	65
13.5.1. Clasificación de características - Dominio del tiempo . . . . .	65
13.5.2. Clasificación de características - Dominio de la frecuencia . . . . .	67
13.6. Redes Neuronales - Señales EEG: Intra-sujeto . . . . .	69
13.6.1. Clasificación de características - Dominio del tiempo: Sujeto P000 . . .	69
13.6.2. Clasificación de características - Dominio del tiempo: Sujeto P001 . . .	71
13.6.3. Clasificación de características - Dominio de la frecuencia: Sujeto P000	73
13.6.4. Clasificación de características - Dominio de la frecuencia: Sujeto P001	75
13.7. Redes Neuronales: Resumen resultados EEG . . . . .	77
13.8. SVM - Señales EMG: Inter-sujeto . . . . .	78
13.8.1. Clasificación de características - Dominio del tiempo . . . . .	78
13.9. SVM - Señales EMG: Intra-sujeto . . . . .	79
13.9.1. Clasificación de características - Dominio del tiempo: Sujeto P000 . . .	80
13.9.2. Clasificación de características - Dominio del tiempo: Sujeto P001 . . .	81
13.10Máquinas SVM - Señales EEG: Inter-sujeto . . . . .	83
13.10.1.Clasificación de características - Dominio del tiempo . . . . .	83
13.10.2.Clasificación de características - Dominio de la frecuencia . . . . .	84
13.11Máquinas SVM - Señales EEG: Intra-sujeto . . . . .	85
13.11.1.Clasificación de características - Dominio del tiempo: Sujeto P000 . . .	86
13.11.2.Clasificación de características - Dominio del tiempo: Sujeto P001 . . .	87
13.11.3.Clasificación de características - Dominio de la frecuencia: Sujeto P000	89
13.11.4.Clasificación de características - Dominio de la frecuencia: Sujeto P001	90
13.12Resumen resultados SVM . . . . .	92
13.13Resultados de clasificación - HUMANA . . . . .	93
13.14Redes Neuronales - 4 clases . . . . .	93
13.15SVM - 4 clases . . . . .	94
13.16Análisis de señales . . . . .	95
<b>14. Interfaces de captura y aprendizaje</b>	<b>97</b>
14.1. Interfaces desarrolladas . . . . .	100
14.2. Simulaciones . . . . .	100
14.2.1. Puma 560 - Resultados de control automático . . . . .	101
<b>15. Conclusiones</b>	<b>104</b>

<b>16.Recomendaciones</b>	<b>105</b>
<b>17.Bibliografía</b>	<b>106</b>
<b>18.Anexos</b>	<b>110</b>
18.1. Clasificadores Red Neuronal - Señales EMG . . . . .	110
18.1.1. Inter-sujeto (3 clases) . . . . .	110
18.1.2. Intra-sujeto (2 clases): Sujeto de estudio - P000 . . . . .	112
18.1.3. Intra-sujeto (2 clases): Sujeto de estudio - P001 . . . . .	113
18.1.4. Intra-sujeto (2 clases): Sujeto de estudio - P002 . . . . .	115
18.1.5. Intra-sujeto (3 clases): Sujeto de estudio - P000 . . . . .	116
18.1.6. Intra-sujeto (3 clases): Sujeto de estudio - P001 . . . . .	118
18.1.7. Intra-sujeto (3 clases): Sujeto de estudio - P002 . . . . .	119
18.1.8. Intra-sujeto (4 clases): Sujeto de estudio - P002 . . . . .	121
18.2. Clasificadores Red Neuronal - Señales EEG . . . . .	123
18.2.1. Inter-sujeto (3 clases) . . . . .	123
18.2.2. Intra-sujeto (2 clases): Sujeto de estudio - P000 . . . . .	126
18.2.3. Intra-sujeto (3 clases): Sujeto de estudio - P000 . . . . .	129
18.2.4. Intra-sujeto (2 clases): Sujeto de estudio - P001 . . . . .	132
18.2.5. Intra-sujeto (3 clases): Sujeto de estudio - P001 . . . . .	135
18.3. Resultados SVM - EMG: Intra-sujeto . . . . .	139
18.3.1. Clasificación de características - Dominio del tiempo: Sujeto P002 . . .	139

---

## Lista de figuras

---

1.	Interfaz de control de sistema róbótico con señales EMG [4]. . . . .	3
2.	Interfaz de control de sistema róbótico con señales EEG [5]. . . . .	3
3.	Interfaz de control de sistema róbótico con señales EMG y EEG [6]. . . . .	4
4.	Resumen de resultados con clasificador SVM [8]. . . . .	4
5.	Resumen de resultados con clasificador ARN [8]. . . . .	5
6.	Resumen de resultados con clasificador ARN y SVM [10]. . . . .	5
7.	Resumen del rendimiento de la RNA para dos clases variando la cantidad de características utilizadas en el dominio de la frecuencia [11]. . . . .	6
8.	Resumen del rendimiento de la RNA para dos clasificadores binarios utilizando características individuales en dominio de la frecuencia [11]. . . . .	6
9.	Biopac MP36 [14]. . . . .	11
10.	Captura de señal EMG. . . . .	11
11.	Captura de señal ECG [17]. . . . .	12
12.	Captura de señal EEG. . . . .	13
13.	Filtro pasa banda [22]. . . . .	14
14.	Electrodos de superficie no invasivos. . . . .	15
15.	Modelo SVM [34]. . . . .	17
16.	Modelo red neuronal [36]. . . . .	18
17.	Manipulador serial: Puma 560 [47]. . . . .	22
18.	Interfaz cerebro-máquina [50]. . . . .	23
19.	Primera posición de electrodos en capturas EMG. . . . .	26
20.	Segunda posición de electrodos en capturas EMG. . . . .	26
21.	Primer gesto: puño arriba. . . . .	27
22.	Segundo gesto: puño abajo. . . . .	27
23.	Tercer gesto: puño cerrado. . . . .	28
24.	Cuarto gesto: Palma extendida. . . . .	28
25.	Posición de electrodos en capturas EEG [13]. . . . .	29
26.	Primer gesto EEG: Levantar cejas. . . . .	30
27.	Segundo gesto EEG: Cabeza hacia abajo. . . . .	30
28.	Tercer gesto EEG: Cabeza hacia arriba. . . . .	31
29.	Cuarto gesto EEG: Inclinar cabeza hacia derecha. . . . .	31

30.	Selección de tipo de captura en BSL Analysis 4.1. . . . .	32
31.	Calibración de instrumento de captura, EMG. . . . .	33
32.	Extraer data de grabación en BSL Analysis 4.1. . . . .	33
33.	Mostrar tiempo de segmento en selección, BSL Analysis 4.1. . . . .	34
34.	Struct individual, captura 60 segundos. . . . .	34
35.	Plantilla utilizada para las capturas EEG/EMG. . . . .	35
36.	Transformada rápida de Fourier para captura EEG. . . . .	37
37.	Filtros aplicados en una captura de señal EMG. . . . .	38
38.	Fitros aplicados en una captura de señal EEG. . . . .	39
39.	Segmentos de actividad (en rojo) detectados por el algoritmo. . . . .	41
40.	Ondas cerebrales para gesto 4: cabeza inclinada; señal filtrada. . . . .	42
41.	Espectro de amplitud unilateral de ondas cerebrales, gesto 4: cabeza inclinada.	43
42.	Identificación de segmentos de actividad utilizando características de ondas beta. . . . .	44
43.	Ejemplo de características extraídas para un gesto. . . . .	47
44.	Matriz de segmentos, técnica de <i>zero padding</i> . . . . .	48
45.	Curva de entrenamiento con <i>zero padding</i> . . . . .	49
46.	Señal sinusoidal de ejemplo, interpolación lineal vs. cúbica. . . . .	50
47.	Segmento de señal EEG completado utilizando interpolación cúbica. . . . .	50
48.	Curva de entrenamiento de segmentos homogeneizados. . . . .	51
49.	Rendimiento 2 clases - Extracción de características en el dominio de la frecuencia. . . . .	52
50.	Rendimiento 2 clases - Extracción de características en el dominio del tiempo. . . . .	53
51.	Rendimiento 1 clase - Algoritmo detección de actividad. . . . .	53
52.	Rendimiento - Extracción de datos .xlsx. . . . .	53
53.	Rendimiento 2 clases, 5 sujetos - Extracción de características en el dominio de la frecuencia. . . . .	53
54.	Rendimiento 2 clases, 5 sujetos - Extracción de características en el dominio del tiempo. . . . .	53
55.	Matriz de confusión, Dominio del tiempo, 5 características - inter-sujeto. . . .	55
56.	Matriz de confusión, Dominio del tiempo, 5 características - intra-sujeto. . . .	55
57.	Hiper-parámetros modificables en la nueva interfaz. . . . .	56
58.	Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	58
59.	Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	58
60.	Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	59
61.	Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	60
62.	Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	61
63.	Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	61

64.	Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	62
65.	Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	62
66.	Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	63
67.	Resumen resultados clasificador para señales EMG - inter-sujeto. . . . .	64
68.	Resumen resultados clasificador para señales EMG - intra-sujeto. . . . .	64
69.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	65
70.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	66
71.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	66
72.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	67
73.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	67
74.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	68
75.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	69
76.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	70
77.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	70
78.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	71
79.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	71
80.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	72
81.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	73
82.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	73
83.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	74
84.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	75
85.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	75
86.	Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba. . . . .	76
87.	Resumen resultados clasificador para señales EEG - Inter-sujeto. . . . .	77
88.	Resumen resultados clasificador para señales EEG - Intra-sujeto. . . . .	77
89.	Clasificación inter-sujeto de 3 gestos, 5 características en el dominio del tiempo. . . . .	78
90.	Clasificación inter-sujeto de 4 gestos, 5 características en el dominio del tiempo. . . . .	79

91. Clasificación sujeto P000, 2 gestos, 5 características en el dominio del tiempo.	80
92. Clasificación sujeto P000, 3 gestos, 5 características en el dominio del tiempo.	80
93. Clasificación sujeto P000, 4 gestos, 5 características en el dominio del tiempo.	81
94. Clasificación sujeto P001, 2 gestos, 5 características en el dominio del tiempo.	81
95. Clasificación sujeto P001, 3 gestos, 5 características en el dominio del tiempo.	82
96. Clasificación sujeto P001, 4 gestos, 5 características en el dominio del tiempo.	82
97. Clasificación inter-sujeto de 3 gestos, 5 características en el dominio del tiempo.	83
98. Clasificación inter-sujeto de 4 gestos, 5 características en el dominio del tiempo.	84
99. Clasificación inter-sujeto de 3 gestos, 6 características en el dominio de la frecuencia. . . . .	84
100. Clasificación inter-sujeto de 4 gestos, 6 características en el dominio de la frecuencia. . . . .	85
101. Clasificación sujeto P000, 2 gestos, 5 características en el dominio del tiempo.	86
102. Clasificación sujeto P000, 3 gestos, 5 características en el dominio del tiempo.	86
103. Clasificación sujeto P000, 3 gestos, 5 características en el dominio del tiempo.	87
104. Clasificación sujeto P001, 2 gestos, 5 características en el dominio del tiempo.	87
105. Clasificación sujeto P001, 3 gestos, 5 características en el dominio del tiempo.	88
106. Clasificación sujeto P001, 3 gestos, 5 características en el dominio del tiempo.	88
107. Clasificación sujeto P000, 2 gestos, 6 características en el dominio de la frecuencia. . . . .	89
108. Clasificación sujeto P000, 3 gestos, 6 características en el dominio de la frecuencia. . . . .	89
109. Clasificación sujeto P000, 4 gestos, 6 características en el dominio de la frecuencia. . . . .	90
110. Clasificación sujeto P001, 2 gestos, 6 características en el dominio de la frecuencia. . . . .	90
111. Clasificación sujeto P001, 3 gestos, 6 características en el dominio de la frecuencia. . . . .	91
112. Clasificación sujeto P001, 4 gestos, 6 características en el dominio de la frecuencia. . . . .	91
113. Resumen resultados SVM, clasificación EMG. . . . .	92
114. Resumen resultados SVM, clasificación EEG. . . . .	92
115. Resultados RN, clasificación de segmentos sanos, ictales, preictales e interictales.	93
116. Resultados RN, clasificación de segmentos sanos, ictales, preictales e interictales.	94
117. Resultados SVM, clasificación de segmentos sanos, ictales, preictales e interictales. . . . .	94
118. Resultados SVM, clasificación de segmentos sanos, ictales, preictales e interictales. . . . .	95
119. Configuración de interfaz para generar anotaciones automáticas. . . . .	96
120. Anotaciones automáticas generadas para EDF proporcionado por HUMANA. . . . .	96
121. Diagrama de flujo comunicación serial, Tiva-C. . . . .	98
122. Interfaz de recolección EMG/EEG, acceso directo a <i>BSL Analysis 4.1</i> . . . . .	99
123. Interfaz de recolección EMG/EEG, generación de plantilla. . . . .	99
124. Definición de manipulador Puma 560, convención <i>Denavit-Hartenberg</i> . . . . .	100
125. Carga de segmento señal EMG (puño arriba). . . . .	101
126. Carga de segmento señal EMG (puño abajo). . . . .	102
127. Carga de segmento señal EMG (palma extendida). . . . .	102

128. Carga de segmento señal EMG (puño) . . . . .	103
129. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	110
130. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	111
131. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	111
132. Matriz de confusión de 2 clases: Puño arriba, puño abajo. . . . .	112
133. Matriz de confusión de 2 clases: Puño arriba, puño abajo. . . . .	112
134. Matriz de confusión de 2 clases: Puño arriba, puño abajo. . . . .	113
135. Matriz de confusión de 2 clases: Puño arriba, puño abajo. . . . .	113
136. Matriz de confusión de 2 clases: Puño arriba, puño abajo. . . . .	114
137. Matriz de confusión de 2 clases: Puño arriba, puño abajo. . . . .	114
138. Matriz de confusión de 2 clases: Puño arriba, puño abajo. . . . .	115
139. Matriz de confusión de 2 clases: Puño arriba, puño abajo. . . . .	115
140. Matriz de confusión de 2 clases: Puño arriba, puño abajo. . . . .	116
141. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	116
142. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	117
143. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	117
144. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	118
145. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	118
146. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	119
147. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	119
148. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	120
149. Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño. . . . .	120
150. Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	121
151. Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	121
152. Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida. . . . .	122
153. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	123
154. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	123
155. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	124
156. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	124
157. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	125
158. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	125
159. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	126
160. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	127
161. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	127
162. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	128
163. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	128
164. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	129
165. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	129
166. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	130
167. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	130
168. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	131
169. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	131
170. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	132
171. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	132

172. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	133
173. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	133
174. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	134
175. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	134
176. Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo. . . . .	135
177. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	135
178. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	136
179. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	136
180. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	137
181. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	137
182. Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.	138
183. Clasificación sujeto P002, 2 gestos, 5 características en el dominio del tiempo.	139
184. Clasificación sujeto P002, 3 gestos, 5 características en el dominio del tiempo.	139
185. Clasificación sujeto P002, 3 gestos, 5 características en el dominio del tiempo.	140

---

## Resumen

---

En este trabajo se presentan una serie de análisis estadísticos con el fin de evaluar el rendimiento, la calidad y la precisión de los sistemas Biopac como alternativa de captura, en colaboración con interfaces humano-máquina. Las interfaces desarrolladas destacaron por su alto grado de personalización y versatilidad, adaptándose de manera eficaz tanto a señales EMG como a señales EEG, permitiendo así controlar manipuladores seriales utilizando técnicas de aprendizaje automático.

El estudio introduce alternativas a los algoritmos previamente desarrollados, empleando en su lugar algoritmos que permiten la identificación de segmentos de actividad mediante umbrales adaptativos. Estos nuevos algoritmos lograron una considerable reducción en el tiempo de análisis de las señales. Los algoritmos desarrollados en etapas previas lograron generar anotaciones automáticas en señales obtenidas con la colaboración de HUMANA, identificando segmentos ictales, inter y preictales exitosamente. Además de esto, se ha evidenciado una mejora en la capacidad de clasificación mediante la aplicación de redes neuronales y máquinas de vectores de soporte.

El proyecto evidenció que las características en tiempo continuo requirieron el mínimo poder computacional, logrando tasas de clasificación excepcionales, llegando inclusive al 100 % de precisión en ciertos casos. Esto las convierte en una opción rápida y precisa para su implementación en algoritmos de aprendizaje automático. Finalmente, el trabajo sienta las bases para identificar la relación entre el estudio de la oscilación neural en la banda beta y la coordinación cerebro-motriz del cuerpo humano.

---

## Abstract

---

The project presents a series of statistical analyses aimed at evaluating the performance, quality, and accuracy of Biopac systems as a capture alternative, in collaboration with human-machine interfaces. The developed interfaces stand out for their high degree of customization and versatility, effectively adapting to both EMG and EEG signals, enabling the control of serial manipulators using machine learning techniques.

The study introduces alternatives to algorithms developed in previous stages, benefiting from algorithms that allowed for the identification of activity segments through adaptive thresholds. These algorithms achieved a significant reduction in processing times and demonstrated notable improvements in classification capability using neural networks and support vector machines.

The project revealed that continuous-time features required minimal computational power, achieving exceptional classification rates, even reaching 100 % accuracy in certain cases. This makes them a fast and accurate option for implementation in machine learning algorithms. Finally, the present work lays the groundwork for identifying the relationship between the study of neural oscillation in the beta band and the brain-motor coordination of the human body.

# CAPÍTULO 1

---

## Introducción

---

En el cruce entre la medicina y el desarrollo de algoritmos de inteligencia artificial, ha prevalecido el campo de diagnóstico de afecciones neuronales mediante la aplicación de algoritmos de aprendizaje automático. El trabajo propone la implementación de los sistemas Biopac como motor principal en la captura de señales bioeléctricas, particularmente enfocándose en señales electromiográficas (EMG) y electroencefalográficas (EEG).

El objetivo principal de este proyecto involucró aplicar los algoritmos de aprendizaje automático desarrollados en etapas previas a una mayor cantidad de señales bioeléctricas, procedentes tanto de la colaboración con HUMANA como de los sistemas Biopac en la UVG. Paralelamente, se identificaron mejoras en las interfaces biomédicas preexistentes así como también mejoras en el acondicionamiento y extracción de características para capturas EMG/EEG. La integración del sistema Biopac en las interfaces biomédicas impulsó una interacción más fluida entre el usuario y el entrenamiento de los algoritmos de aprendizaje automático.

El documento presenta la metodología aplicada para la recolección sistemática de señales, la aplicación de algoritmos de extracción de características, reconocimiento de patrones, y el desarrollo de las interfaces humano-máquina. La validación de los resultados está respaldada por análisis estadísticos que guiaron la evolución y el perfeccionamiento de los algoritmos, incluyendo estudios intra e intersujeto.

## CAPÍTULO 2

---

### Antecedentes

---

Entre los trastornos neurológicos más comunes a nivel global se encuentra la epilepsia, la cual representa un 6 % de la carga global de enfermedades. Según datos de la OPS en 2021, se registra que alrededor de 60 millones de personas a nivel mundial sufren de epilepsia; cifra que se proyecta duplicar cada 20 años. En Latinoamérica y el Caribe se destaca la mayor prevalencia de la afección neurológica, donde se estima viven 5 millones de personas afectadas por cuadros epilépticos [1].

En Guatemala se encuentra consolidado el Centro de Epilepsia y Neurocirugía Funcional, HUMANA. El centro HUMANA estima que 325,000 personas sufren de epilepsia a nivel nacional, con un 30 % siendo pacientes que presentan un cuadro clínico de difícil control. El diagnóstico de la afección y su categorización no es posible de realizar mediante observación directa, por lo que se implementa el análisis de señales electroencefalográficas, EEG. Las anotaciones de una señal EEG son realizadas por un profesional que resalta los segmentos de interés, sin embargo, este procedimiento puede resultar largo y tedioso (24-72 hrs) [2].

Durante la última década, una gran cantidad de investigaciones se han enfocado en el procesamiento de señales y en la implementación de métodos para la extracción de características de las mismas. Al inicio se creía que las señales EEG eran valores aleatorios; sin embargo, se han descubierto diversos modelos matemáticos en el dominio del tiempo, la frecuencia y tiempo-frecuencia, los cuales son capaces de clasificar y distinguir patrones en las señales [3].

Con el objetivo de crear procesos innovadores que ayuden a personas con este tipo de afecciones, se ha abierto el espacio a la creación de aplicaciones que permiten la manipulación de sistemas utilizando datos obtenidos de señales bioeléctricas. En la Universidad del Valle de Guatemala se han desarrollado herramientas que permiten explorar diferentes aplicaciones a partir de la información extraída de estas señales. En el año 2020, con el trabajo de graduación presentado por María Fernanda Girón [4], se implementó una herramienta que permite utilizar señales electromiográficas (EMG) para el control de sistemas robóticos. En el trabajo, se implementaron algoritmos de aprendizaje supervisado que permiten la clasificación de movimientos o gestos a partir de características extraídas de señales EMG.

El mejor resultado obtenido fue a través de una Red Neuronal Artificial, con rendimiento superior al 90 % clasificando específicamente 4 movimientos. Adicionalmente, se observó que utilizando únicamente características en el dominio del tiempo fue suficiente para obtener rendimientos mayores al 80 %. Rodrigo Ralda con su trabajo de graduación [5], desarrolló la primera iteración de una interfaz que permite la manipulación de sistemas robóticos utilizando señales electroencefalográficas (EEG). En este trabajo se implementó la técnica de aprendizaje supervisado, utilizando Redes Neuronales Artificiales y Máquinas de Vectores de Soporte para encontrar una combinación con menor error al seleccionar características, el mejor rendimiento obtenido fue mayor al 80 %, logrando así manipular un sistema robótico con señales EEG.

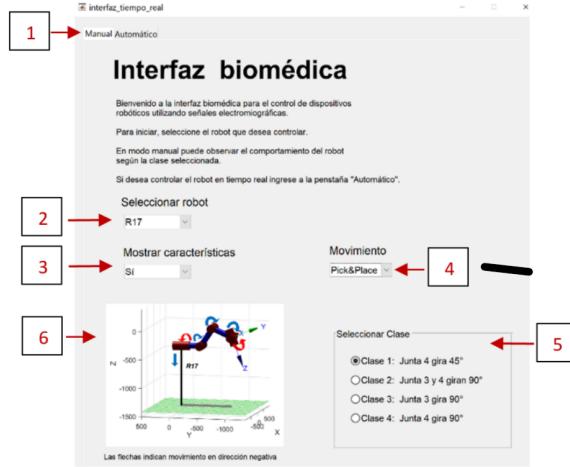


Figura 1: Interfaz de control de sistema róbótico con señales EMG [4].

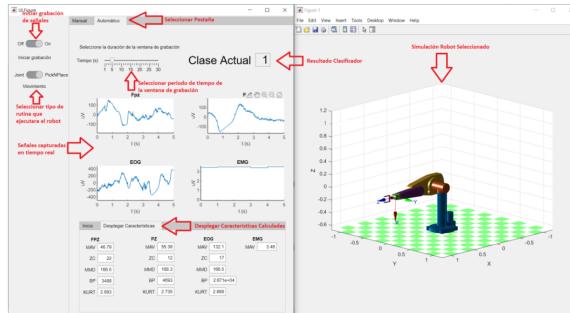


Figura 2: Interfaz de control de sistema róbótico con señales EEG [5].

Hasta el año 2020, las interfaces biomédicas no poseían correlación con respecto a las señales utilizadas en funcionamiento, el trabajo posterior presentado por Roberto José Cáceres García en el año 2021 [6] implementó la unificación de las interfaces, además de presentar control de sistemas robóticos utilizando la combinación de señales biomédicas EMG y EEG. En este trabajo se utilizó entrenamiento con 4 clases combinando las señales, que funcionaron parecido a dos clasificadores distintos. Esto logró un rendimiento superior al 91 %, también se realizaron pruebas grabando 2 clases distintivas para las señales EMG y usando las señales EEG como auxiliares, obteniendo un 87 % de rendimiento, finalmente utilizando características de la señal EMG únicamente se logró un 85 % de rendimiento. Los tra-

jos anteriormente expuestos nos dan poderosas herramientas y aplicaciones del aprendizaje automático que permiten a la información obtenida de señales bioeléctricas apoyar en la rehabilitación y detección de pacientes con afecciones neurológicas.

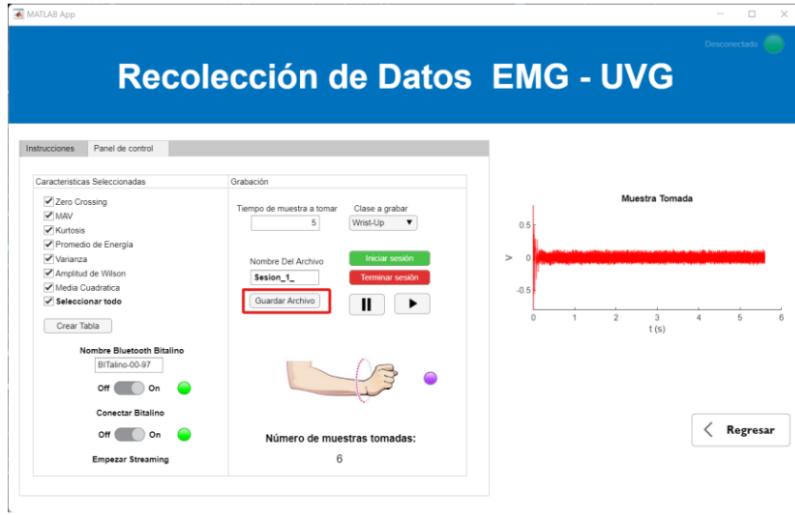


Figura 3: Interfaz de control de sistema robótico con señales EMG y EEG [6].

En la última década el área de diagnóstico de epilepsia ha implementado técnicas de aprendizaje automático maximizando la información y utilidades que se pueden obtener de las señales EEG. Entre estas aplicaciones se encuentran el análisis de neuroimágenes, detección automatizada de convulsiones a partir de señales EEG, predicción de mejorías utilizando recetas médicas, predicción de resultados post-quirúrgicos, entre otros [7].

En la Universidad del Valle de Guatemala, el trabajo de graduación presentado por María Jesús Angulo Tijerino en el año 2020 [8], implementó aprendizaje no supervisado como primera iteración en el estudio de señales EEG de pacientes HUMANA con registros epilépticos, al realizar una correcta división y categorización de segmentos, se encontró que es posible detectar crisis epilépticas en señales EEG de forma automática. En este mismo año se generó una base de datos con las muestras extraídas de HUMANA en el trabajo de graduación presentado por María Fernanda Pineda Esmieu [9], además creando una herramienta de software para la interacción con la base de datos y resultados.

Resultados Clasificador SVM (Máquina de Vectores de Soporte)								
Análisis	Caso	Base de Datos	Rendimiento VP	FN	FP	VN	Kernel Lineal	Kernel RBF
Directo	1	Ubonn	98%	50%	0%	0%	50% x	x
			100%	50%	0%	0%	50% x	x
			100%	50%	0%	0%	50% x	x
			95%	10%	1%	0%	9% x	x
		CHB-MIT	96.30%	38%	0%	3%	41% x	-
Wavelets	2	Ubonn	100%	41%	0%	0%	41% x	-
			100%	25%	0%	0%	25% x	-
			100%	25%	0%	0%	25% x	-
			100%	25%	0%	0%	25% x	-
			100%	25%	0%	0%	25% x	-

Figura 4: Resumen de resultados con clasificador SVM [8].

En el año 2021, David Alejandro Vela Aguilera en su trabajo de graduación [10] des-

Resultados Clasificador RNA (Red Neuronal Artificial)							
Análisis	Caso	Base de Datos	Rendimiento	VP	FN	FP	VN
Directo	1	Ubonn	99.5%	49.5%	0.0%	0.5%	50.0%
			99.5%	50.0%	0.5%	0.0%	49.5%
			97.1%	47.6%	0.5%	2.4%	49.5%
		CBH-MIT	100.0%	50.0%	0.0%	0.0%	50.0%
Wavelet	2	Ubonn	99.5%	50.0%	0.5%	0.0%	49.5%
			99.0%	50.0%	1.0%	0.0%	49.0%
			99.5%	50.0%	0.5%	0.0%	49.5%
			99.0%	49.5%	0.5%	0.5%	49.5%
		CHB-MIT					
		Daubechies 4	89.2%	44.9%	5.4%	5.4%	44.4%
		Daubechies 10	81.6%	42.6%	10.8%	7.6%	39.0%

Figura 5: Resumen de resultados con clasificador ARN [8].

rrolló una nueva versión de la herramienta de análisis de señales EEG para el estudio de epilepsia, en ella se realizaron ajustes en el clustering dividiendo las muestras en 4 clases, esto obtuvo un promedio de exactitud del 96.7 %, presentando una mejora significativa del proceso de clasificación. Adicionalmente, se realizó una sección que genera anotaciones de las señales EEG y las muestra de forma interactiva para facilidad del usuario. Hasta este año la manipulación de las señales fue en tiempo continuo, utilizando mayormente técnicas de aprendizaje supervisado, abriendo espacio a la implementación de otras técnicas de aprendizaje y el análisis en diferentes espectros, no solo el de tiempo continuo.

Características	Tiempo Continuo			Wavelet		
	Modelo	RNA	SVM	RNA	SVM	
Kernel	-	Gaussiano	Lineal	-	Gaussiano	Lineal
2 Clases	100%	99.80%	100%	97.70%	98.70%	97.90%
3 Clases	97.90%	98.90%	97.20%	98.20%	98.30%	97.20%
4 Clases	88%	91.30%	88.30%	81.20%	83.30%	77.10%
Promedio	95.30%	96.70%	95.20%	92.40%	93.40%	90.70%
Desv. Estándar	5.23%	3.81%	4.99%	7.90%	7.17%	9.64%

Figura 6: Resumen de resultados con clasificador ARN y SVM [10].

La última iteración en el año 2022, con el trabajo de graduación presentado por Camila Lemus Lone [11], implementó ambos tipos de aprendizaje; supervisado y no supervisado. En este trabajo se utilizaron características obtenidas en dominio de frecuencia, el entrenamiento y evaluación fue utilizando Redes Neuronales Artificiales y Máquinas de Vectores de Soporte para clasificadores binarios de las clases Ictal/Sano y las clases Interictal/Preictal, este tipo de clasificación obtuvo un rendimiento superior al 99 %. Los trabajos anteriormente expuestos implementaron el estudio de señales extraídas de fuentes públicas en su mayoría, presentando limitaciones al acceso de datos de pacientes HUMANA o de muestras utilizado equipo de la Universidad del Valle de Guatemala, afectando el volumen del estudio. Las limitaciones de anteriores proyectos abren el espacio para explorar la extracción de características utilizando diferentes espectros, aplicar los algoritmos desarrollados en bases de datos más extensas y generar estadísticas más exactas.

Cantidad de características	Características utilizadas (razones)	Exactitud RNA	
		Ubonn - Sano/Ictal	Kaggle - Interictal/Preictal
<b>1</b>	<b>1</b>	91.55%	90.50%
2	<b>1, 2</b>	100%	98.90%
3	<b>1, 2, 3</b>	99.99%	98.80%
4	<b>1, 2, 3, 4</b>	99.99%	98.80%
5	<b>1, 2, 3, 4, 5</b>	99.99%	98.80%
6	<b>1, 2, 3, 4, 5, std</b>	100%	99.40%

Figura 7: Resumen del rendimiento de la RNA para dos clases variando la cantidad de características utilizadas en el dominio de la frecuencia [11].

Extracción de características en dominio de la frecuencia				
Característica	Ubonn - Sano/Ictal		Kaggle - Interictal/Preictal	
	Porcentaje de rendimiento RNA	Tiempo	Porcentaje de rendimiento RNA	Tiempo
<b>razón 1</b>	91.00%	3.10 min	98.60%	4.52 min
<b>razón 2</b>	91.10%	3.08 min	84.20%	4.46 min
<b>razón 3</b>	77.00%	4.60 min	98.50%	6.76 min
<b>razón 4</b>	99.70%	2.88 min	96.10%	4.50 min
<b>razón 5</b>	90.90%	4.60 min	98.30%	6.16 min
<b>std</b>	99.60%	11.00 s	67.40%	9.73 s

Figura 8: Resumen del rendimiento de la RNA para dos clasificadores binarios utilizando características individuales en dominio de la frecuencia [11].

## CAPÍTULO 3

---

### Justificación

---

En la actualidad, el análisis de señales bioeléctricas por medio de algoritmos de aprendizaje automático desempeña un papel fundamental en el diagnóstico y el tratamiento de diversas condiciones médicas, así como en la investigación científica. No obstante, Guatemala no cuenta con acceso a estas herramientas, habilitando un costo de oportunidad para la aplicación de estas nuevas tecnologías de aprendizaje automático.

Previo a este trabajo, las bases de datos accedidas para el análisis de señales bioeléctricas por medio de aprendizaje automático han sido de fuentes públicas, limitando el alcance del proyecto y eliminando robustez en sus conclusiones. Por ello este trabajo tiene como objetivo expandir el alcance de los resultados obtenidos en fases previas, aplicando de manera sistemática algoritmos de aprendizaje automático desarrollados en etapas anteriores a una base de datos más grande. La elección de HUMANA y el sistema Biopac como fuentes de datos bioeléctricos es fundamentada por varias razones. HUMANA, por su parte, cuenta con el único laboratorio de Vídeo Electro Encefalograma en Guatemala, esta base de datos contiene registros obtenidos por especialistas en Neurociencia, justificando su validez. Por otro lado, el sistema Biopac es conocido por su fiabilidad y precisión en la grabación de señales bioeléctricas, lo que garantiza la calidad de los datos utilizados en este estudio.

En base a lo anterior, el presente trabajo se justifica con la validación de los algoritmos desarrollados en etapas anteriores a muchos más datos, mejorando las interfaces, herramientas desarrolladas, generación de estadísticas de comparación y la introducción de un nuevo método de extracción de señales bioeléctricas en el departamento, utilizando sistemas Biopac. Este trabajo puede contribuir a la mejora de los diagnósticos médicos, permitiendo una detección temprana de enfermedades y una mayor precisión en el seguimiento de la evolución de los pacientes. Además, puede impulsar el desarrollo de dispositivos médicos más eficientes.

# CAPÍTULO 4

---

## Objetivos

---

### Objetivo General

Aplicar los algoritmos de aprendizaje automático desarrollados en fases anteriores a una mayor cantidad de señales bioléctricas procedentes de HUMANA y señales obtenidas con el sistema Biopac dentro de la UVG, y mejorar las interfaces biomédicas desarrolladas anteriormente.

### Objetivos Específicos

- Recolectar señales bioeléctricas de forma sistemática y masiva utilizando el sistema Biopac.
- Aplicar algoritmos de extracción de características y aprendizaje automático, desarrollados en fases anteriores, a las señales recolectadas y señales obtenidas de HUMANA.
- Realizar análisis estadísticos para evaluar el rendimiento de los algoritmos e identificar posibles mejoras a los mismos.
- Mejorar las interfaces biomédicas desarrolladas anteriormente e integrar el uso del sistema Biopac para la captura de las señales bioeléctricas.

## CAPÍTULO 5

---

### Alcance

---

Este proyecto involucró el desarrollo en tres interfaces distintas: la interfaz de recolección de datos EMG/EEG, la interfaz dirigida al control robótico y la integración de la funcionalidad de captura de señales de Biopac en el *Epileptic Analysis Toolbox*, una herramienta que había sido desarrollada en fases anteriores. El trabajo se dividió en cinco fases: la creación de una base de datos robusta, a través de la población de datos extraídos utilizando los sistemas Biopac, el procesamiento de señales, la creación de un algoritmo para la detección de actividad, la aplicación de algoritmos para la extracción de características y aprendizaje automático, y finalmente, la utilización de los clasificadores entrenados para el control de sistemas robóticos.

El alcance del proyecto se vio limitado por la incapacidad de obtener datos en tiempo real de los sistemas Biopac, debido a la encriptación realizada por la compañía. La empresa ofrece como única solución adquirir un kit de desarrollador, sin embargo, para este proyecto se planteó una alternativa que no incluye la adquisición de este kit. Se adaptó la metodología de trabajo a la utilización de una Tiva-C, conteniendo señales previamente capturadas. Se estableció una comunicación serial, por medio de la interfaz de control robótico, para simular lo que sería una transmisión en tiempo real.

Se espera que en proyectos futuros se aproveche plenamente la base de datos creada, así como también los algoritmos mejorados para la extracción de características, la identificación de segmentos de actividad y los clasificadores implementados para el uso de interfaces humano-máquina.

# CAPÍTULO 6

---

Marco teórico

---

## 6.1. Señales bioeléctricas

Las señales bioeléctricas son señales generadas por potenciales y corrientes eléctricas en organismos vivos. Estas señales son producidas por diversos procesos biológicos, como la actividad neuronal, la contracción muscular y la actividad cardiaca. Las señales bioeléctricas son ampliamente utilizadas en la medicina y la investigación científica para el diagnóstico, la monitorización y el estudio de diversas funciones fisiológicas. Las tres señales principales de estudio son: señales Electromiográficas (EMG), Electroencefalográficas (EEG), y Electrocardiogramas (ECG) [12].

## 6.2. Biopac

Biopac Systems, Inc. es una empresa que se dedica a la fabricación y venta de equipos y software para la adquisición y análisis de datos fisiológicos. Sus sistemas de captura se utilizan en investigaciones científicas, estudios clínicos y aplicaciones educativas en una variedad de campos, como la psicología, la fisiología, la neurociencia y la biomecánica. Los sistemas de captura de Biopac están diseñados para medir y registrar una amplia gama de señales fisiológicas [13], incluyendo:

- **Señales electrofisiológicas:** Estos sistemas pueden capturar señales eléctricas generadas por el cuerpo humano, como el electrocardiograma (ECG), la electroencefalografía (EEG), la electromiografía (EMG) y la electrodermal activity (EDA). Estas mediciones proporcionan información sobre la actividad eléctrica del corazón, el cerebro, los músculos y la respuesta de la piel [13].
- **Señales biomecánicas:** Los sistemas de Biopac también pueden registrar señales biomecánicas, como la actividad muscular, el movimiento y la fuerza. Utilizan sensores

y transductores para medir parámetros como la actividad de los músculos, la posición y la aceleración [13].

- **Señales respiratorias:** Los sistemas de Biopac pueden capturar señales relacionadas con la respiración, como el flujo de aire, la presión y la capacidad pulmonar. Estos datos son útiles en el estudio de la función pulmonar y la ventilación [13].



Figura 9: Biopac MP36 [14].

### 6.3. Señales EMG

Las señales electromiográficas se generan a partir de la actividad eléctrica de los músculos. Estas señales son captadas mediante electrodos colocados en la superficie de la piel o mediante agujas de electromiografía insertadas directamente en el músculo. El resultado del EMG proporciona información sobre la actividad muscular, como la contracción, relajación, fuerza y coordinación.

El análisis de las señales EMG se utiliza en diversas áreas, como la medicina, la rehabilitación, la biomecánica y la investigación científica. Se emplea para evaluar el funcionamiento y la salud de los músculos, diagnosticar trastornos neuromusculares, y evaluar la eficacia de terapias y tratamientos [15].

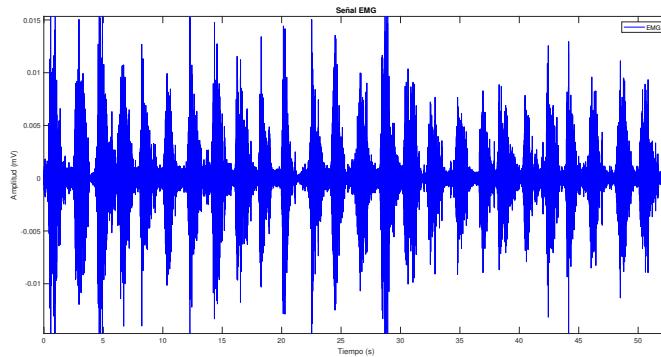


Figura 10: Captura de señal EMG.

## 6.4. Señales ECG

Las señales electrocardiográficas son generadas por la actividad eléctrica del corazón. Estas señales son captadas mediante electrodos colocados en la superficie del cuerpo, generalmente en el pecho, las extremidades y otras ubicaciones específicas donde se pueda monitorear el comportamiento del corazón. El ECG registra los cambios en el potencial eléctrico que ocurren durante el ciclo cardíaco, lo que permite evaluar la función cardíaca y detectar posibles anomalías o trastornos.

El análisis de las señales ECG se utiliza ampliamente en la medicina para el diagnóstico, la monitorización y el tratamiento de enfermedades cardíacas. Permite evaluar la regularidad del ritmo cardíaco, identificar arritmias, falta de flujo sanguíneo en el corazón, evaluar la función de las cámaras cardíacas, evaluar la respuesta del corazón a diferentes estímulos y medicamentos [16].

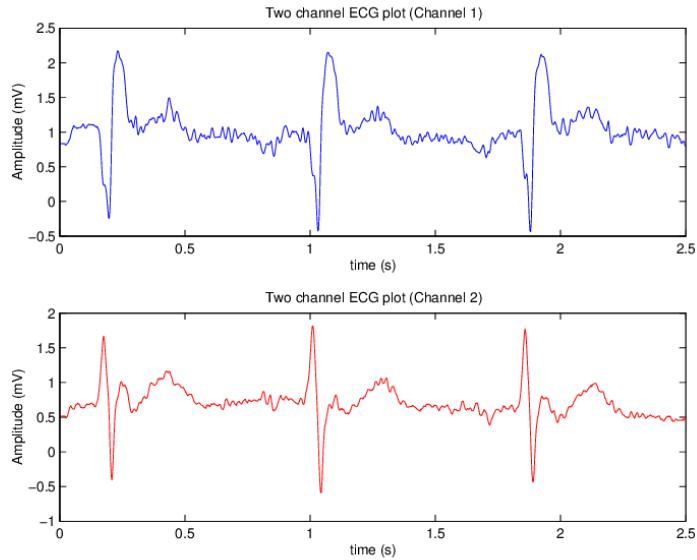


Figura 11: Captura de señal ECG [17].

## 6.5. Señales EEG

Las señales electroencefalográficas son señales bioeléctricas que registran la actividad eléctrica del cerebro. Estas señales son capturadas mediante electrodos colocados en el cuero cabelludo y proporcionan información sobre la actividad neuronal, los patrones de sueño, la función cognitiva y otras actividades cerebrales [18]. Es de particular interés este tipo de señal para el estudio de la epilepsia, pues permite observar el comportamiento del cerebro al exponerse a estímulos sensoriales. Los patrones más frecuentes en señales EEG para describir la actividad cerebral son denominados ritmos. Los ritmos cerebrales son especialmente afectados por el estado del sueño, edad, y presencia de patologías. Los ritmos cerebrales se pueden dividir en ondas Delta (0.5 - 3 Hz), Theta (4 - 7 Hz), Alpha (8 - 12 Hz), Beta (13 - 30 Hz) y Gamma (30 - 120 Hz) [19].

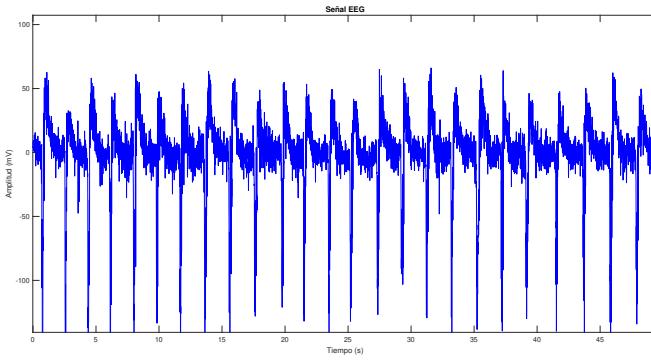


Figura 12: Captura de señal EEG.

## 6.6. Procesamiento de señales bioeléctricas

El procesamiento de señales bioeléctricas refiere al análisis y la manipulación de las señales eléctricas generadas por el cuerpo humano. Este procedimiento implica una serie de técnicas y algoritmos que permiten extraer, analizar y visualizar la información contenida en las señales. Esto incluye la eliminación de ruido y artefactos, la detección y segmentación de eventos de interés, la extracción de características relevantes y la clasificación de patrones. El procesamiento de señales utilizando MATLAB es una tarea comúnmente realizada en el campo de la ingeniería y las ciencias de la computación. La herramienta MATLAB ofrece una amplia gama de herramientas y funciones específicamente diseñadas para el procesamiento de señales, lo que facilita el análisis y la manipulación de datos bioeléctricos [20].

El procedimiento se puede generalizar según el siguiente listado de tareas:

- **Adquisición de datos:** MATLAB proporciona funciones para leer y cargar datos de señales bioeléctricas desde diferentes fuentes, como archivos de formato común (por ejemplo, .mat, .csv) o mediante interfaces de adquisición de datos.
- **Preprocesamiento de señales:** Esta etapa implica la limpieza y preparación de las señales para su análisis. Puede incluir la eliminación de ruido, filtrado, normalización, detección de artefactos y segmentación de eventos de interés [21].
- **Análisis y extracción de características:** MATLAB ofrece una variedad de funciones y herramientas para realizar análisis en el dominio de tiempo, frecuencia y tiempo-frecuencia de las señales. También se pueden utilizar técnicas de transformada de Fourier, transformada Wavelet y métodos de análisis espectral para extraer características relevantes de las señales [21].
- **Visualización de señales:** MATLAB proporciona funciones para visualizar las señales en diferentes formatos, como gráficos de líneas, gráficos de dispersión, espectrogramas y mapas de colores. Estas visualizaciones ayudan a comprender mejor las características y patrones de las señales [21].
- **Modelado y clasificación:** MATLAB ofrece algoritmos y herramientas para construir modelos de aprendizaje automático y realizar tareas de clasificación, como la

detección de eventos o la identificación de patrones específicos en las señales bioeléctricas [21].

## 6.7. Filtrado de señales

El filtrado de señales bioeléctricas es una técnica fundamental en el procesamiento de señales, este filtrado tiene como objetivo eliminar el ruido no deseado y resaltar las características relevantes de interés. El filtrado se aplica para mejorar la calidad de las señales bioeléctricas, facilitar su análisis y reducir las interferencias que puedan afectar su interpretación. Existen diferentes tipos de filtros utilizados en el procesamiento de señales bioeléctricas, como filtros pasa banda, filtros rechaza banda, filtros paso alto, filtros paso bajo y filtros de mediana, entre otros. Estos filtros se aplican según las características específicas de la señal y los objetivos del análisis. La elección del filtro adecuado depende de factores como



Figura 13: Filtro pasa banda [22].

el tipo de ruido presente en la señal, la frecuencia de la señal de interés y la preservación de las características importantes de la señal original. Además, se pueden utilizar técnicas avanzadas, como el filtrado adaptativo, para adaptar el filtro a las características cambiantes de la señal [23].

## 6.8. Métodos de captura de señales bioeléctricas

Entre los métodos de captura de señales bioeléctricas existen:

- **Electrodos de contacto:** Se utilizan electrodos de metal o material conductor que se colocan en contacto directo con la piel. Estos electrodos capturan las señales bioeléctricas a través de la conducción eléctrica [24].
- **Electrodos secos:** Son electrodos que no requieren de un gel conductor o líquido para realizar la conexión eléctrica con la piel [24].
- **Electrodos no invasivos:** Este método de captura no requiere la inserción de electrodos dentro del cuerpo. Este método es utilizado comúnmente en la electroencefalografía (EEG) de superficie, la electrocardiografía (ECG) de superficie y la electromiografía (EMG) de superficie [25].

- **Electrodos intracorporales:** Son métodos de captura que implican la inserción de electrodos dentro del cuerpo para registrar las señales bioeléctricas directamente desde los órganos o tejidos. Estos métodos se utilizan en aplicaciones específicas, como la electrocorticografía (ECoG) o la estimulación eléctrica directa [25].



Figura 14: Electrodos de superficie no invasivos.

## 6.9. Epilepsia

La epilepsia es un trastorno neurológico crónico caracterizado por la presencia recurrente de convulsiones o crisis epilépticas. Se origina debido a una actividad eléctrica anormal y excesiva en el cerebro, lo que provoca una variedad de síntomas que van desde movimientos involuntarios y alteraciones de la conciencia, hasta convulsiones generalizadas. Según datos de la OPS, las afecciones neurológicas representan un 6 % de la carga global de enfermedades, posicionando a la afección entre las más comunes a nivel mundial [1].

Esta afección puede manifestarse de diferentes maneras, algunas convulsiones pueden ser breves y sutiles, como la pérdida de conciencia momentánea o una sensación extraña, otras pueden ser más intensas, con movimientos violentos, pérdida total de conciencia y cambios en la respiración y la función motriz [26].

- **Causas:** Existen múltiples causas, como lesiones cerebrales traumáticas, infecciones cerebrales, trastornos genéticos, trastornos metabólicos, tumores cerebrales o anomalías en el desarrollo del sistema nervioso central. Sin embargo, en muchos casos, la causa exacta no se puede determinar [27].
- **Diagnóstico:** El diagnóstico de la epilepsia implica la evaluación clínica, donde se recopilan los antecedentes médicos y se realizan pruebas, como un electroencefalograma

(EEG). En este tipo de diagnóstico se utiliza la observación mediante videocámaras, y el monitoreo de las ondas cerebrales en tiempo real [27].

- **Tratamiento:** El tratamiento de la epilepsia generalmente involucra el uso de medicamentos antiepilepticos para controlar las convulsiones. En algunos casos, cuando los medicamentos no son efectivos, se pueden considerar otras opciones terapéuticas, como la cirugía cerebral o la estimulación del nervio vago [28].

## 6.10. Aprendizaje automático

El aprendizaje automático es un campo de estudio de la inteligencia artificial que se enfoca en el desarrollo de algoritmos y modelos estadísticos que permiten a las computadoras aprender y mejorar automáticamente a través de la experiencia. El aprendizaje automático se utiliza en una amplia gama de aplicaciones, particularmente se utiliza en el diagnóstico médico como herramienta para mejorar la eficiencia y categorización de las señales bioeléctricas. Este proceso de automatización permite la extracción de información que por métodos de visualización es imposible obtener [29]. Algunas de las características del aprendizaje automático son:

- **Extracción automática de características:** El aprendizaje automático permite identificar y extraer automáticamente características relevantes de las señales bioeléctricas, lo que facilita el análisis y la interpretación de los datos. Esto es especialmente útil en señales complejas como la electroencefalografía (EEG) o la electromiografía (EMG), donde las características relevantes pueden ser sutiles y difíciles de detectar para un observador humano [30].
- **Clasificación y diagnóstico:** Los algoritmos de aprendizaje automático pueden aprender a clasificar diferentes patrones en las señales bioeléctricas, lo que resulta crucial para el diagnóstico de enfermedades y trastornos. Por ejemplo, en el caso de la epilepsia, el aprendizaje automático puede ayudar a identificar patrones anormales en las señales EEG que son característicos de los episodios epilépticos [30].
- **Personalización:** El aprendizaje automático también puede ayudar a personalizar los enfoques de tratamiento y cuidado de los pacientes. Al analizar las señales bioeléctricas de un individuo y combinarlas con información clínica adicional, los modelos de aprendizaje automático pueden adaptar las intervenciones terapéuticas para satisfacer las necesidades específicas de cada paciente, mejorando así los resultados y la atención médica en general [30].

## 6.11. Aprendizaje no supervisado

El aprendizaje no supervisado es una de las ramas del aprendizaje automático, en ella el algoritmo de aprendizaje se encarga de descubrir patrones y estructuras ocultas en los datos sin la ayuda de etiquetas o información previa, por ende su nombre. El aprendizaje no supervisado se centra en explorar la estructura de los datos y agruparlos en conjuntos. Este

tipo de aprendizaje permite agrupar a los datos en cantidades determinadas por el usuario o de forma natural [31].

## 6.12. Aprendizaje supervisado

El aprendizaje supervisado es otra rama del aprendizaje automático donde se utilizan datos etiquetados para entrenar un modelo. En ella, el modelo aprende a realizar predicciones o tomar decisiones mediante el método de entrenadores y sujetos de prueba, donde se conoce la respuesta correcta. El objetivo es migrar el conocimiento aprendido de las etiquetas previas, a datos no pertenecientes al grupo entrenado, logrando un rendimiento preciso en la tarea de predicción de los datos no conocidos [32].

## 6.13. Máquinas de vectores de soporte

Las Máquinas de Vectores de Soporte (SVM) son un algoritmo de aprendizaje supervisado que se utiliza en problemas de clasificación y regresión. La idea principal detrás de las SVM es encontrar un hiperplano en un espacio de alta dimensionalidad que permita separar de manera óptima dos clases de datos. Este hiperplano se selecciona de manera que maximice la distancia entre los puntos de datos más cercanos de cada clase. Si los datos no son linealmente separables en el espacio de características original, las SVM pueden emplear funciones de kernel para mapear los datos a un espacio de mayor dimensionalidad donde sean linealmente separables. Los kernels comunes incluyen el kernel lineal, el kernel gaussiano, entre otros.

Las SVM tienen la ventaja de ser eficaces en espacios de alta dimensionalidad y pueden manejar conjuntos de datos pequeños o grandes. También son robustas frente al sobreajuste debido a la maximización del margen. Además, las SVM se han extendido para resolver problemas de clasificación multiclas y regresión [33].

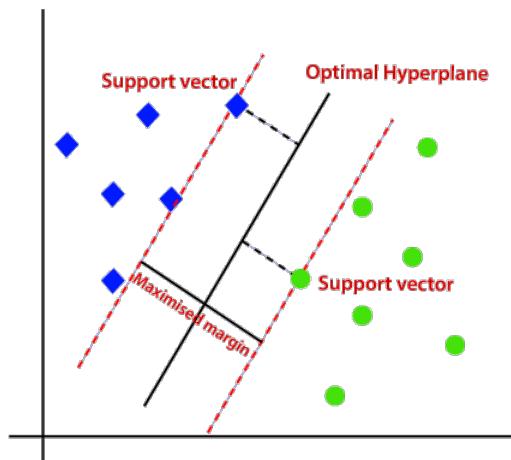


Figura 15: Modelo SVM [34].

## 6.14. Redes Neuronales

Las redes neuronales son un paradigma de aprendizaje automático inspirado en la estructura y el funcionamiento del cerebro humano. Son modelos computacionales que consisten en capas de nodos interconectados, diseñados para procesar información de manera similar a cómo las neuronas en el cerebro procesan señales eléctricas y químicas.

La unidad básica de una red neuronal es el **nodo**, este al tomar entradas, realiza una combinación lineal de todas, ponderadas por parámetros denominados **pesos**, luego aplica una función de activación no lineal. La función de activación introduce no linealidad en la red, lo que le permite aprender relaciones y patrones complejos en los datos. Las redes neuronales se organizan en capas, con una capa de entrada, una o más capas ocultas y una capa de salida. La información fluye desde la capa de entrada a través de las capas ocultas hasta la capa de salida. Cada conexión entre nodos tiene un peso asociado que se ajusta durante el proceso de entrenamiento de la red. El proceso de entrenamiento implica la presentación de un conjunto de datos de entrenamiento a la red y la actualización iterativa de los pesos para minimizar una función de pérdida, que mide la diferencia entre las salidas predichas y las salidas reales. Esto se hace mediante algoritmos de optimización como el descenso de gradiente.

Las redes neuronales se han utilizado en una amplia variedad de aplicaciones de aprendizaje automático, incluyendo reconocimiento de imágenes, procesamiento de lenguaje natural, reconocimiento de voz, y más. Con el surgimiento de las redes neuronales profundas (también conocidas como redes neuronales profundas o DNN), que tienen muchas capas ocultas, se ha logrado un gran avance en la capacidad de modelar datos complejos y de alto nivel [35].

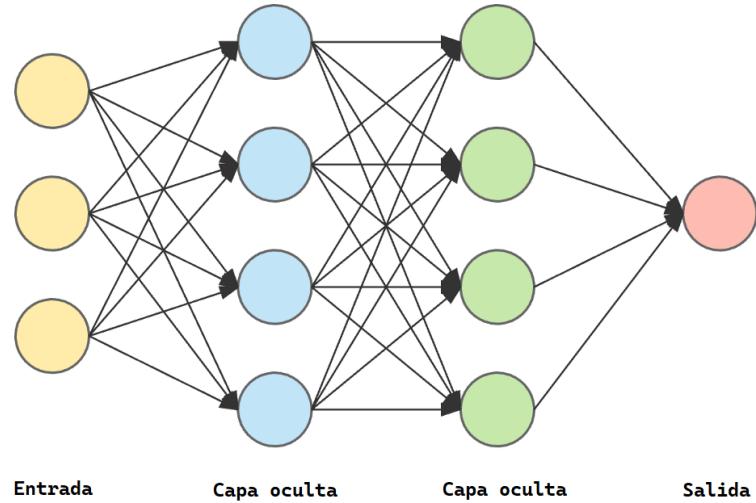


Figura 16: Modelo red neuronal [36].

## 6.15. Características en el dominio del tiempo

Las características más simples de la señal EEG son características estadísticas, como la media, la mediana, la varianza, la desviación estándar, la asimetría, la curtosis y similares [37].

- **Integración de la señal:** Este valor es obtenido calculando la sumatoria de los valores absolutos de una señal EMG. Puede ser tratada como un estimador de poder [38].
- **Media del valor absoluto:** Estima la media del valor absoluto, sumando el valor absoluto de  $x_i$  en un segmento  $k$  y divido por la longitud del segmento [38].
- **Media cuadrática:** Se modela como un proceso aleatorio gaussiano modulado en amplitud cuyo RMS es relacionado con la fuerza constante y la contracción no fatigante [38].
- **Longitud de Waveform:** Longitud acumulada en forma de onda sobre un segmento escogido. Los valores resultantes indican una medida de amplitud, frecuencia y duración en un solo valor [38].
- **Zero Crossings:** Número de veces que la forma de onda cruza cero, es bueno incluir un umbral para detectar los ceros, ya que por el ruido pueden haber ceros falsos [38].

## 6.16. Características en el dominio de la frecuencia

Las potencias relativas de ciertas bandas de frecuencia son las características de dominio de frecuencia más utilizadas en todos los campos de análisis de las señales de EEG. Comúnmente, bandas de frecuencia más utilizadas son la Delta, Theta, Alpha, Beta, y Gamma, aunque también existe la banda Sigma (12–14 Hz). Las relaciones entre las bandas de frecuencia (*ratios*) se utilizan ampliamente como características en el análisis de señales de EEG [37].

- **Coeficientes autorregresivos:** Describe cada muestra de la señal EMG como una combinación lineal de muestras anteriores más un término de error de ruido blanco. Los coeficientes AR se utilizan como características en el reconocimiento de patrones EMG [38].
- **Mediana de frecuencia:** Divide la densidad del espectro de potencia en dos partes iguales [38].
- **Densidad espectral de potencia:** Es la base para el cálculo de las características del dominio de la frecuencia, se puede calcular con varios métodos paramétricos y no paramétricos. Los métodos no paramétricos se usan con más frecuencia e incluyen métodos como la transformada de Fourier (generalmente calculada con el algoritmo de transformada rápida de Fourier, FFT), el método de Welch o el método multicono de Thompson [37].

## 6.17. *K-Fold Cross Validation*

En el ámbito de la ciencia de datos y el aprendizaje automático, la validación cruzada *K-fold* (*K-fold Cross Validation*) es una técnica fundamental para evaluar y validar el rendimiento de modelos predictivos. Esta metodología es especialmente relevante en la aplicación de algoritmos de aprendizaje automático a conjuntos de datos tales como las máquinas de soporte vectorial, ya que permite estimar de manera más robusta la capacidad de generalización de un modelo a partir de un conjunto limitado de datos disponibles [39].

La validación cruzada K-fold implica la división del conjunto de datos en K particiones o *folds* de aproximadamente igual tamaño. Luego, se realiza un proceso iterativo en el que K-1 de estos *folds* se utilizan para entrenar el modelo, mientras que el *fold* restante se reserva para evaluar el rendimiento del modelo entrenado. Este proceso se repite K veces, de manera que cada *fold* se utiliza exactamente una vez como conjunto de prueba. Finalmente, se calcula la métrica de rendimiento (como la precisión o el error) en cada una de las K iteraciones y se obtiene un promedio para evaluar el rendimiento general del modelo [40].

## 6.18. Modelo Autorregresivo (AR)

Un modelo autorregresivo (AR) es un tipo de modelo estadístico que se utiliza para describir y predecir series temporales. En un modelo AR, se asume que el valor actual de una serie temporal depende linealmente de sus valores anteriores en el tiempo. La idea principal detrás de un modelo AR es que cualquier patrón o estructura en la serie temporal puede explicarse en términos de sus propios valores pasados. El modelo AR se define mediante su orden, denotado como  $p$ , que representa la cantidad de pasos en el pasado que se utilizan para predecir el valor actual [41].

La ecuación general de un modelo AR( $p$ ) se expresa como:

$$X_t = c + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + \varepsilon_t \quad (1)$$

## 6.19. Criterio de Información de Akaike (AIC)

El Criterio de Información de Akaike (AIC) es una medida estadística que se utiliza comúnmente para la selección de modelos en estadística y análisis de series temporales. Fue desarrollado por Hirotugu Akaike en 1974 y se ha convertido en una herramienta fundamental para determinar el ajuste adecuado de un modelo a un conjunto de datos. El AIC se basa en principios de teoría de la información y proporciona una forma de comparar modelos estadísticos en función de su capacidad para explicar los datos sin sobreajuste.

El AIC se calcula utilizando la siguiente fórmula:

$$AIC = 2k - 2\ln(L) \quad (2)$$

Un valor más bajo de AIC indica un mejor ajuste del modelo a los datos, teniendo en cuenta la penalización por la complejidad del modelo  $2k$ . El AIC se utiliza comúnmente en

la selección de modelos, especialmente en casos donde se están considerando varios modelos posibles. Al comparar diferentes modelos, se prefiere aquel que tenga el AIC más bajo, ya que se considera que proporciona un equilibrio óptimo entre la capacidad de ajuste y la simplicidad del modelo [42].

## 6.20. Filtro de Blanqueo

El filtro de blanqueo es una técnica esencial en el procesamiento de señales y el análisis de datos en diversas disciplinas, incluyendo la ingeniería biomédica y el procesamiento de señales bioeléctricas. Su objetivo principal es decorrelacionar las señales y eliminar cualquier estructura de correlación lineal presente en los datos, lo que facilita un análisis más preciso y la detección de características relevantes en los mismos. El proceso de blanqueo se basa en dos pasos principales. En primer lugar, se calcula la matriz de covarianza de los datos originales, que describe las relaciones de correlación entre las diferentes señales. Luego, se aplica una transformación a los datos utilizando esta matriz de covarianza inversa, lo que tiene el efecto de decorrelacionar las señales y normalizar su varianza [43].

El filtro de blanqueo es particularmente útil en el análisis de señales biomédicas, como las señales electromiográficas (EMG) y electroencefalográficas (EEG). Al aplicar el filtro de blanqueo a estas señales, se reduce el impacto de las correlaciones no deseadas y se resaltan las características relevantes, como patrones de actividad muscular o señales cerebrales específicas [44].

## 6.21. Sobreajuste (*Overfit*)

El *overfitting*, también conocido como sobreajuste, es un fenómeno crítico en el aprendizaje automático y la construcción de modelos de clasificación. Ocurre cuando un clasificador se ajusta en exceso a los datos de entrenamiento y captura el ruido presente en esos datos en lugar de aprender patrones generales subyacentes. Este comportamiento lleva a una pérdida significativa de la capacidad de generalización del modelo, lo que significa que el clasificador será menos efectivo al hacer predicciones en datos nuevos o no vistos previamente.

El *overfitting* puede ocurrir debido a la complejidad excesiva del modelo o a la falta de datos de entrenamiento suficientes. Los modelos demasiado complejos, como los árboles de decisión profundos o las redes neuronales con demasiadas capas, tienen una mayor probabilidad de sobreajustarse a los datos de entrenamiento. Además, si el conjunto de datos de entrenamiento es pequeño en relación con la complejidad del modelo, es más probable que se produzca el sobreajuste [45].

## 6.22. Manipulador Serial

Un manipulador serial, también conocido como brazo robótico serial, es un dispositivo mecánico articulado compuesto por una serie de eslabones conectados por articulaciones

rotativas o prismáticas. Este tipo de robot es ampliamente utilizado en una variedad de aplicaciones, desde la fabricación industrial hasta la investigación en robótica. Un ejemplo destacado de un manipulador serial es el Puma 560.

El Puma 560 es un manipulador serial de 6 grados de libertad (GDL) que ha sido ampliamente estudiado y utilizado en la investigación en robótica. Fue desarrollado por la empresa Unimation a principios de la década de 1980 y se ha convertido en un estándar en el campo. El Puma 560 se caracteriza por su estructura articulada que consta de seis articulaciones rotativas que permiten una amplia gama de movimientos tridimensionales. Los manipuladores seriales, como el Puma 560, se utilizan en diversas aplicaciones, incluyendo la manipulación de objetos, ensamblaje industrial, cirugía asistida por robots y muchas otras tareas que requieren precisión y control. La cinemática y dinámica de estos manipuladores son temas de interés clave en la investigación en robótica, ya que comprenden la base teórica para el control y la planificación de movimientos. En la simulación y control de manipuladores seriales, se utilizan herramientas y bibliotecas específicas, como la *Robotics Toolbox* desarrollada por Peter Corke para uso específico en MATLAB, que proporcionan funciones y recursos para el análisis, la simulación y el control de robots [46].

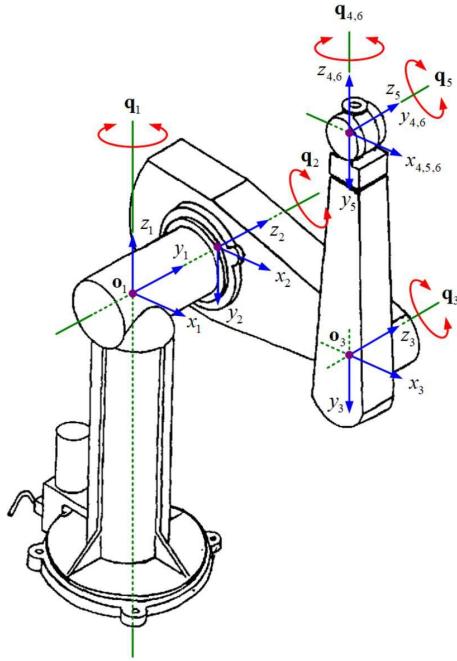


Figura 17: Manipulador serial: Puma 560 [47].

### 6.23. *Denavit-Hartenberg*

La representación *Denavit-Hartenberg* (DH) es un enfoque fundamental en la descripción de la cinemática de manipuladores seriales y brazos robóticos. Esta metodología, desarrollada por Jacques Denavit y Richard Hartenberg en la década de 1950, ha demostrado ser una herramienta invaluable en la modelización y control de manipuladores robóticos.

La representación DH se basa en una serie de parámetros que describen las relaciones

entre las articulaciones y los eslabones en un manipulador serial. Estos parámetros incluyen las longitudes de los eslabones, los ángulos de las articulaciones, las distancias entre las articulaciones y los ángulos de torsión. Utilizando esta información, se puede construir una matriz de transformación homogénea para cada articulación, lo que permite calcular la posición y orientación de la herramienta final del robot en función de las variables articulares. Esta es utilizada en la programación y simulación de robots, ya que proporciona una forma sistemática y estandarizada de describir la geometría y la cinemática de manipuladores seriales [48].

## 6.24. Interfaz cerebro-máquina

Las Interfaces Cerebro-Máquina (BCI) representan la interacción entre el cerebro humano y las máquinas. Estas interfaces permiten la comunicación directa entre el cerebro y dispositivos externos, como computadoras, prótesis, robots y otros sistemas. El objetivo principal de las BCI es traducir las señales cerebrales en comandos que controlen estas máquinas, brindando así una nueva forma de comunicación y control para personas con discapacidades motoras.

Las BCI se basan en la idea de que el cerebro genera señales eléctricas que pueden ser registradas y decodificadas para comprender la intención del individuo. Estas señales provienen de regiones específicas del cerebro, como la corteza motora, y pueden incluir señales electroencefalográficas (EEG), señales electromiográficas (EMG). El proceso fundamental de una BCI implica la adquisición de señales cerebrales, su procesamiento y la generación de comandos para el dispositivo externo. Los algoritmos de aprendizaje automático, como las redes neuronales y las máquinas de vectores de soporte, se utilizan para decodificar las señales cerebrales y traducirlas en acciones específicas, como mover un cursor en una pantalla o controlar el movimiento de una prótesis. Las aplicaciones de las BCI son diversas y van desde restaurar la movilidad y la comunicación en personas con discapacidades hasta permitir una interacción humano-máquina fluída [49].

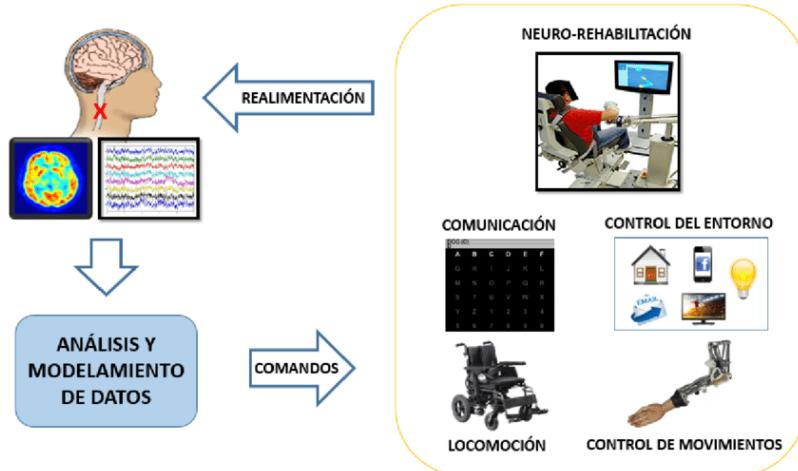


Figura 18: Interfaz cerebro-máquina [50].

## 6.25. Entropía cruzada (*cross-entropy*)

La entropía cruzada, también conocida como *cross-entropy loss* en inglés, es una medida de la diferencia entre dos distribuciones de probabilidad. En el contexto del aprendizaje automático y la clasificación, se utiliza comúnmente como una función de costo para evaluar la diferencia entre las distribuciones de probabilidad predichas por un modelo y las distribuciones de probabilidad reales (etiquetas) asociadas a los datos de entrenamiento [51].

La entropía cruzada se utiliza especialmente en problemas de clasificación y se expresa en términos de probabilidades. Cuanto más diferentes sean las probabilidades predichas por el modelo de las probabilidades reales, mayor será la entropía cruzada y, por lo tanto, mayor será la penalización en términos de la función de costo. La fórmula básica de la entropía cruzada para un solo ejemplo de clasificación binaria es:

$$H(y, p) = -[y \cdot \log(p) + (1 - y) \cdot \log(1 - p)] \quad (3)$$

Donde:

- $H(y, p)$  es la entropía cruzada entre la etiqueta real  $y$  y la probabilidad predicha  $p$ .
- $y$  es la etiqueta real (1 si el ejemplo pertenece a la clase objetivo, 0 en caso contrario).
- $p$  es la probabilidad predicha por el modelo de que el ejemplo pertenezca a la clase objetivo.

# CAPÍTULO 7

---

## Recolección de señales bioeléctricas

---

Con el fin de crear una base de datos robusta y variada para el análisis de algoritmos de extracción de características y aprendizaje automático, se propuso la captura sistemática y masiva de señales que incluyeran una variedad de gestos de activación muscular y cerebral. Este proceso se llevó a cabo utilizando los sistemas Biopac, logrando proporcionar datos suficientes y variados para el entrenamiento de los algoritmos de aprendizaje automático y reconocimiento de patrones. Los estudios se basaron en grabaciones de 60 segundos por sesión, siendo un total de 5 sesiones por sujeto. La en el dominio de la frecuencia de las actividades se estableció fueran cada 2 segundos para señales EMG y aproximadamente cada 4 segundos para EEG.

### 7.1. Posición de electrodos - EMG

Para garantizar la versatilidad de los datos y obtener estadísticas más precisas, se llevó a cabo la captura de señales en dos posiciones principales de electrodos, tal y como se observa en las Figuras 19 y 20. Para los gestos EMG capturados, la elección de estas posiciones se basó en la consideración de los músculos involucrados en las contracciones de interés, específicamente el *Flexor Digitorum Profundus* y el *Extensor Carpi Radialis Brevis*. La metodología utilizada implicó un proceso de palpación y referencia anatómica para determinar las mejores ubicaciones.

### 7.2. Captura de señales - EMG

De las capturas de señales EMG, se tomaron una variedad de parámetros, particularmente se trajeron los datos en crudo de las señales, la ventana de tiempo de captura y la



Figura 19: Primera posición de electrodos en capturas EMG.



Figura 20: Segunda posición de electrodos en capturas EMG.

en el dominio de la frecuencia de muestreo. Estos datos son relevantes en el estudio de las señales bioeléctricas, pues permiten el procesamiento y la extracción de características de las mismas.

### 7.2.1. Gesto 1: Puño arriba

Este gesto implica la acción de mover la mano empuñada hacia arriba, como se observa en la Figura 21. Durante este gesto, el músculo *Extensor Carpi Radialis Brevis* se contrae primordialmente, por lo que, se utilizó la segunda posición de electrodos.

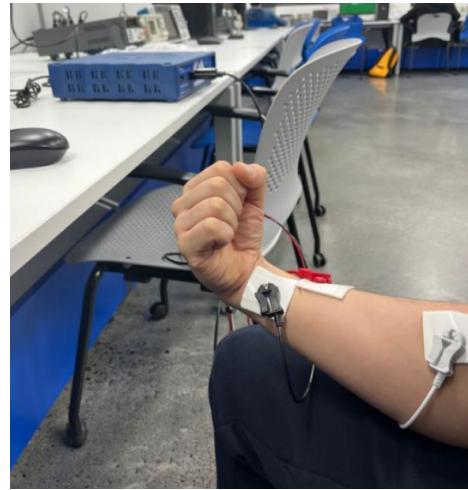


Figura 21: Primer gesto: puño arriba.

### 7.2.2. Gesto 2: Puño abajo

Este gesto implica la acción de contraer la mano empuñada hacia abajo, como se observa en la Figura 22. Durante este gesto, el músculo *Flexor Digitorum Brevis* desempeña un papel importante al contraerse para flexionar los dedos, mientras que el *Extensor Carpi Radialis Brevis* también se activa para estabilizar la muñeca. Este gesto fue capturado utilizando la primera posición de electrodos.

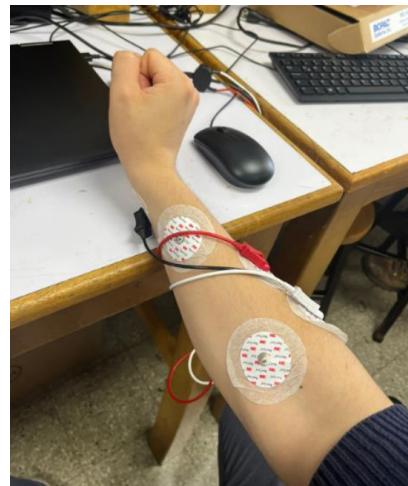


Figura 22: Segundo gesto: puño abajo.

### **7.2.3. Gesto 3: Puño cerrado**

El gesto de puño cerrado es un movimiento que implica la acción de cerrar la mano de manera firme, con los dedos flexionados hacia la palma, este se puede observar en la Figura 23. La captura fue llevada a cabo utilizando la primera posición de electrodos.

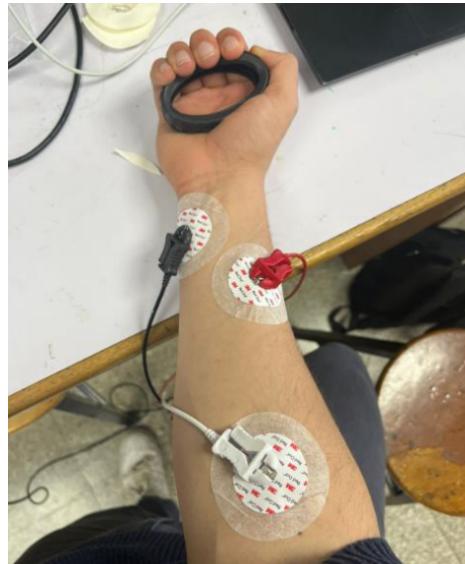


Figura 23: Tercer gesto: puño cerrado.

### **7.2.4. Gesto 4: Palma extendida**

El gesto de palma extendida es un movimiento que implica la acción de abrir la mano de manera firme, con los dedos completamente extendidos, tal y como se observa en la Figura 24. La captura fue llevada a cabo utilizando la segunda posición de electrodos.



Figura 24: Cuarto gesto: Palma extendida.

### 7.3. Posición de electrodos - EEG

Para la captura de señales electroencefalográficas (EEG) se utilizó primordialmente una posición de electrodos. Esta posición contiene el electrodo de tierra en la región del Mastoide, considerada según la guía de Biopac para la captura de señales que incluyen gestos de parpadeo y movimientos de cabeza. Con el objetivo de asegurar la obtención de datos óptimos en las mediciones EEG, se siguieron meticulosamente las directrices recomendadas por las guías de Biopac. En primer lugar, se preparó la superficie del cuero cabelludo apartando el cabello de la zona de adhesión de los electrodos, lo que permitió un mejor contacto. Además, se limpió la piel previo a la colocación de electrodos. Para maximizar la eficacia de la adhesión, se aplicó una cantidad precisa de gel a cada electrodo y se ejerció una presión constante durante aproximadamente un minuto después de la colocación inicial. Durante la adquisición de señales EEG, se enfatizó la necesidad de que el sujeto permaneciera inmóvil. La posición se puede visualizar en la Figura 25.



Figura 25: Posición de electrodos en capturas EEG [13].

## 7.4. Captura de señales - EEG

Las grabaciones EEG contienen en promedio longitudes de 5 minutos por sujeto. Al igual que en las grabaciones EMG, se extrajeron los datos en crudo, la ventana de tiempo de captura y la en el dominio de la frecuencia de muestreo.

### Gesto 1: Cejas Arriba

Este gesto implica accionar los músculos en la frente para levantar las cejas de manera rítmica y controlada, como se puede observar en la Figura 26. Su grabación se utiliza para estudiar gestos faciales y sus efectos en la actividad eléctrica cerebral.

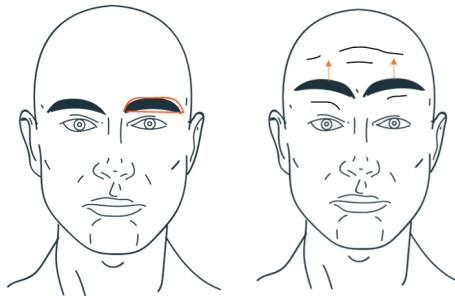


Figura 26: Primer gesto EEG: Levantar cejas.

### 7.4.1. Gesto 2: Cabeza hacia abajo

Este gesto implica inclinar la cabeza hacia abajo, hacia el pecho o en dirección al suelo, tal y como se puede observar en la Figura 27. Este gesto se utiliza para estudiar cambios en la posición de la cabeza y su influencia en las ondas cerebrales.

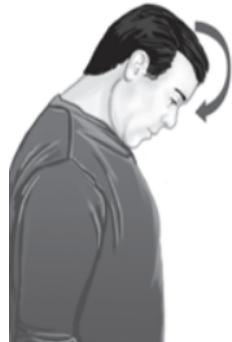


Figura 27: Segundo gesto EEG: Cabeza hacia abajo.

#### **7.4.2. Gesto 3: Cabeza hacia arriba**

El gesto implica elevar la cabeza hacia arriba, alejándola del pecho o de su posición habitual, como se muestra en la Figura 28.



Figura 28: Tercer gesto EEG: Cabeza hacia arriba.

#### **7.4.3. Gesto 4: Cabeza inclinada**

El gesto implica inclinar la cabeza hacia la derecha, como se puede observar en la Figura 29. Este gesto se utiliza para estudiar la actividad cerebral asociada con cambios en la posición de la cabeza y su influencia en las ondas cerebrales.

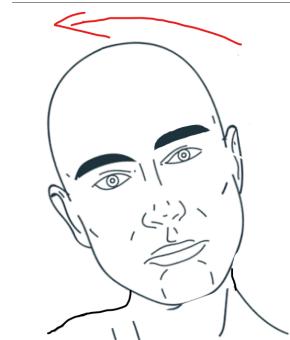


Figura 29: Cuarto gesto EEG: Inclinar cabeza hacia derecha.

### **7.5. Base de datos - Humana**

Las señales utilizadas en esta sección fueron suministradas por investigaciones realizadas en el Centro de Epilepsia HUMANA en formato EDF. Estas señales abarcan datos de segmentos ictales, preictales e interictales. El análisis de estas señales implica trabajar con períodos de tiempo considerablemente largos, lo que permite obtener información detallada tanto sobre los ataques epilépticos como sobre el comportamiento normal de las ondas cerebrales específicas para cada sujeto.

# CAPÍTULO 8

## Extracción y manipulación de datos en MATLAB

Como primera fase, fue necesario convertir los datos de grabaciones a un formato que pudiera ser procesado por la herramienta de desarrollo utilizada, en este caso MATLAB. Los algoritmos desarrollados en etapas previas ya se encontraban en esta herramienta y poseían una estructura predefinida, por lo que el proceso de extracción y preparación de datos fue fundamental para garantizar que los algoritmos y clasificadores pudieran ser aplicados en el análisis de las nuevas capturas.

Inicialmente, los datos de las capturas de señales EEG y EMG fueron tomadas con el *software* BSL Analysis 4.1; desarrollado por Biopac Systems Inc. El programa muestra un selector como el de la Figura 30 donde se permite elegir el método de captura. Este proyecto enfatizó las capturas L01 y L04. Para proseguir con una captura, es necesario calibrar el equipo. Esto se hace mediante una pequeña ventana de captura donde es necesario permanecer quieto y seguir las instrucciones mostradas en pantalla. En la Figura 31 se muestra la calibración realizada para capturar señales EMG.

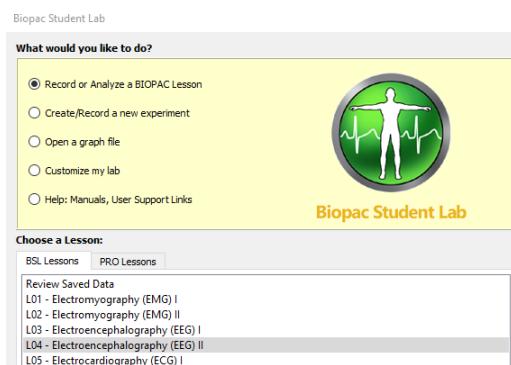


Figura 30: Selección de tipo de captura en BSL Analysis 4.1.

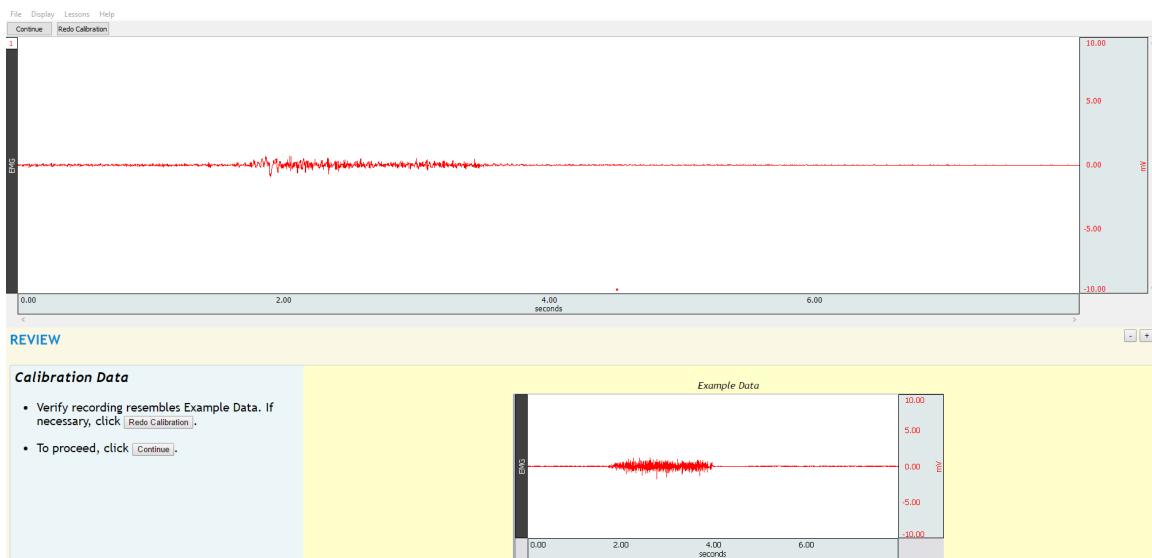


Figura 31: Calibración de instrumento de captura, EMG.

Una vez finalizada la calibración, el software permite iniciar la captura de señales bioeléctricas. El proceso de extracción de información por medio del *software* BSL Analysis 4.1 implicó la selección de los segmentos de captura relevantes para el estudio. Este programa ofrece la capacidad de extraer tanto los datos pertinentes, como se muestra en la Figura 32, como el intervalo de tiempo delta correspondiente al segmento seleccionado, como se muestra en la Figura 33. Una vez obtenida esta información, se archivaron los datos en formato Excel (.xlsx) con la plantilla utilizada en la Figura 35. Este fue un paso previo a la manipulación en MATLAB.

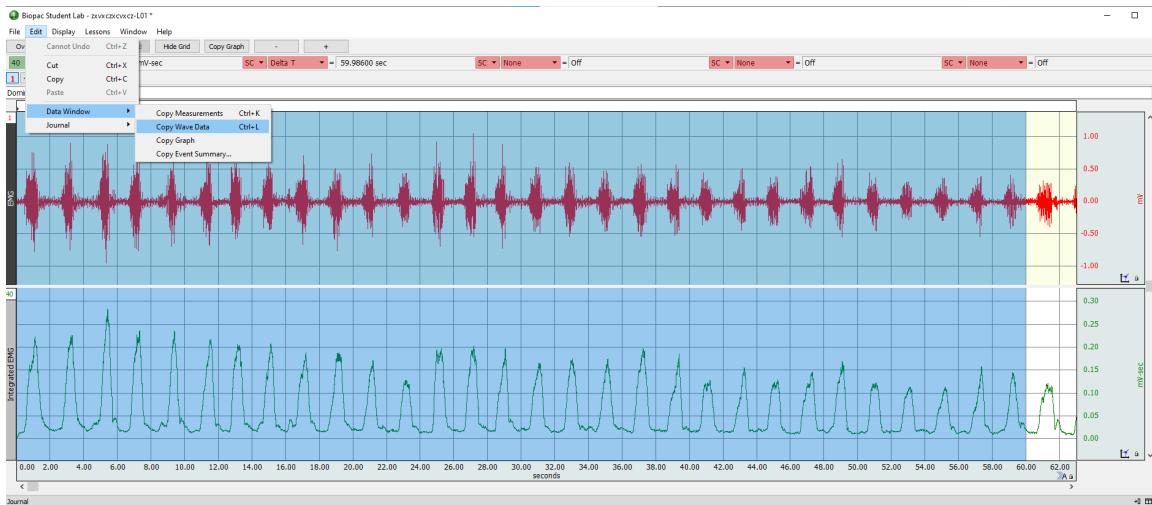


Figura 32: Extraer data de grabación en BSL Analysis 4.1.

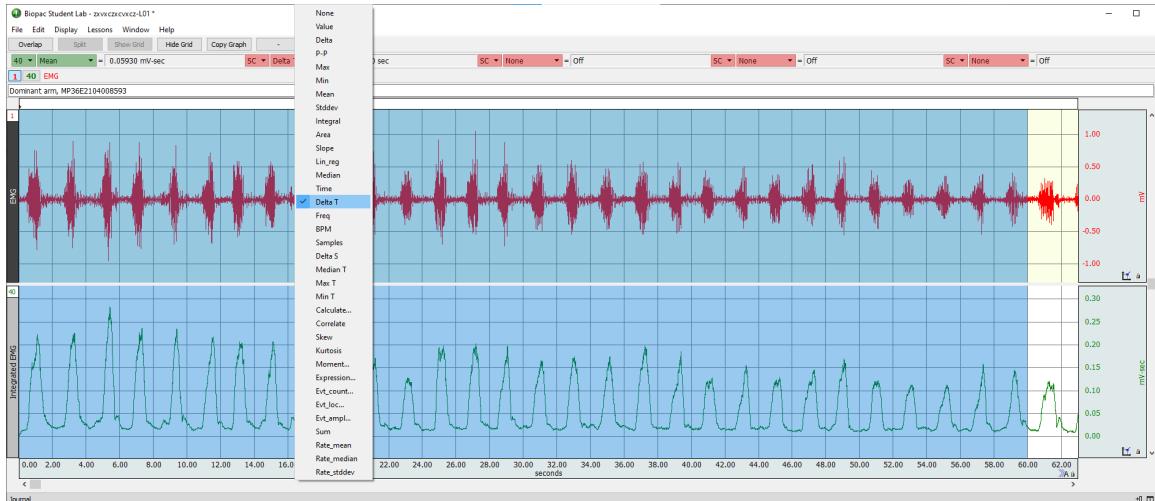


Figura 33: Mostrar tiempo de segmento en selección, BSL Analysis 4.1.

## 8.1. Algoritmo de extracción de datos en MATLAB

Para la migración del formato de datos en Excel (.xlsx) a MATLAB (.mat), se desarrolló un algoritmo que toma como entrada el archivo del gesto en formato Excel (.xlsx), el algoritmo desarrollado procede a extraer los datos de la plantilla. Cada conjunto de datos se organizó en una estructura denominada *struct*, como se puede visualizar en la Figura 34 con los siguientes campos:

- **data:** Contiene los datos brutos de la señal.
- **data\_length\_sec:** Representa la longitud de la señal en segundos.
- **sampling\_frequency:** Indica la en el dominio de la frecuencia de muestreo de la señal.
- **channels:** Describe el canal o canales de la señal.

Al finalizar la extracción de datos, el algoritmo permite al usuario especificar los nombres de los archivos .mat resultantes y la ubicación, lo que facilitó la manipulación de varios gestos a la vez, así como también la adición de gestos al estudio.

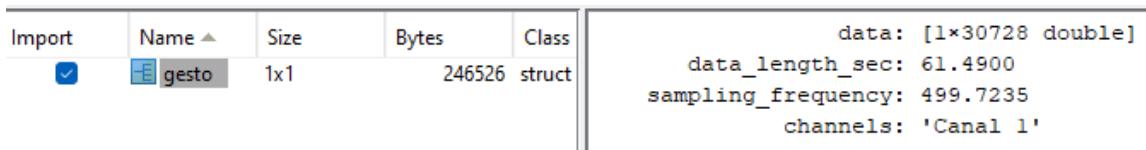


Figura 34: Struct individual, captura 60 segundos.

## 8.2. Almacenamiento en formato .mat

Cada grabación de 60 segundos por sujeto se almacenó en un archivo .mat individual, también se realizó un proceso de concatenación para generar un archivo .mat único que contiene la información de todas las grabaciones. Esto permitió una fácil manipulación y análisis posterior de los datos, alistándolos para ser utilizados en los algoritmos de extracción de características y aprendizaje automático.

	A	B	C	D	E
1	data	data_length_sec	sampling_frequency	channels	
2	-3.14941	326.33	229.1177642	canal 1	
3	-15.7959				
4	-22.937				
5	-24.884				
6	-23.2117				
7	-19.6655				
8	-13.562				
9	-8.22754				
10	-5.7312				
11	-5.04761				
12	-4.5166				

Figura 35: Plantilla utilizada para las capturas EEG/EMG.

# CAPÍTULO 9

---

## Procesamiento de señales capturadas

---

El procesamiento de señales desempeña un papel crucial en este proyecto, particularmente en la obtención de información confiable y útil de las señales bioeléctricas registradas. El proceso elimina el ruido presente y facilita la identificación de segmentos de actividad. En el presente capítulo se discute la lógica detrás del diseño de los filtros utilizados.

### 9.1. Filtro pasa bandas - EMG

Para el procesamiento de las señales EMG, se aplicó un filtro *Butterworth* pasa bandas de segundo orden. Este tipo de filtro es conocido por su capacidad para preservar la forma de onda de las señales, mientras atenúa eficazmente las en el dominio de la frecuencias no deseadas. Las componentes de en el dominio de la frecuencia con información útil dada la mayor concentración de energía en señales EMG, es entre los 50 Hz y 150 Hz, aunque su canal de información va de los 20 Hz a los 250 o 300 Hz [52].

### 9.2. Filtro pasa bandas - EEG

El procesamiento de señales EEG, por otra parte, contiene información en un rango de en el dominio de la frecuencias que difiere al de una señal EMG. En la Figura 36 se muestra el espectro de amplitud unilateral (en el dominio de la frecuencia) utilizado como base para el estudio EEG.

Del análisis espectral, se extrajeron las en el dominio de la frecuencias en el intervalo de 0.5 Hz a 45 Hz. Este rango de en el dominio de la frecuencias corresponde a las en el dominio de la frecuencias de corte utilizadas en el diseño de un filtro *Butterworth* pasa bandas de

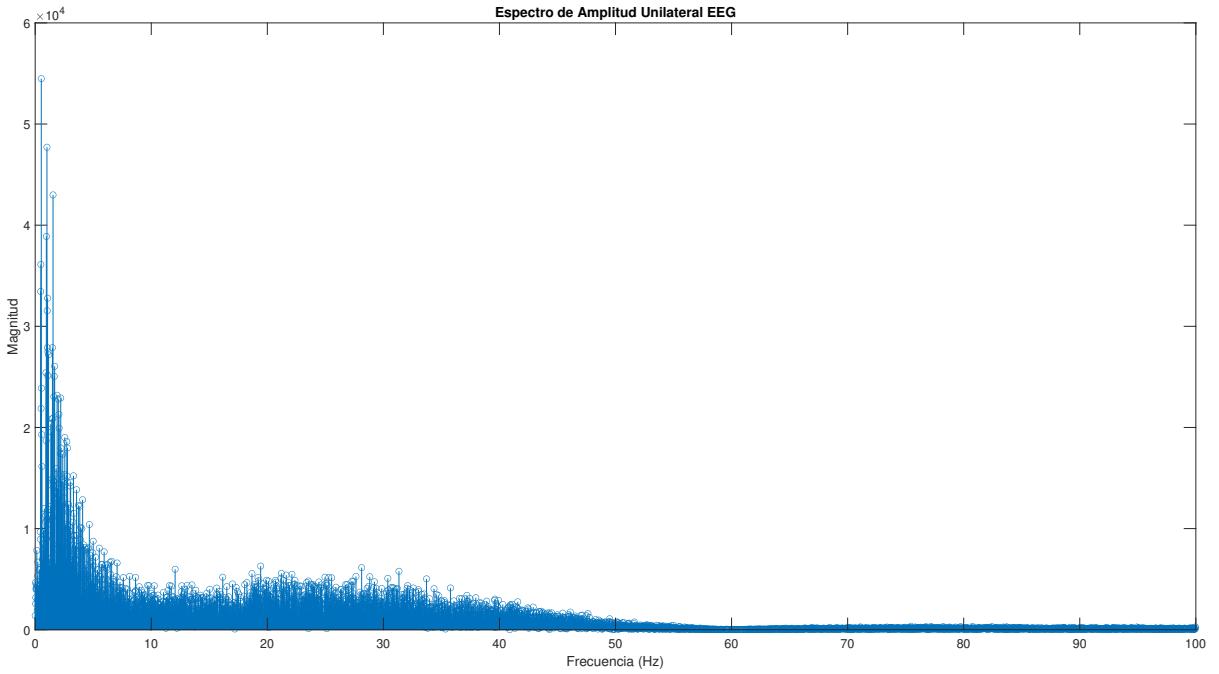


Figura 36: Transformada rápida de Fourier para captura EEG.

cuarto orden. Este filtro fue utilizado para acondicionar las señales EEG, alistándolas para la extracción de características y en particular, la extracción de las magnitudes de ondas cerebrales presentes.

### 9.3. Filtro rechaza bandas

Un aspecto crítico en el procesamiento de señales EEG y EMG, es la eliminación del ruido de en el dominio de la frecuencia de línea eléctrica, que a menudo se manifiesta entre 50 a 60 Hz. Para abordar este desafío, se implementó un filtro de rechaza banda. Este filtro se diseñó específicamente para atenuar las componentes de en el dominio de la frecuencia de línea eléctrica, garantizando así que las señales resultantes estuvieran libres de este tipo de interferencia.

### 9.4. Filtro de blanqueo

Basándose en el hecho que las señales EMG/EEG no son estacionarias, pues los músculos y señales cerebrales varían, las capturas pueden contener correlaciones significativas entre sus valores en diferentes puntos temporales [53]. Estadísticamente, estas correlaciones pueden dificultar la detección de eventos y la distinción de características específicas para la señal, ya que el ruido o la actividad pasada puede influir en los valores actuales. El filtro de blanqueo ayuda a eliminar estas correlaciones, dejando la señal con propiedades estadísticamente más

deseables. Al eliminar las correlaciones y reducir la dependencia temporal en la señal, el filtro de blanqueo demostró mejorar la sensibilidad de los algoritmos de detección.

Para aplicar este filtro, se desarrolló un algoritmo que busca el mejor orden para un modelo autorregresivo (AR), mediante el cálculo del criterio de información de Akaike (AIC). El orden AR óptimo se determinó eligiendo el valor que minimizaba el AIC, lo que indicó una mejor capacidad para modelar la señal. Una vez determinado el mejor orden, el desarrollo del algoritmo implicó obtener la varianza del ruido específico para una señal, permitiendo así eliminar correlaciones temporales y reducir efectivamente el ruido.

En la Figura 37 se pueden observar los filtros aplicados a una captura de señal EMG, similarmente, se puede observar el resultado de aplicar los filtros a una captura de señal EEG en la Figura 38.

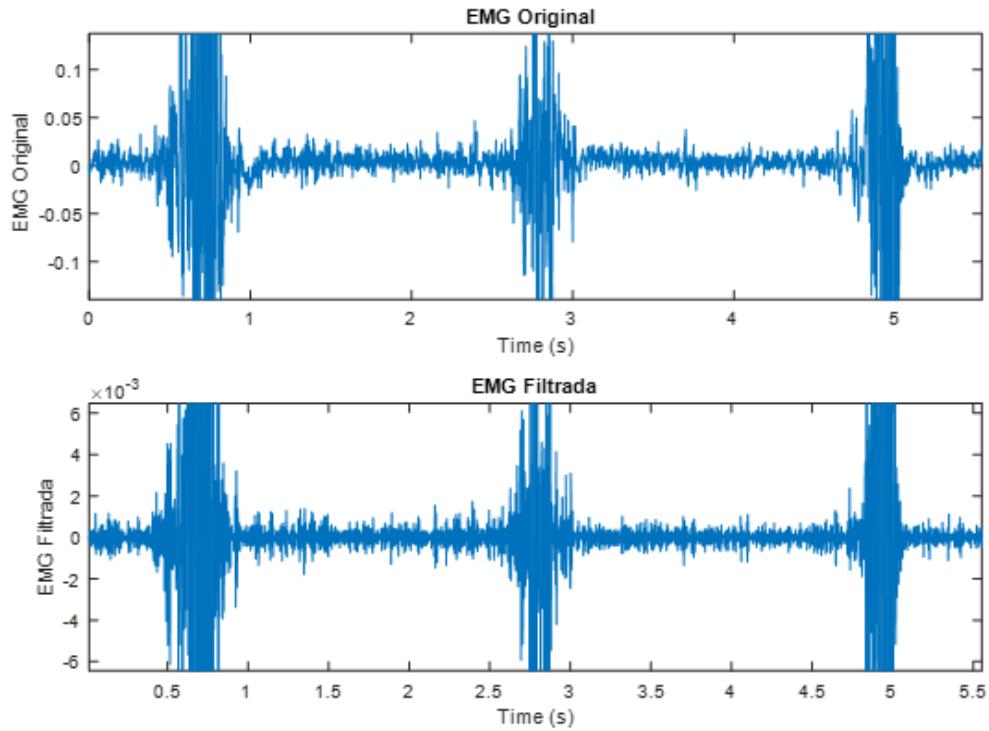


Figura 37: Filtros aplicados en una captura de señal EMG.

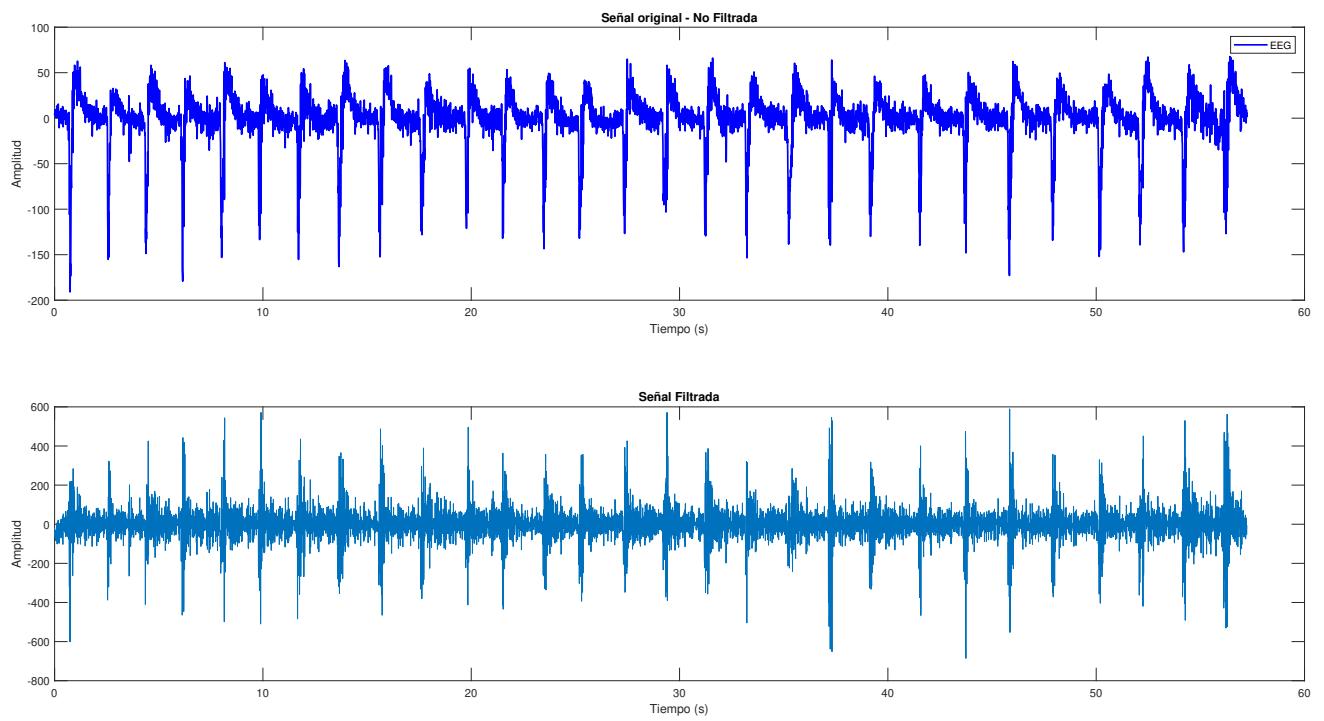


Figura 38: Fitros aplicados en una captura de señal EEG.

# CAPÍTULO 10

---

## Desarrollo de Algoritmos: Detección de Actividad EMG/EEG

---

Las señales EMG y EEG utilizadas en este proyecto, contienen información de interés en forma de eventos específicos, tales como: contracciones musculares, respuestas cerebrales a estímulos, patrones de actividad cerebral, entre otros. El objetivo principal de utilizar algoritmos de detección, fue dividir las señales en segmentos que contuvieran actividad de interés, esto para reducir la influencia de ruido y actividad no relevante en el cálculo de características. El desarrollo de algoritmos de detección de actividad condujeron a entrenamientos más precisos y representativos de las propiedades de la señal, en relación con el evento específico que se estuviera estudiando. Además, se evidenció que al centrar el análisis en segmentos específicos de la señal, la carga computacional era grandemente reducida.

### 10.1. Umbral Único - EMG

Para iniciar el desarrollo del algoritmo, se realizaron pruebas utilizando un umbral único con el fin de detectar actividad en las señales EMG capturadas. Esto funcionaba a modo de gatillo, pues habilitaba una ventana de captura predefinida al detectar una contracción muscular (al estar por encima del umbral definido). Los ensayos evidenciaron una problemática: la ventana de captura era un parámetro bastante específico según cada señal, pues las características de las señales variaban mucho entre sujetos. Esto introdujo un porcentaje de error en la segmentación. Se concluyó que las activaciones musculares muestran variaciones en una misma grabación, agregado a esto, cada gesto tendría una ventana de captura diferente y umbrales considerablemente sensibles. Basándose en lo anterior, se buscó una manera de automatizar el proceso de detección. Esto llevó a experimentar con la extracción de características específicamente para segmentar la señal, y la implementación de un umbral doble que detectaría el inicio y el final de un segmento de actividad, para eliminar el error inducido por una ventana de captura manual.

## 10.2. Umbral Doble - EMG

En esta iteración de herramienta, se desarrolló un algoritmo de extracción de características, el cual calcula el valor absoluto medio de la señal dentro de una cantidad de ventanas. Los segmentos son identificados utilizando un par de umbrales (superior e inferior) que determinan el inicio y el final de los segmentos de actividad; la media absoluta de la señal entre ventanas es constantemente comparada con el valor de los umbrales. Esto eliminó la necesidad de establecer una ventana de captura para extraer segmentos, lo cual redujo el porcentaje de error en la detección. El algoritmo almacena los segmentos detectados y excluye aquellos que no cumplen con una longitud mínima definida por el usuario, esto para evitar falsos positivos inducidos por el ruido. Los segmentos válidos se almacenan junto con sus características, para reducir los tiempos de computación en análisis posteriores. En la Figura 39 se puede observar el resultado de aplicar el umbral doble como técnica de detección.

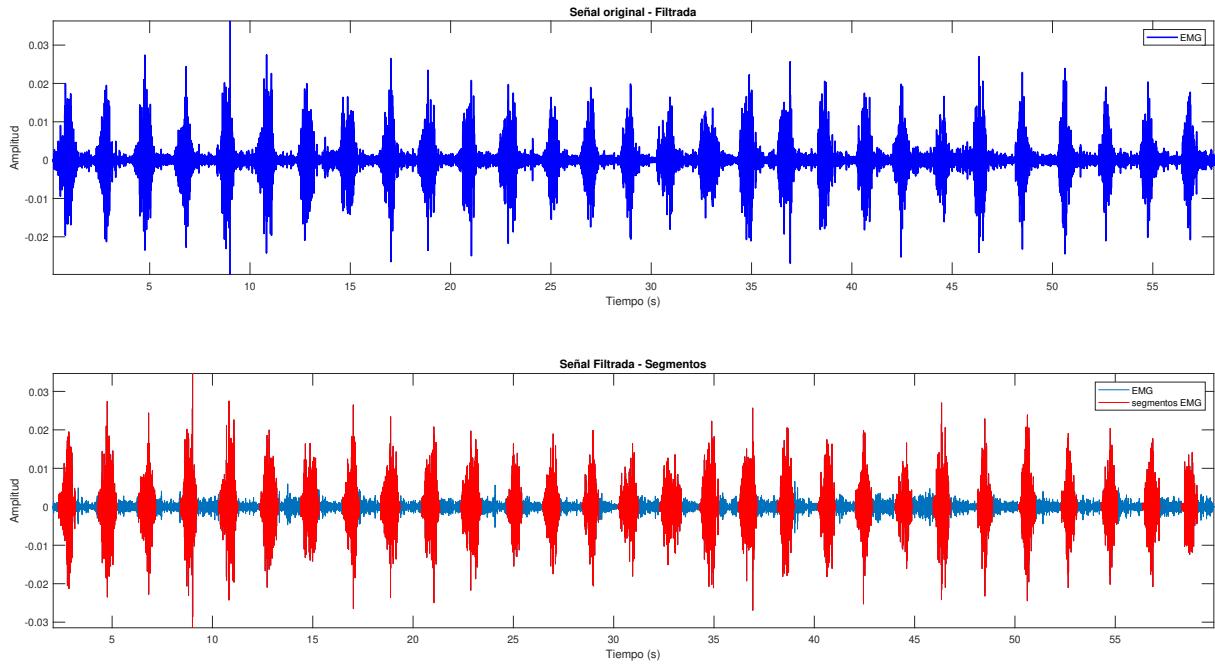


Figura 39: Segmentos de actividad (en rojo) detectados por el algoritmo.

## 10.3. Umbral Adaptativo - EEG

A pesar de haber desarrollado un algoritmo complejo para la extracción de segmentos de actividad en señales, utilizar el mismo enfoque en señales EEG demostró una problemática. Intentar obtener información de actividad directamente de la señal EEG no permitía identificar segmentos de actividad con precisión, similar a lo logrado con las señales EMG. Para resolver esta problemática, se analizaron los tipos de oscilación neural, particularmente para identificar la onda cerebral más relacionada con actividades motrices, permitiendo segmentar de manera precisa los diferentes gestos.

### 10.3.1. Análisis de ondas cerebrales

Para el siguiente análisis fue necesario implementar filtros *Butterworth* pasa bandas con en el dominio de la frecuencias de corte respectivas a las ondas cerebrales: alpha, beta, delta, gamma, theta.

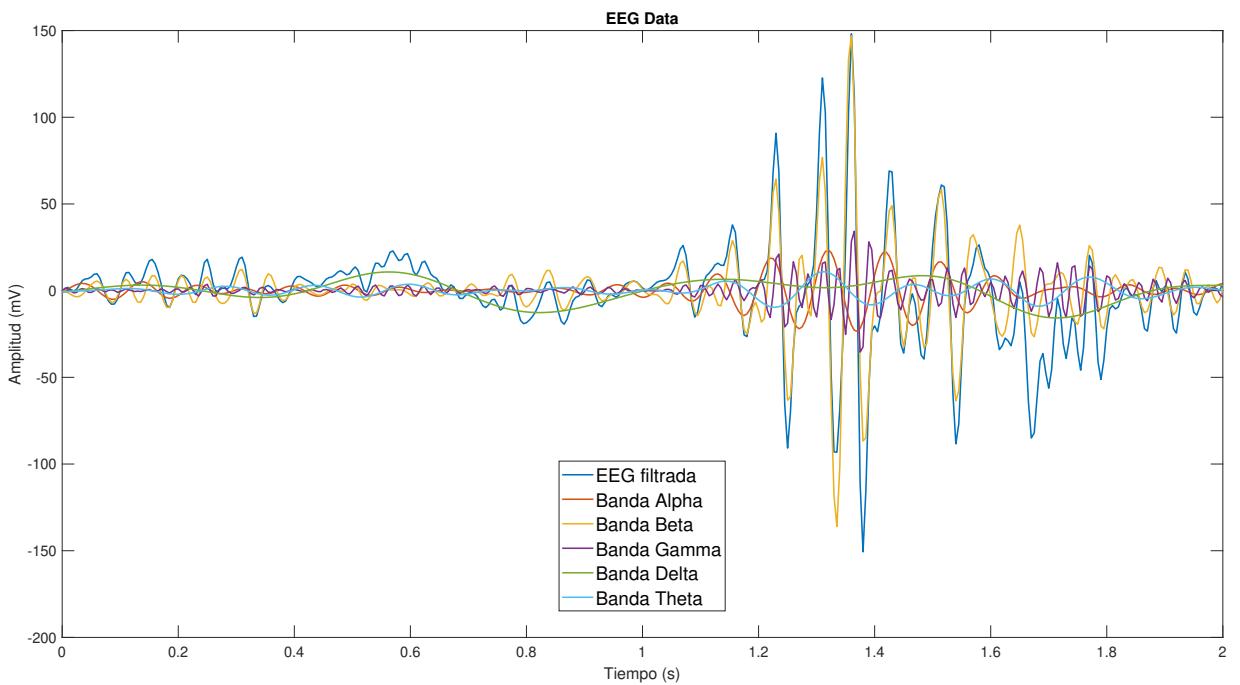


Figura 40: Ondas cerebrales para gesto 4: cabeza inclinada; señal filtrada.

En la Figura 40 se observa que para un segmento de actividad de cabeza inclinada, las ondas beta aumentan considerablemente su amplitud en comparación con las demás estudiadas. La investigación hecha en [54], lleva a cabo el estudio de las ondas beta en la coordinación de movimiento. Los resultados de la investigación evidenciaron que cuando una persona se prepara para realizar un movimiento o una acción motora voluntaria, puede observarse un aumento en la actividad de la banda beta en regiones motoras del cerebro. Esto llevó a la hipótesis que las ondas beta son capaces de proporcionar información acerca

de las interacciones entre el cerebro y el cuerpo, así como los procesos de control motor. En la Figura 41 se observa el espectro de amplitud unilateral, el cual permite visualizar de mejor manera el comportamiento de las ondas beta a través de una captura completa.

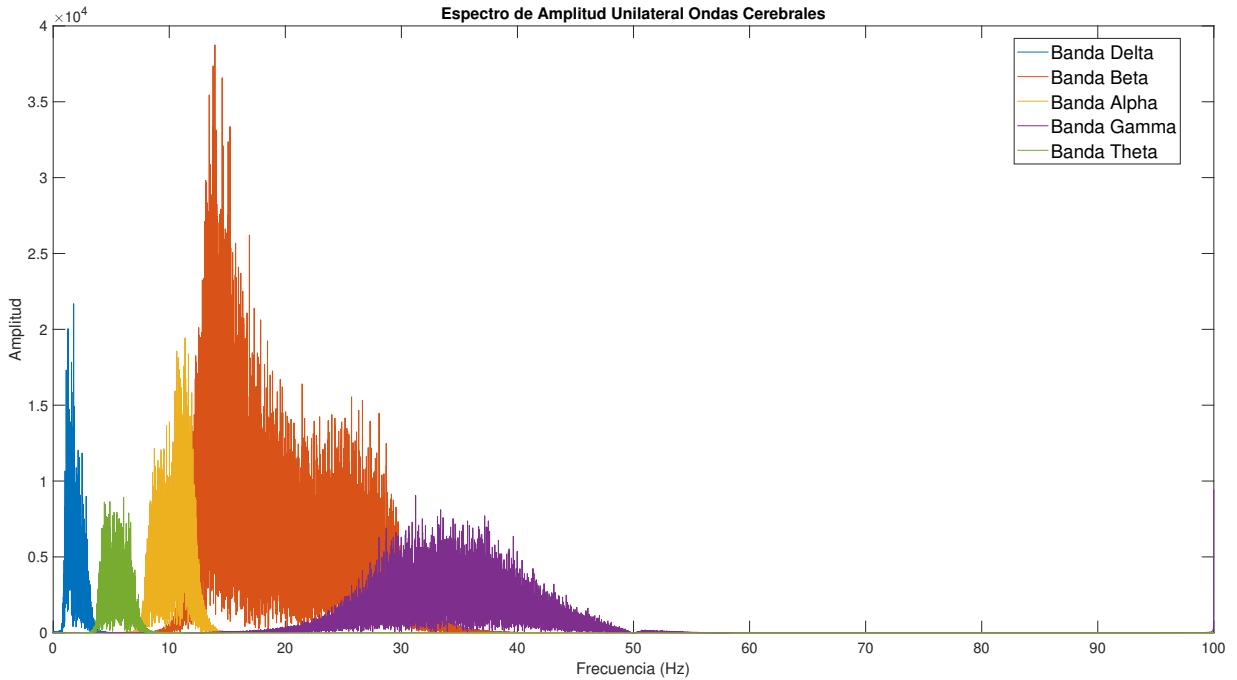


Figura 41: Espectro de amplitud unilateral de ondas cerebrales, gesto 4: cabeza inclinada.

Para poner a prueba la hipótesis, se utilizó el mismo algoritmo de extracción de características (valor medio absoluto) generado en la herramienta de umbral doble, pero en este caso, se utilizó el comportamiento de la onda beta para obtener información acerca de la señal original. Para esta aplicación, se optó por crear un método de detección de actividad que fuera más automatizado. Esto es el resultado del análisis de diferentes capturas, pues se observó que las señales EEG poseen aún más variaciones entre individuos que las señales EMG.

En base a lo anterior, se implementó un umbral adaptativo. El umbral adaptativo se encarga de ajustar dos umbrales en función a la característica extraída para la señal. Mediante ventanas deslizantes, el algoritmo es capaz de modificar los valores de ambos umbrales para detectar anomalías, en este caso, actividad cerebral. Para cambiar la sensibilidad en la detección se define un valor de  $\Sigma$ , entre mayor es este, más rápido los umbrales se adaptan a cambios de amplitud para la característica extraída. Lo anterior hace que el algoritmo sea adaptable a diferentes condiciones y variaciones en señales EEG. Esta adaptabilidad es esencial para identificar eventos de interés en la señal sin requerir ajustes manuales de umbrales.

Los resultados presentados en la Figura 42 permitieron concluir que la hipótesis presentada era verídica. Las ondas cerebrales beta contienen información interpretable sobre las interacciones entre el cerebro y el cuerpo, y pudieron utilizarse efectivamente para ex-

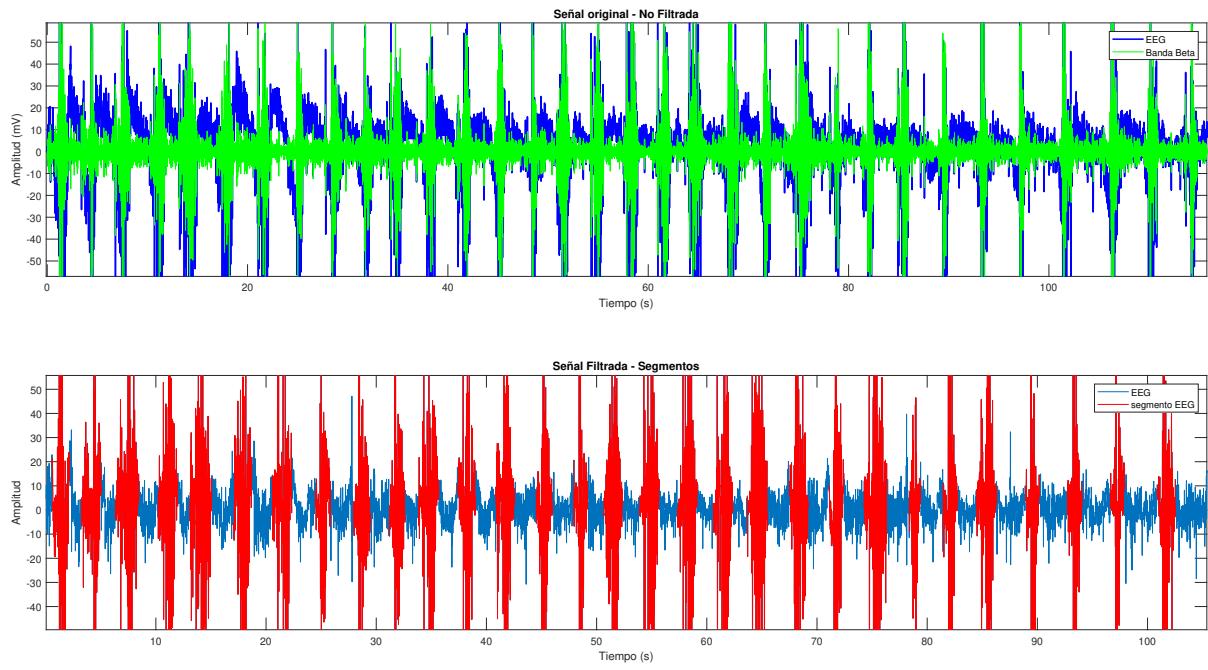


Figura 42: Identificación de segmentos de actividad utilizando características de ondas beta.

traer segmentos de la señal original con actividad cerebral. Además, la iteración final de la herramienta, que incluía el umbral adaptativo, se implementó con éxito en la detección de actividad muscular, lo que automatizó aún más el proceso de detección. Estos hallazgos respaldaron la utilidad de la herramienta desarrollada y su capacidad para analizar y segmentar señales bioeléctricas de manera efectiva.

# CAPÍTULO 11

---

## Aplicación de algoritmos de extracción de características y aprendizaje automático

---

En los capítulos anteriores se exploraron los beneficios de la segmentación de señales bioeléctricas y el proceso de transferencia de los segmentos a MATLAB. Para la consecución de los objetivos de la tesis, surgió la necesidad de clasificar estos segmentos mediante técnicas de aprendizaje automático. Para lograr esto de manera efectiva, fue esencial extraer características únicas de cada segmento de actividad.

La investigación comenzó evaluando los algoritmos de extracción de características desarrollados en etapas anteriores. Estos algoritmos se centraron principalmente en la extracción de características que abarcaban la longitud completa de la señal, tanto en el dominio del tiempo como en el dominio de la en el dominio de la frecuencia. Esta evaluación reveló la necesidad de adaptar estos algoritmos al nuevo contexto de investigación.

### 11.1. Algoritmos de extracción de características

Una vez acondicionadas las señales y con sus respectivos segmentos de actividad detectados, se puede proceder a aplicar los algoritmos de extracción de características desarrollados en etapas previas, a los nuevos datos recolectados.

#### 11.1.1. Características en el dominio del tiempo - EMG/EEG

Para este trabajo, se inició con la implementación de los algoritmos de extracción en el dominio del tiempo. Estas características tienen un bajo costo computacional, además de una implementación no tan compleja. El algoritmo sobre el cuál se desarrolló la interfaz

tiene la capacidad de extraer 5 características:

- Cruces por Cero
- Valor Medio Absoluto
- Curtosis
- Energía Acumulada
- Desviación Estándar

El resultado del algoritmo es un conjunto de vectores de características, correspondientes a las seleccionadas por el usuario. Estos vectores representan a los segmentos de señales. En la Figura 43 se puede visualizar la matriz de vectores resultante al analizar un gesto, cada fila representa el vector de características de una señal (segmento) y las columnas corresponden a las características utilizadas.

#### **11.1.2. Características en el dominio de la en el dominio de la frecuencia - EEG**

Luego de comprobar la funcionalidad de los algoritmos usando características en el dominio del tiempo, fue necesario realizar pruebas utilizando los algoritmos desarrollados para el dominio de la en el dominio de la frecuencia. Se encontró que en etapas previas, las características más utilizadas en todos los campos de análisis de señales EEG, son las potencias relativas relacionadas a ciertas bandas de en el dominio de la frecuencia. Es por ello que se decidió explorar con las siguientes razones entre bandas como características:

- razón 1:  $\frac{\theta}{\alpha}$
- razón 2:  $\frac{\beta}{\alpha}$
- razón 3:  $\frac{\theta+\alpha}{\beta}$
- razón 4:  $\frac{\theta}{\beta}$
- razón 5:  $\frac{\theta+\alpha}{\alpha+\beta}$
- Desviación estándar

El resultado de este análisis es similar al demostrado en la Figura 43.

## **11.2. Algoritmos de aprendizaje automático**

La aplicación de estos algoritmos, se basó en la utilización de 2 clasificadores: máquinas de vectores de soporte y redes neuronales. Estos clasificadores demostraron ser altamente

Features_result.Car_gesto_1.VectorCaracteristicas_gesto_1					
1	2	3	4	5	6
6.8657e-04	1.9664e+03	0.0012	1.3501	0.0012	0.0070
0.0012	159.8458	0.0075	0.1945	0.0074	0.0048
8.4087e-04	433.9051	0.0031	0.3649	0.0031	0.0080
3.1561e-04	371.3219	0.0030	0.1172	0.0030	0.0088
1.2222e-04	4.1255e+03	3.6461e-04	0.5042	3.6452e-04	0.0071
1.5735e-05	5.7456e+03	1.8978e-04	0.0904	1.8975e-04	0.0063
0.0031	358.6087	0.0059	1.1084	0.0059	0.0049
3.3890e-04	989.6961	0.0013	0.3354	0.0013	0.0072
6.3444e-05	3.8563e+03	3.2276e-04	0.2447	3.2267e-04	0.0052
5.0128e-04	1.7580e+03	0.0011	0.8813	0.0011	0.0077
7.0233e-05	4.4465e+03	2.9513e-04	0.3123	2.9506e-04	0.0079
2.6036e-04	806.5172	0.0015	0.2100	0.0015	0.0088
3.1191e-04	4.6453e+03	5.2718e-04	1.4489	5.2707e-04	0.0098
0.0013	1.1214e+03	0.0022	1.4263	0.0022	0.0107
8.4618e-05	2.5961e+03	4.6982e-04	0.2197	4.6963e-04	0.0073
1.8950e-05	7.1299e+03	1.5920e-04	0.1351	1.5918e-04	0.0078
2.7196e-04	4.3602e+03	5.0130e-04	1.1858	5.0119e-04	0.0070
4.7158e-05	1.1964e+03	8.8297e-04	0.0564	8.8223e-04	0.0110
2.1227e-04	1.2298e+03	0.0010	0.2610	0.0010	0.0101
3.6689e-04	2.8281e+03	7.2048e-04	1.0376	7.2023e-04	0.0082
5.9311e-04	2.7428e+03	9.5769e-04	1.6268	9.5735e-04	0.0082
1.6179e-05	5.7961e+03	1.8871e-04	0.0938	1.8868e-04	0.0099
0.0028	224.0094	0.0072	0.6185	0.0072	0.0070
1.4889e-05	2.5726e+04	5.3760e-05	0.3830	5.3758e-05	0.0096
2.2781e-05	1.4154e+04	9.3434e-05	0.3224	9.3428e-05	0.0107

Figura 43: Ejemplo de características extraídas para un gesto.

efectivos en etapas previas y arrojaron los mejores resultados en varios ensayos. Para implementar el clasificador de máquinas de vectores de soporte, se utilizó la función *fitecoc* de la *toolbox* de estadísticas y aprendizaje automático en MATLAB. Esta función es especialmente relevante porque permite la clasificación multiclas. Para garantizar la independencia de los resultados con respecto a la partición de los datos de entrenamiento y validación, se implementó la técnica de validación cruzada de  $k$  iteraciones (*k-fold cross-validation*). Esta técnica fue aplicada con éxito en las interfaces de control robótico basadas en señales EMG y EEG de etapas previas, lo que resultó en una alta precisión.

Para desarrollar el clasificador basado en redes neuronales, se empleó la función *patternnet*, que permite la configuración personalizada de la red neuronal, y la función *train* se utilizó para entrenar el clasificador. Los porcentajes de partición de los datos de entrenamiento son flexibles y se dejan a elección del usuario en las interfaces desarrolladas; sin embargo, los valores comúnmente utilizados son 70 % para entrenamiento, 20 % para pruebas y 10 % para validación.

## 11.3. Homogeneización de segmentos detectados

Dada la necesidad de comparar los segmentos de actividad entre sí, los algoritmos de aprendizaje automático requieren que estos segmentos tengan una longitud uniforme, en un proceso conocido como homogeneización. Esta etapa se vuelve esencial al tratar con los segmentos extraídos mediante las herramientas desarrolladas en capítulos anteriores. La extracción de segmentos evidenció la existencia de variaciones en longitud entre activaciones musculares y cerebrales, incluso para un mismo gesto dentro de la misma ventana de grabación.

Para las secciones siguientes, se trabajó bajo la hipótesis de que la mejor manera de lograr esta homogeneización, era ajustar la longitud de los segmentos al valor promedio. La matriz resultante de segmentos con la longitud propuesta, truncaba aquellos segmentos que excedieran la longitud promedio y descartaba los que fueran más cortos. Al utilizar esta metodología, se notó la pérdida de información en segmentos que no cumplían con la condición, aunque estos fueran segmentos con información relevante. Por lo tanto, se decidió descartar esta metodología y explorar alternativas. Una de las alternativas consideradas fue la incorporación de *Zero Padding*, lo cual solucionó el problema de la pérdida de segmentos. Sin embargo, esta solución introdujo un error considerable en el proceso de entrenamiento, por completar las señales con ceros. Finalmente, se determinó que la mejor manera de homogeneizar todos los segmentos de actividad era mediante el uso de la técnica de interpolación.

### 11.3.1. Homogeneización utilizando *Zero Padding*

Dado que se observó una pérdida significativa de información, se optó por llenar los espacios vacíos de la matriz utilizando la técnica de *zero padding*. La Figura 44 ilustra la estructura resultante después de la homogeneización, donde las columnas representan los segmentos y las filas representan los vectores de características de cada segmento.

movements_segment													
287x212 double													
	199	200	201	202	203	204	205	206	207	208	209	210	211
1	3.8711	-8.4228	-13.3711	-7.3087	3.4979	13.1067	19.0843	19.3782	14.4016	10.2100	12.8606	21.3678	32.35
2	17.5711	3.6239	-6.7831	0	0	0	0	0	0	0	0	0	0
3	0	0	0	0	0	0	0	0	0	0	0	0	0
4	146.4028	84.3081	-7.5472	-32.4830	23.1764	91.5974	99.2347	28.4943	-77.5694	-149.9552	-143.2005	-73.9232	-7.52
5	59.6873	5.1654	-76.8737	-138.4970	-131.0436	-58.7948	19.3456	48.7585	30.5285	8.2084	12.1141	29.4995	31.85
6	30.7198	32.1412	15.8950	-3.7828	-15.1199	-7.9124	17.1055	40.3344	39.4403	16.6708	-1.9841	-1.3824	2.96
7	12.8324	75.1031	54.3379	-1.6246	-32.2626	-32.5245	-30.0935	-16.2588	69.0447	247.2888	392.7845	286.6898	-131.63
8	-22.8680	-10.9851	-3.3853	12.0654	87.9817	182.5442	166.2238	-6.3832	-202.9075	-246.7083	-114.1239	47.2868	87.83
9	-152.9132	-42.6643	126.6897	245.1484	188.4657	-40.2527	-262.4966	-276.7005	-72.6297	141.6872	150.6456	-46.1470	-241.10
10	0	0	0	0	0	0	0	0	0	0	0	0	0
11	2.6262	11.6049	16.5570	29.8700	44.9156	46.7906	31.1261	6.3625	-17.1783	-34.2784	-41.9244	-35.0403	-10.60
12	-178.7882	-30.6091	88.8381	96.5019	40.2170	7.1167	9.7886	7.8363	0.6229	28.8457	88.2500	106.9548	35.77
13	7.3428	38.8015	47.1730	15.6980	-30.5479	-51.7792	-33.5912	5.1680	37.5220	51.0892	47.7194	33.6055	18.05
14	0	0	0	0	0	0	0	0	0	0	0	0	0
15	39.2080	37.4267	26.7821	-8.6197	-49.9699	-53.3693	-3.2301	57.9590	70.1937	22.8364	-33.8291	-45.5193	-10.91
16	155.4657	-193.8797	-531.7275	-549.3820	-226.0303	140.0920	261.9207	141.3645	-10.4505	-40.8688	24.5815	75.2070	
17	48.4142	-4.6090	-55.6229	-75.1615	-57.6802	-18.3676	24.0966	57.3094	74.0761	71.1848	52.3191	28.1214	9.45

Figura 44: Matriz de segmentos, técnica de *zero padding*.

Como resultado el método de *zero padding* aplicado a los segmentos de actividad, logró satisfacer las dimensiones del promedio en vez de desechar segmentos. Sin embargo, esto significó aumentar el porcentaje de error del entrenamiento. Al aplicar algoritmos de aprendizaje automático y observar las curvas de entrenamiento, tanto la red neuronal, como la

máquina de soporte vectorial, presentaron comportamientos no satisfactorios. Como resultado, no lograron clasificar segmentos nuevos de señal de manera exitosa, desviándose del objetivo principal del proyecto. La Figura 45 muestra la curva de entrenamiento al aplicar *zero padding*. En esta representación, se observa el comportamiento de los conjuntos de datos de entrenamiento, prueba y validación a lo largo de las iteraciones de entrenamiento. Es evidente que estos conjuntos de datos no siguen una tendencia consistente, excepto en un pequeño intervalo inicial. Esta falta de coherencia indica que el modelo no está aprendiendo de manera efectiva, puesto que la medida de diferencia de *Cross Entropy* no converge a un valor específico.

Además, es importante señalar que el punto de mayor rendimiento en el conjunto de validación, representado por el círculo no relleno en la Figura 45, no muestra ninguna correlación con las métricas de los otros conjuntos de datos, indicando divergencia. La curva de validación con similitud a un diente de sierra, es indicativa de sobreajuste (*overfitting*) puesto que, a variaciones pequeñas en el conjunto de validación, el modelo no es capaz de minimizar el error en la clasificación. Como resultado de este comportamiento, se concluyó que las señales en todas las clases tenían una estructura predominantemente compuesta por ceros; debido a variaciones significativas de longitud respecto al promedio, lo cual no permitía distinguir de manera satisfactoria diferencias entre clases.

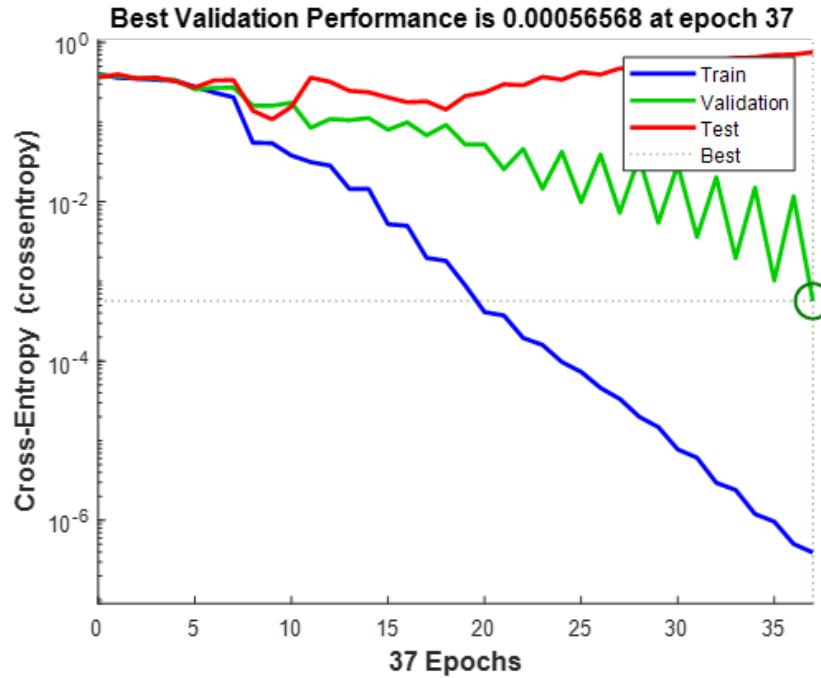


Figura 45: Curva de entrenamiento con *zero padding*.

### 11.3.2. Homogeneización utilizando interpolación

Para resolver la problemática introducida en la sección 11.3.1, se identificó la necesidad de un *padding* más adaptable a la estructura de las señales bioeléctricas. Con este fin se implementó la interpolación. Este tipo de *padding* permite estimar los valores entre muestras

para completar una longitud definida, sin alterar significativamente la forma de la señal.

Para realizar una interpolación como tal, se implementa la función de MATLAB *interp1*, esta retorna valores interpolados utilizando el método lineal o cúbico (*spline*). El método de interpolación fue elegido con el fin de minimizar en lo posible el ruido introducido a la señal, por estimación de datos. En la Figura 46, se muestran las diferencias de implementar el método lineal y el método cúbico de interpolación para crear un sinusoidoide.

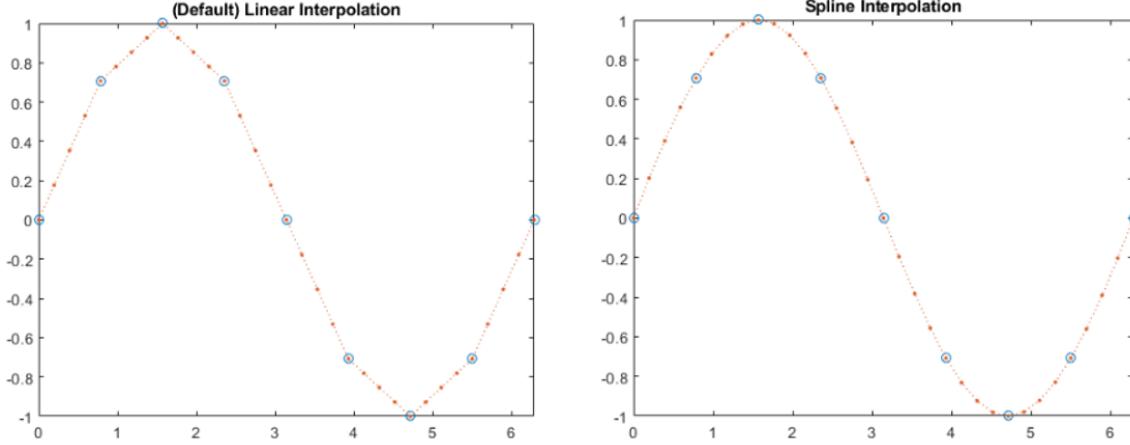


Figura 46: Señal sinusoidal de ejemplo, interpolación lineal vs. cúbica.

Al aplicar la interpolación cúbica, fue posible extraer la totalidad de segmentos de actividad sin variaciones en su longitud, asegurándose que la forma del segmento no presentara cambios radicales como en el *zero padding*. En la Figura 47 se muestra un segmento de señal EEG completado con la técnica de interpolación cúbica.

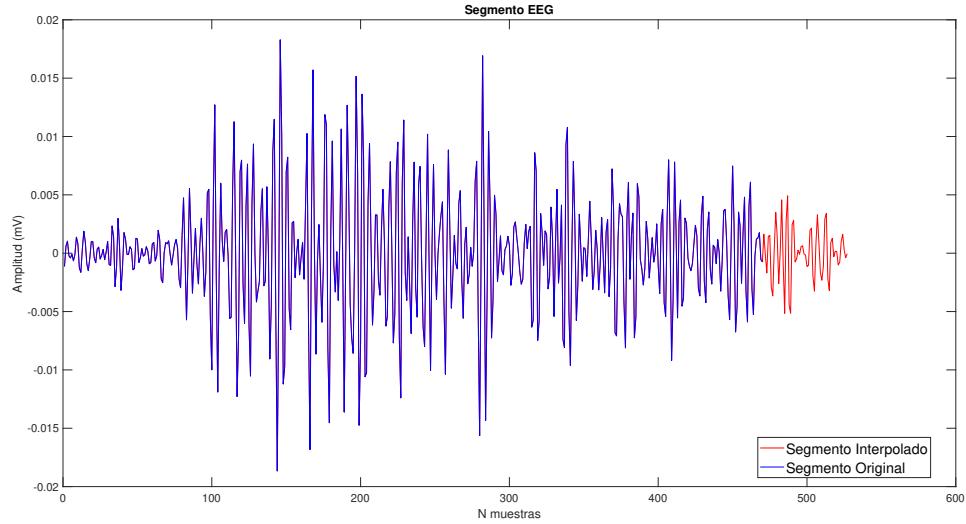


Figura 47: Segmento de señal EEG completado utilizando interpolación cúbica.

Finalmente, se evaluó la efectividad de este tipo de *padding* en los algoritmos de aprendizaje automático. La curva de aprendizaje que se muestra en la Figura 48, ilustra un proceso

de entrenamiento exitoso en el que la medida de diferencia, conocida como *Cross-Entropy*, disminuye de manera uniforme a lo largo de las iteraciones de entrenamiento. El modelo alcanza un punto en el que su rendimiento en el conjunto de entrenamiento se estabiliza, lo que indica que ha aprendido de manera efectiva los patrones presentes en los datos de entrenamiento, logrando así el objetivo de esta sección.

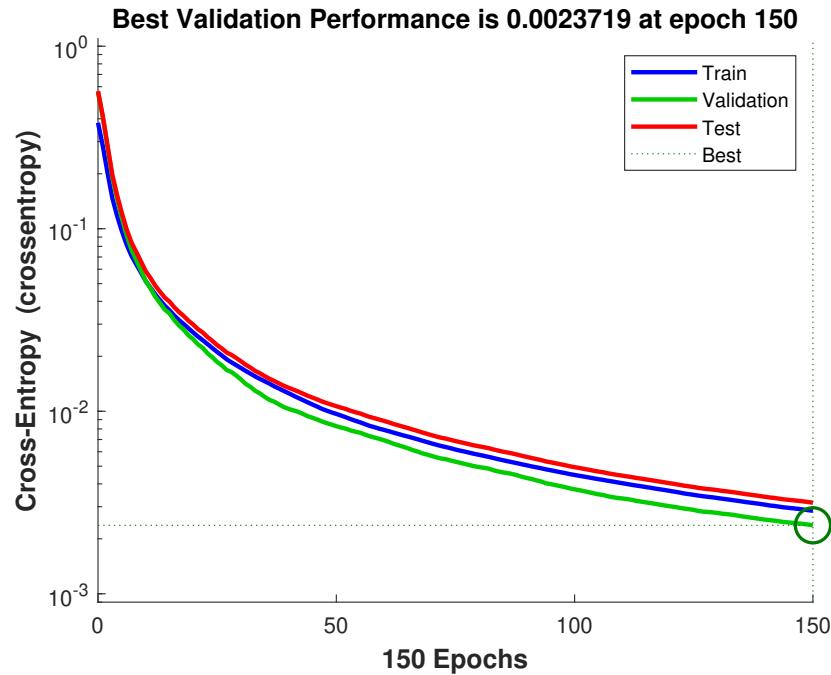


Figura 48: Curva de entrenamiento de segmentos homogeneizados.

Los resultados presentados en este capítulo evidencian los beneficios de la homogeneización de señales mediante la técnica de interpolación. Esta técnica logró conducir a un entrenamiento con decadencia uniforme, según la medida de *Cross Entropy*, convergiendo a un valor específico. En el contexto de algoritmos de aprendizaje automático, esta mejora repercute positivamente en el tiempo de computación y la robustez de los entrenamientos.

## CAPÍTULO 12

---

### Análisis estadísticos de algoritmos - Fase previa

---

Para evaluar el rendimiento en las nuevas capturas, se experimentaron con diferentes combinaciones de características, además de diferentes duraciones de señales capturadas. El objetivo fue evaluar el rendimiento tanto de los algoritmos de extracción de datos, identificación de actividad, así como también el rendimiento de los algoritmos de extracción de características y aprendizaje automático desarrollados en etapas anteriores.

En las Figuras 49 - 54, se muestran los cuadros con los tiempos de ejecución de los algoritmos desarrollados, para estos se utilizó una computadora con 16 GB de Ram, un procesador Intel Core i7-12700 y el sistema operativo Windows 11:

Dominio de Frecuencia	Promedio de tiempo para extraer características	
	Intra-Sujeto	
Cantidad de Características	Grabaciones Individuales (60 segundos) 2 clases	Grabaciones concatenadas (5 minutos) 2 clases
1	0.36 s	1.83 s
2	0.52 s	2.61 s
3	0.59 s	2.98 s
4	0.71 s	3.65 s
5	0.79 s	3.98 s
6	0.83 s	4.22 s

Figura 49: Rendimiento 2 clases - Extracción de características en el dominio de la frecuencia.

Dominio Tiempo Continuo	Promedio de tiempo para extraer características	
	Intra-Sujeto	
Cantidad de Características	Grabaciones Individuales (60 segundos) 2 clases	Grabaciones concatenadas (5 minutos) 2 clases
1	0.48 s	0.69 s
2	0.57 s	0.87 s
3	0.61 s	1.16 s
4	0.64 s	1.32 s
5	0.73 s	1.6 s

Figura 50: Rendimiento 2 clases - Extracción de características en el dominio del tiempo.

Promedio de tiempo para detección de actividad	
Intra-Sujeto - 1 clase	
Grabaciones Individuales (60 segundos)	Grabaciones concatenadas (5 minutos)
0.68 s	1.2 s
Inter-Sujeto - 1 clase	
1.13 s	

Figura 51: Rendimiento 1 clase - Algoritmo detección de actividad.

Promedio de tiempo para extracción datos .xlsx	
Biopac	
Extracción de 2 clases	
23.82 s	
Extracción de 3 clases	
37.64 s	

Figura 52: Rendimiento - Extracción de datos .xlsx.

Dominio de Frecuencia	Promedio de tiempo para extraer características	
	Inter-Sujeto - 5 sujetos	
Cantidad de Características	2 clases	
1		5.12 s
2		6.14 s
3		7.08 s
4		8.21 s
5		9.14 s
6		9.64 s

Figura 53: Rendimiento 2 clases, 5 sujetos - Extracción de características en el dominio de la frecuencia.

Dominio Tiempo Continuo	Promedio de tiempo para extraer características	
	Inter-Sujeto - 5 sujetos	
Cantidad de Características	2 clases	
1		3.73 s
2		3.89 s
3		3.98 s
4		4.12 s
5		4.43 s

Figura 54: Rendimiento 2 clases, 5 sujetos - Extracción de características en el dominio del tiempo.

## **12.1. Entrenamientos inter-sujeto**

Los entrenamientos inter-sujeto compararon las respuestas o características de múltiples sujetos. Cada sujeto se consideró como una entidad independiente, y se recopilaron datos de cada uno de ellos por separado. Luego, el análisis estadístico se realizó sobre toda la población. Este estudio demostró ser esencial para el diseño de sistemas efectivos y aplicables a una población más diversa.

## **12.2. Entrenamientos intra-sujeto**

Los entrenamientos intra-sujeto se centraron en la variabilidad dentro de un mismo sujeto, a lo largo del tiempo o en diferentes condiciones. En estos casos, un único sujeto proporcionó datos en múltiples ocasiones, de varios o un único gesto. El objetivo fue evaluar la consistencia de las respuestas bioeléctricas de un mismo sujeto en condiciones controladas. Esto es particularmente importante para aplicar algoritmos de clasificación o control en tiempo real, ya que se necesita garantizar que las señales sean coherentes a lo largo del tiempo.

## **12.3. Elección de entrenamientos**

Para los entrenamientos realizados sobre la base de datos, se observó una tendencia, el análisis intra-sujeto demostró en promedio tener un mejor porcentaje de clasificación en comparación con el análisis inter-sujeto. Esta distinción era esperada, pues cada individuo posee una combinación única de características fisiológicas, patrones de actividad muscular y respuestas cerebrales a estímulos, lo que se traduce en diferencias sustanciales en las señales EMG y EEG que generan.

En la Figura 55 se muestra la matriz de confusión de un análisis inter-sujeto en el dominio del tiempo. A modo de representar las diferencias substanciales entre los entrenamientos inter e intra-sujeto, en la Figura 56 también se puede observar la matriz de confusión del análisis intra-sujeto en el dominio del tiempo. Estas matrices de confusión se emplean para comparar las predicciones del modelo, incluyendo los casos de falsos positivos y falsos negativos, con las clases clasificadas siendo puño arriba, puño abajo y puño. Los resultados de las matrices de confusión revelan una diferencia del 6.4 % en la exactitud de clasificación, un parámetro que se encuentra en la diagonal de todas las matrices de confusión. Con el mejor porcentaje correspondiendo al entrenamiento intra-sujeto (94.3 %).

En base a los resultados observados, se tomó la decisión de utilizar enfoques intra-sujeto para el desarrollo de las interfaces humano-máquina de este proyecto, debido a que estos permitirían obtener modelos más específicos a un sujeto. En cuanto a los enfoques inter-sujeto, se optó por su utilización en otra interfaz, la *Epileptic Analysis Toolbox*. En esta interfaz, se buscó adaptar los modelos de entrenamiento y reconocimiento de patrones a variaciones más generalizadas, esto fue posible mediante las señales obtenidas en colaboración con el centro HUMANA.

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	726 21.4%	183 5.4%	11 0.3%	11 0.3%	78.0% 22.0%
	Clase 2	100 2.9%	587 17.3%	7 0.2%	26 0.8%	81.5% 18.5%
	Clase 3	5 0.1%	36 1.1%	769 22.6%	338 9.9%	67.0% 33.0%
	Clase 4	19 0.6%	44 1.3%	63 1.9%	475 14.0%	79.0% 21.0%
		85.4% 14.6%	69.1% 30.9%	90.5% 9.5%	55.9% 44.1%	75.2% 24.8%

Figura 55: Matriz de confusión, Dominio del tiempo, 5 características - inter-sujeto.

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	236 23.9%	2 0.2%	14 1.4%	7 0.7%	91.1% 8.9%
	Clase 2	0 0.0%	230 23.3%	20 2.0%	1 0.1%	91.6% 8.4%
	Clase 3	10 1.0%	10 1.0%	198 20.0%	21 2.1%	82.8% 17.2%
	Clase 4	1 0.1%	5 0.5%	15 1.5%	218 22.1%	91.2% 8.8%
		95.5% 4.5%	93.1% 6.9%	80.2% 19.8%	88.3% 11.7%	89.3% 10.7%

Figura 56: Matriz de confusión, Dominio del tiempo, 5 características - intra-sujeto.

## 12.4. Identificación de mejoras

Con el objetivo de mejorar las estadísticas generadas por los entrenamientos, particularmente en el caso de las redes neuronales, se observó que a pesar de obtener un clasificador con una precisión bastante cercana al 100 %, con en el dominio de la frecuencia, se producía un problema de sobreajuste (*overfitting*) en los resultados. El sobreajuste introdujo un alto porcentaje de error en el algoritmo, lo cual fue especialmente problemático en aplicaciones de interfaces de control robótico, dónde el algoritmo debe ser capaz de clasificar señales no antes vistas con un alto grado de precisión. Para abordar este fenómeno, se implementó la modificación manual de los hiperparámetros de la red neuronal, tal y como se puede observar en la Figura 57. Esta estrategia logró evitar que los entrenamientos se ajustaran en exceso a los datos utilizados para el entrenamiento, mejorando así la capacidad de generalización del modelo. Además, se notó que el poder computacional empleado para extraer características estaba siendo desperdiciado, por lo que se implementaron los algoritmos de detección desarrollados en el capítulo 9.



Figura 57: Hiper-parámetros modificables en la nueva interfaz.

# CAPÍTULO 13

---

## Resultados de clasificación

---

En este capítulo se muestran los resultados de clasificación para redes neuronales y máquinas de vectores de soporte. Estos resultados involucran estudios inter e intra-sujeto, comparando la clasificación de hasta 4 gestos.

### 13.1. Redes Neuronales - Señales EMG: Inter-sujeto

Para los resultados de redes neuronales se utilizaron los siguientes hiper-parámetros de entrenamiento: 70 % para entrenamiento, 20 % para pruebas y 10 % para validación. Un *learning rate* de 0.001, con un mínimo de épocas de 100 y 10 capas ocultas. Las capturas únicamente cuentan con 1 canal de señal, y para el análisis estadístico de los entrenamientos, se cuentan con variaciones en la cantidad de características estudiadas, así como también, la cantidad de gestos. Para esta sección, se trabajó con 3 sujetos de estudio.

## 13.2. Clasificación de características - Dominio del tiempo

### Clasificación con 2 características (ZC, MAV)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	483 14.2%	282 8.3%	119 3.5%	128 3.8%	47.7% 52.3%
	Clase 2	169 5.0%	337 9.9%	112 3.3%	91 2.7%	47.5% 52.5%
	Clase 3	94 2.8%	156 4.6%	386 11.4%	353 10.4%	39.0% 61.0%
	Clase 4	104 3.1%	75 2.2%	233 6.9%	278 8.2%	40.3% 59.7%
		56.8% 43.2%	39.6% 60.4%	45.4% 54.6%	32.7% 67.3%	43.6% 56.4%

Figura 58: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

### Clasificación con 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	670 19.7%	301 8.9%	4 0.1%	7 0.2%	68.2% 31.8%
	Clase 2	151 4.4%	353 10.4%	11 0.3%	25 0.7%	65.4% 34.6%
	Clase 3	8 0.2%	80 2.4%	762 22.4%	356 10.5%	63.2% 36.8%
	Clase 4	21 0.6%	116 3.4%	73 2.1%	462 13.6%	68.8% 31.2%
		78.8% 21.2%	41.5% 58.5%	89.6% 10.4%	54.4% 45.6%	66.1% 33.9%

Figura 59: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

## Clasificación con 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	726 21.4%	183 5.4%	11 0.3%	11 0.3%	78.0% 22.0%
	Clase 2	100 2.9%	587 17.3%	7 0.2%	26 0.8%	81.5% 18.5%
	Clase 3	5 0.1%	36 1.1%	769 22.6%	338 9.9%	67.0% 33.0%
	Clase 4	19 0.6%	44 1.3%	63 1.9%	475 14.0%	79.0% 21.0%
		85.4% 14.6%	69.1% 30.9%	90.5% 9.5%	55.9% 44.1%	75.2% 24.8%
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud

Figura 60: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

Los resultados anteriores se enfocaron en comparar la exactitud de clasificación para características en el dominio del tiempo, con el fin de identificar una combinación que lograra minimizar el tiempo de computación y generara clasificaciones precisas. Como era de esperar, los entrenamientos con menor cantidad de características resultaron ser menos eficientes a la hora de clasificar, sin embargo, se hizo notorio que para el conjunto de datos de la población, extraer únicamente 3 características (ZC, MAV, Desv. Estándar), retornó en promedio exactitudes porcentualmente cercanas a las obtenidas utilizando 5 características. En el Anexo 18.1.1 del documento, es posible visualizar las variaciones en la exactitud de clasificación al variar la cantidad de gestos, así como también la cantidad de características comparadas.

### 13.3. Redes Neuronales - Señales EMG: Intra-sujeto

Los resultados presentados en esta sección se fundamentaron en el análisis de 3 sujetos, abordando cada uno de ellos de manera individual. Esta metodología se adoptó con el propósito de examinar el entrenamiento de clasificadores en contextos más específicos a cada sujeto en particular. Durante este estudio, se mantuvieron los parámetros de rendimiento evaluados en la sección 13.1. A continuación, se muestran los resultados de clasificación para 2 sujetos (P000, P001) considerando 4 clases.

#### 13.3.1. Clasificación de características - Dominio del tiempo: Sujeto P000

##### Clasificación con 2 características (ZC, MAV)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	186 18.8%	22 2.2%	12 1.2%	7 0.7%	81.9% 18.1%
	Clase 2	18 1.8%	160 16.2%	20 2.0%	17 1.7%	74.4% 25.6%
	Clase 3	31 3.1%	7 0.7%	143 14.5%	50 5.1%	61.9% 38.1%
	Clase 4	12 1.2%	58 5.9%	72 7.3%	173 17.5%	54.9% 45.1%
		75.3% 24.7%	64.8% 35.2%	57.9% 42.1%	70.0% 30.0%	67.0% 33.0%

Figura 61: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

### Clasificación con 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	220 22.3%	26 2.6%	0 0.0%	3 0.3%	88.4% 11.6%
	Clase 2	22 2.2%	182 18.4%	1 0.1%	13 1.3%	83.5% 16.5%
	Clase 3	3 0.3%	16 1.6%	222 22.5%	58 5.9%	74.2% 25.8%
	Clase 4	2 0.2%	23 2.3%	24 2.4%	173 17.5%	77.9% 22.1%
		89.1% 10.9%	73.7% 26.3%	89.9% 10.1%	70.0% 30.0%	80.7% 19.3%

Figura 62: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

### Clasificación con 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	239 24.2%	5 0.5%	1 0.1%	4 0.4%	96.0% 4.0%
	Clase 2	2 0.2%	239 24.2%	3 0.3%	0 0.0%	98.0% 2.0%
	Clase 3	2 0.2%	2 0.2%	229 23.2%	45 4.6%	82.4% 17.6%
	Clase 4	4 0.4%	1 0.1%	14 1.4%	198 20.0%	91.2% 8.8%
		96.8% 3.2%	96.8% 3.2%	92.7% 7.3%	80.2% 19.8%	91.6% 8.4%

Figura 63: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

### 13.3.2. Clasificación de características - Dominio del tiempo: Sujeto P001

#### Clasificación con 2 características (ZC, MAV)

		Matriz de Confusión Confusion Matrix				
		Clase 1	34 3.4%	67 6.8%	0 0.0%	64.2% 35.8%
Output Class	Clase 1	181 18.3%				
	Clase 2	11 1.1%	137 13.9%	63 6.4%	12 1.2%	61.4% 38.6%
	Clase 3	43 4.4%	64 6.5%	105 10.6%	7 0.7%	47.9% 52.1%
	Clase 4	12 1.2%	12 1.2%	12 1.2%	228 23.1%	86.4% 13.6%
		73.3% 26.7%	55.5% 44.5%	42.5% 57.5%	92.3% 7.7%	65.9% 34.1%
		Exactitud				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud

Figura 64: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

#### Clasificación con 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	4 0.4%	36 3.6%	1 0.1%	84.1% 15.9%
Output Class	Clase 1	217 22.0%				
	Clase 2	0 0.0%	190 19.2%	45 4.6%	1 0.1%	80.5% 19.5%
	Clase 3	24 2.4%	49 5.0%	156 15.8%	12 1.2%	64.7% 35.3%
	Clase 4	6 0.6%	4 0.4%	10 1.0%	233 23.6%	92.1% 7.9%
		87.9% 12.1%	76.9% 23.1%	63.2% 36.8%	94.3% 5.7%	80.6% 19.4%
		Exactitud				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud

Figura 65: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

## Clasificación con 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	237 24.0%	4 0.4%	1 0.1%	3 0.3%	96.7% 3.3%
	Clase 2	1 0.1%	240 24.3%	1 0.1%	0 0.0%	99.2% 0.8%
	Clase 3	2 0.2%	2 0.2%	223 22.6%	32 3.2%	86.1% 13.9%
	Clase 4	7 0.7%	1 0.1%	22 2.2%	212 21.5%	87.6% 12.4%
		96.0% 4.0%	97.2% 2.8%	90.3% 9.7%	85.8% 14.2%	92.3% 7.7%

Figura 66: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

Los resultados obtenidos al estudiar la variabilidad intra-sujeto por medio de la extracción de características en el dominio del tiempo, retornaron mejores resultados que los estudiados en el enfoque inter-sujeto de la sección 13.1. Esto hace sentido, pues el estudio en vez de generalizar, se centra en variabilidades más específicas entre los sujetos de estudio. Los resultados de más sujetos, variando cantidad de clases y características extraídas, se encuentran en el Anexo 18.1.2.

### 13.4. Redes Neuronales: Resumen resultados EMG

En la Figura 67, se presenta el resumen de resultados de las mejores iteraciones en entrenamientos inter-sujeto. Similarmente en la Figura 68, se pueden observar los resultados de las mejores iteraciones en los entrenamientos intra-sujeto.

Resumen resultados RN: Señales EMG		
Tiempo Continuo - Inter-sujeto		
Características	No. Clases	% Exactitud
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	3	82.9
ZC, MAV, Desviación Estándar		80.3
ZC, MAV		52.5
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	4	75.2
ZC, MAV, Desviación Estándar		66.1
ZC, MAV		43.6

Figura 67: Resumen resultados clasificador para señales EMG - inter-sujeto.

Resumen resultados RN: Señales EMG (PROMEDIO DE EXACTITUD)					
Tiempo Continuo - Intra-sujeto					
Características	No. Clases	P000	P001	P002	Promedio: % Exactitud
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	2	99	98.4	94.9	97.43
ZC, MAV, Desviación Estándar		94.6	96.8	93.7	95.03
ZC, MAV		88.5	89.5	85	87.67
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	3	97	97.4	92.3	95.57
ZC, MAV, Desviación Estándar		95	88	90.4	91.13
ZC, MAV		81.5	77.5	71.1	76.70
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	4	91.6	92.3	89.3	91.07
ZC, MAV, Desviación Estándar		80.7	80.6	82.3	81.20
ZC, MAV		67	65.9	67	66.63

Figura 68: Resumen resultados clasificador para señales EMG - intra-sujeto.

## 13.5. Redes Neuronales - Señales EEG: Inter-sujeto

Para los entrenamientos en señales EEG, se utilizaron los mismos hiper-parámetros de entrenamiento, así como también los mismos parámetros de rendimiento que los utilizados en la sección 13.1 del documento. Particularmente, el estudio de las señales EEG introdujo otro parámetro de medición estadístico; características en el dominio de la frecuencia. Con el objetivo de mejorar la eficiencia computacional sin sacrificar la precisión del clasificador, se varió la cantidad de características en el dominio de la frecuencia; esto permitió obtener la combinación más eficiente.

### 13.5.1. Clasificación de características - Dominio del tiempo

#### Clasificación con 2 características (ZC, MAV)

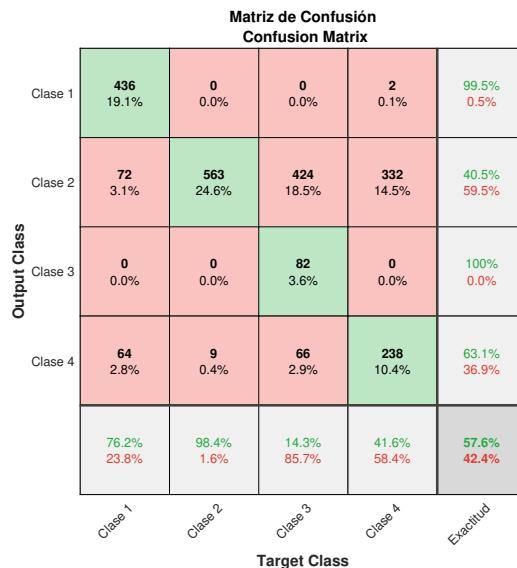


Figura 69: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

### Clasificación con 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	518 22.6%	0 0.0%	0 0.0%	16 0.7%	97.0% 3.0%
	Clase 2	0 0.0%	570 24.9%	571 25.0%	0 0.0%	50.0% 50.0%
	Clase 3	40 1.7%	0 0.0%	0 0.0%	0 0.0%	0.0% 100%
	Clase 4	14 0.6%	2 0.1%	1 0.0%	556 24.3%	97.0% 3.0%
		90.6% 9.4%	99.7% 0.3%	0.0% 100%	97.2% 2.8%	71.9% 28.1%

Figura 70: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

### Clasificación con 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	471 20.6%	28 1.2%	2 0.1%	1 0.0%	93.8% 6.2%
	Clase 2	42 1.8%	410 17.9%	55 2.4%	51 2.2%	73.5% 26.5%
	Clase 3	45 2.0%	97 4.2%	490 21.4%	16 0.7%	75.6% 24.4%
	Clase 4	14 0.6%	37 1.6%	25 1.1%	504 22.0%	86.9% 13.1%
		82.3% 17.7%	71.7% 28.3%	85.7% 14.3%	88.1% 11.9%	81.9% 18.1%

Figura 71: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

### 13.5.2. Clasificación de características - Dominio de la frecuencia

Clasificación con 2 características (razón 1, razón 2)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	389 17.0%	64 2.8%	83 3.6%	1 0.0%	72.4% 27.6%
	Clase 2	80 3.5%	345 15.1%	55 2.4%	17 0.7%	69.4% 30.6%
	Clase 3	83 3.6%	57 2.5%	259 11.3%	32 1.4%	60.1% 39.9%
	Clase 4	20 0.9%	106 4.6%	175 7.6%	522 22.8%	63.4% 36.6%
		68.0% 32.0%	60.3% 39.7%	45.3% 54.7%	91.3% 8.7%	66.2% 33.8%
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
		Target Class				

Figura 72: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

Clasificación con 4 características (razón 1, razón 2, razón 3, desviación estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	462 20.2%	36 1.6%	3 0.1%	0 0.0%	92.2% 7.8%
	Clase 2	63 2.8%	395 17.3%	51 2.2%	37 1.6%	72.3% 27.7%
	Clase 3	42 1.8%	69 3.0%	405 17.7%	59 2.6%	70.4% 29.6%
	Clase 4	5 0.2%	72 3.1%	113 4.9%	476 20.8%	71.5% 28.5%
		80.8% 19.2%	69.1% 30.9%	70.8% 29.2%	83.2% 16.8%	76.0% 24.0%
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
		Target Class				

Figura 73: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

Clasificación con 6 características (razón 1, razón 2, razón 3, razón 4, razón 5, desviación estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	524 22.9%	0 0.0%	0 0.0%	26 1.1%	95.3% 4.7%
	Clase 2	0 0.0%	563 24.6%	269 11.8%	0 0.0%	67.7% 32.3%
	Clase 3	0 0.0%	5 0.2%	294 12.8%	0 0.0%	98.3% 1.7%
	Clase 4	48 2.1%	4 0.2%	9 0.4%	546 23.9%	90.0% 10.0%
		91.6% 8.4%	98.4% 1.6%	51.4% 48.6%	95.5% 4.5%	84.2% 15.8%

Figura 74: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

## 13.6. Redes Neuronales - Señales EEG: Intra-sujeto

Esta sección de resultados tiene como objetivo contrastar la robustez del modelo de clasificación entre los estudios intra e inter-sujeto. Se utilizaron los mismos parámetros de entrenamiento que en la sección 13.5 para 2 sujetos (P000, P001), considerando 4 gestos.

### 13.6.1. Clasificación de características - Dominio del tiempo: Sujeto P000

#### Clasificación con 2 características (ZC, MAV)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	263 23.0%	34 3.0%	5 0.4%	0 0.0%	87.1% 12.9%
	Clase 2	7 0.6%	142 12.4%	27 2.4%	19 1.7%	72.8% 27.2%
	Clase 3	15 1.3%	62 5.4%	176 15.4%	31 2.7%	62.0% 38.0%
	Clase 4	1 0.1%	48 4.2%	78 6.8%	236 20.6%	65.0% 35.0%
		92.0% 8.0%	49.7% 50.3%	61.5% 38.5%	82.5% 17.5%	71.4% 28.6%

Figura 75: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

### Clasificación con 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	269 23.5%	17 1.5%	1 0.1%	0 0.0%	93.7% 6.3%
	Clase 2	13 1.1%	178 15.6%	14 1.2%	16 1.4%	80.5% 19.5%
	Clase 3	3 0.3%	50 4.4%	248 21.7%	58 5.1%	69.1% 30.9%
	Clase 4	1 0.1%	41 3.6%	23 2.0%	212 18.5%	76.5% 23.5%
		94.1% 5.9%	62.2% 37.8%	86.7% 13.3%	74.1% 25.9%	79.3% 20.7%

Figura 76: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

### Clasificación con 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	265 23.2%	18 1.6%	0 0.0%	0 0.0%	93.6% 6.4%
	Clase 2	18 1.6%	190 16.6%	18 1.6%	17 1.5%	78.2% 21.8%
	Clase 3	3 0.3%	37 3.2%	264 23.1%	11 1.0%	83.8% 16.2%
	Clase 4	0 0.0%	41 3.6%	4 0.3%	258 22.6%	85.1% 14.9%
		92.7% 7.3%	66.4% 33.6%	92.3% 7.7%	90.2% 9.8%	85.4% 14.6%

Figura 77: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

### 13.6.2. Clasificación de características - Dominio del tiempo: Sujeto P001

#### Clasificación con 2 características (ZC, MAV)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	259 22.6%	31 2.7%	5 0.4%	0 0.0%	87.8% 12.2%
	Clase 2	14 1.2%	144 12.6%	31 2.7%	22 1.9%	68.2% 31.8%
	Clase 3	13 1.1%	60 5.2%	173 15.1%	51 4.5%	58.2% 41.8%
	Clase 4	0 0.0%	51 4.5%	77 6.7%	213 18.6%	62.5% 37.5%
		90.6% 9.4%	50.3% 49.7%	60.5% 39.5%	74.5% 25.5%	69.0% 31.0%
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
		Target Class	Target Class	Target Class	Target Class	Target Class

Figura 78: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

#### Clasificación con 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	268 23.4%	27 2.4%	0 0.0%	3 0.3%	89.9% 10.1%
	Clase 2	11 1.0%	166 14.5%	20 1.7%	51 4.5%	66.9% 33.1%
	Clase 3	5 0.4%	54 4.7%	249 21.8%	56 4.9%	68.4% 31.6%
	Clase 4	2 0.2%	39 3.4%	17 1.5%	176 15.4%	75.2% 24.8%
		93.7% 6.3%	58.0% 42.0%	87.1% 12.9%	61.5% 38.5%	75.1% 24.9%
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
		Target Class	Target Class	Target Class	Target Class	Target Class

Figura 79: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

**Clasificación con 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)**

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	265 23.2%	36 3.1%	0 0.0%	6 0.5%	86.3% 13.7%
	Clase 2	15 1.3%	154 13.5%	14 1.2%	22 1.9%	75.1% 24.9%
	Clase 3	3 0.3%	49 4.3%	260 22.7%	19 1.7%	78.5% 21.5%
	Clase 4	3 0.3%	47 4.1%	12 1.0%	239 20.9%	79.4% 20.6%
	Exactitud	92.7% 7.3%	53.8% 46.2%	90.9% 9.1%	83.6% 16.4%	80.2% 19.8%

Figura 80: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

### 13.6.3. Clasificación de características - Dominio de la frecuencia: Sujeto P000

Clasificación con 2 características (razón 1, razón 2)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	264 23.1%	0 0.0%	0 0.0%	15 1.3%	94.6% 5.4%
	Clase 2	0 0.0%	283 24.7%	0 0.0%	0 0.0%	100% 0.0%
	Clase 3	0 0.0%	3 0.3%	286 25.0%	0 0.0%	99.0% 1.0%
	Clase 4	22 1.9%	0 0.0%	0 0.0%	271 23.7%	92.5% 7.5%
		92.3% 7.7%	99.0% 1.0%	100% 0.0%	94.8% 5.2%	96.5% 3.5%

Figura 81: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

Clasificación con 4 características (razón 1, razón 2, razón 3, desviación estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	285 24.9%	0 0.0%	0 0.0%	18 1.6%	94.1% 5.9%
	Clase 2	0 0.0%	283 24.7%	1 0.1%	0 0.0%	99.6% 0.4%
	Clase 3	0 0.0%	3 0.3%	285 24.9%	0 0.0%	99.0% 1.0%
	Clase 4	1 0.1%	0 0.0%	0 0.0%	268 23.4%	99.6% 0.4%
		99.7% 0.3%	99.0% 1.0%	99.7% 0.3%	93.7% 6.3%	98.0% 2.0%

Figura 82: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

Clasificación con 6 características (razón 1, razón 2, razón 3, razón 4, razón 5, Desviación estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	286 25.0%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	286 25.0%	0 0.0%	0 0.0%	100% 0.0%
	Clase 3	0 0.0%	0 0.0%	286 25.0%	0 0.0%	100% 0.0%
	Clase 4	0 0.0%	0 0.0%	0 0.0%	286 25.0%	100% 0.0%
	Exactitud	100% 0.0%	100% 0.0%	100% 0.0%	100% 0.0%	100% 0.0%

Figura 83: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

### 13.6.4. Clasificación de características - Dominio de la frecuencia: Sujeto P001

Clasificación con 2 características (razón 1, razón 2)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	271 23.7%	0 0.0%	0 0.0%	15 1.3%	94.8% 5.2%
	Clase 2	0 0.0%	283 24.7%	0 0.0%	0 0.0%	100% 0.0%
	Clase 3	0 0.0%	3 0.3%	286 25.0%	0 0.0%	99.0% 1.0%
	Clase 4	15 1.3%	0 0.0%	0 0.0%	271 23.7%	94.8% 5.2%
		94.8% 5.2%	99.0% 1.0%	100% 0.0%	94.8% 5.2%	97.1% 2.9%

Figura 84: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

Clasificación con 4 características (razón 1, razón 2, razón 3, desviación estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	282 24.7%	0 0.0%	0 0.0%	15 1.3%	94.9% 5.1%
	Clase 2	0 0.0%	283 24.7%	1 0.1%	0 0.0%	99.6% 0.4%
	Clase 3	0 0.0%	3 0.3%	285 24.9%	0 0.0%	99.0% 1.0%
	Clase 4	4 0.3%	0 0.0%	0 0.0%	271 23.7%	98.5% 1.5%
		98.6% 1.4%	99.0% 1.0%	99.7% 0.3%	94.8% 5.2%	98.0% 2.0%

Figura 85: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

Clasificación con 6 características (razón 1, razón 2, razón 3, razón 4, razón 5, Desviación estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	286 25.0%	0 0.0%	0 0.0%	1 0.1%	99.7% 0.3%
	Clase 2	0 0.0%	285 24.9%	3 0.3%	0 0.0%	99.0% 1.0%
	Clase 3	0 0.0%	1 0.1%	283 24.7%	0 0.0%	99.6% 0.4%
	Clase 4	0 0.0%	0 0.0%	0 0.0%	285 24.9%	100% 0.0%
		100% 0.0%	99.7% 0.3%	99.0% 1.0%	99.7% 0.3%	99.6% 0.4%

Figura 86: Matriz de confusión para 4 clases: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.

### 13.7. Redes Neuronales: Resumen resultados EEG

En la Figura 87 se puede observar el resumen de los resultados en pruebas inter-sujeto, similarmente la Figura 88 muestra los promedios de clasificación obtenidos en las pruebas intra-sujeto. Para observar los resultados completos de pruebas inter-sujeto, es necesario referir al Anexo 18.2.1. Para los resultados de las pruebas intra-sujeto se puede referir al Anexo 18.2.2.

Resumen resultados RN: Señales EEG			
Tiempo Continuo - Inter-sujeto			
Características	No. Clases	% Exactitud	
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	3	84.2	
ZC, MAV, Desviación Estándar		78.8	
ZC, MAV		60.8	
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	4	81.9	
ZC, MAV, Desviación Estándar		71.9	
ZC, MAV		57.6	
Frecuencia - Inter-sujeto			
Razón 1, 2, 3, 4, 5, Desviación Estándar	3	93.1	
Razón 1, 2, 3		85.5	
Razón 1,2		83.6	
Razón 1, 2, 3, 4, 5, Desviación Estándar	4	84.2	
Razón 1, 2, 3		76	
Razón 1,2		66.2	

Figura 87: Resumen resultados clasificador para señales EEG - Inter-sujeto.

Resumen resultados RN: Señales EEG (PROMEDIO DE EXACTITUD)					
Tiempo Continuo - Intra-sujeto					
Características	No. Clases	P000	P001	Promedio: % Exactitud	
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	2	92	95.8	93.90	
ZC, MAV, Desviación Estándar		91.6	94.2	92.90	
ZC, MAV		89.3	78.1	83.70	
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	3	86.3	87.5	86.90	
ZC, MAV, Desviación Estándar		85	80.4	82.70	
ZC, MAV		76.3	75.6	75.95	
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	4	85.4	80.2	82.80	
ZC, MAV, Desviación Estándar		79.3	75.1	77.20	
ZC, MAV		71.4	69	70.20	
Frecuencia - Intra-sujeto					
Características	No. Clases	P000	P001	Promedio: % Exactitud	
Razón 1, 2, 3, 4, 5, Desviación Estándar	2	100	100	100.00	
Razón 1, 2, 3		100	100	100.00	
Razón 1,2		100	100	100.00	
Razón 1, 2, 3, 4, 5, Desviación Estándar	3	99.4	99.5	99.45	
Razón 1, 2, 3		99.6	99.1	99.35	
Razón 1,2		99.5	99.2	99.35	
Razón 1, 2, 3, 4, 5, Desviación Estándar	4	100	99.6	99.80	
Razón 1, 2, 3		98	97.9	97.95	
Razón 1,2		96.5	97.1	96.80	

Figura 88: Resumen resultados clasificador para señales EEG - Intra-sujeto.

El estudio reveló información importante acerca de los entrenamientos utilizando características en el dominio del tiempo y en el dominio de la frecuencia. Particularmente, las características en el dominio de la frecuencia ofrecieron las clasificaciones con mayor exactitud.

titud del estudio. En comparación a los porcentajes de exactitud con características en el dominio del tiempo, los entrenamientos utilizando características en el dominio de la frecuencia presentaron menos variabilidad entre iteraciones de entrenamiento. Además, se notó que utilizar las 4 características evaluadas en el estudio del dominio de la frecuencia, fue suficiente para lograr un porcentaje de clasificación bastante cercano al obtenido utilizando las 6 características, y en ocasiones, inclusive mejor. En base a lo anterior, se concluyó que agregar más características al modelo no siempre era sinónimo de un mejor entrenamiento, y al contrario, hacían este proceso más tardado. Comparando los resultados inter e intra-sujeto, se evidenció que las pruebas intra-sujeto mantuvieron mayores porcentajes de clasificación, similar a lo observado en la sección 13.4. Por último, la clasificación de 2 gestos utilizando características en el dominio de la frecuencia, demostró que a pesar de variar las características extraídas se lograron porcentajes de clasificación iguales.

## 13.8. SVM - Señales EMG: Inter-sujeto

Para la aplicación de las máquinas de vectores de soporte se utilizaron los siguiente hiperparámetros: 10 *k folds* y kernel *gaussiano*. Los parámetros de análisis estadístico se basaron en comparar la totalidad de características (5 características en el dominio del tiempo) y variar la cantidad de gestos.

### 13.8.1. Clasificación de características - Dominio del tiempo

**Matriz de confusión 3 gestos: Puño arriba, puño abajo, puño**

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	77 30.2%	13 5.1%	0 0.0%	85.6% 14.4%
	Clase 2	7 2.7%	72 28.2%	0 0.0%	91.1% 8.9%
	Clase 3	1 0.4%	0 0.0%	85 33.3%	98.8% 1.2%
		90.6% 9.4%	84.7% 15.3%	100% 0.0%	91.8% 8.2%

Figura 89: Clasificación inter-sujeto de 3 gestos, 5 características en el dominio del tiempo.

### Matriz de confusión 4 gestos: Puño arriba, puño abajo, puño, palma extendida.

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	91 21.4%	9 2.1%	0 0.0%	1 0.2%	90.1% 9.9%
	Clase 2	13 3.1%	96 22.6%	4 0.9%	2 0.5%	83.5% 16.5%
	Clase 3	0 0.0%	2 0.5%	88 20.7%	32 7.5%	72.1% 27.9%
	Clase 4	2 0.5%	0 0.0%	14 3.3%	71 16.7%	81.6% 18.4%
		85.8% 14.2%	89.7% 10.3%	83.0% 17.0%	67.0% 33.0%	81.4% 18.6%
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud

Figura 90: Clasificación inter-sujeto de 4 gestos, 5 características en el dominio del tiempo.

### 13.9. SVM - Señales EMG: Intra-sujeto

Como fue descrito en la sección 13.3 del documento, el enfoque intra-sujeto implicó la recolección de datos de tres sujetos (P000, P001, P002) y se centró en el análisis de las variaciones individuales entre ellos. Con el fin de realizar una comparación de los porcentajes de clasificación alcanzados por los distintos clasificadores, la presente sección contiene las matrices de confusión resultantes de aplicar un clasificador SVM a datos recolectados de los 3 sujetos.

### 13.9.1. Clasificación de características - Dominio del tiempo: Sujeto P000

Matriz de confusión 2 gestos: Puño arriba, puño abajo

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exactitud
Output Class	Clase 1	30 50.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	30 50.0%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%
		Target Class		
		Clase 1	Clase 2	Exactitud

Figura 91: Clasificación sujeto P000, 2 gestos, 5 características en el dominio del tiempo.

Matriz de confusión 3 gestos: Puño arriba, puño abajo, puño

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	24 32.4%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	24 32.4%	0 0.0%	100% 0.0%
	Clase 3	0 0.0%	1 1.4%	25 33.8%	96.2% 3.8%
		100% 0.0%	96.0% 4.0%	100% 0.0%	98.6% 1.4%
		Target Class			
		Clase 1	Clase 2	Clase 3	Exactitud

Figura 92: Clasificación sujeto P000, 3 gestos, 5 características en el dominio del tiempo.

### Matriz de confusión 4 gestos: Puño arriba, puño abajo, puño, palma extendida

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exclusud
Output Class	Clase 1	23 23.2%	0 0.0%	0 0.0%	1 1.0%	95.8% 4.2%
	Clase 2	2 2.0%	24 24.2%	0 0.0%	0 0.0%	92.3% 7.7%
	Clase 3	0 0.0%	1 1.0%	23 23.2%	2 2.0%	88.5% 11.5%
	Clase 4	0 0.0%	0 0.0%	1 1.0%	22 22.2%	95.7% 4.3%
		92.0% 8.0%	96.0% 4.0%	95.8% 4.2%	88.0% 12.0%	92.9% 7.1%

Figura 93: Clasificación sujeto P000, 4 gestos, 5 características en el dominio del tiempo.

### 13.9.2. Clasificación de características - Dominio del tiempo: Sujeto P001

#### Matriz de confusión 2 gestos: Puño arriba, puño abajo

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exclusud
Output Class	Clase 1	25 51.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	24 49.0%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%

Figura 94: Clasificación sujeto P001, 2 gestos, 5 características en el dominio del tiempo.

### Matriz de confusión 3 gestos: Puño arriba, puño abajo, puño

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	23 31.1%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	1 1.4%	23 31.1%	2 2.7%	88.5% 11.5%
	Clase 3	1 1.4%	1 1.4%	23 31.1%	92.0% 8.0%
		92.0% 8.0%	95.8% 4.2%	92.0% 8.0%	93.2% 6.8%

Figura 95: Clasificación sujeto P001, 3 gestos, 5 características en el dominio del tiempo.

### Matriz de confusión 4 gestos: Puño arriba, puño abajo, puño, palma extendida

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	25 25.3%	0 0.0%	4 4.0%	1 1.0%	83.3% 16.7%
	Clase 2	0 0.0%	20 20.2%	5 5.1%	1 1.0%	76.0% 23.1%
	Clase 3	0 0.0%	3 3.0%	16 16.2%	1 1.0%	80.0% 20.0%
	Clase 4	0 0.0%	1 1.0%	0 0.0%	22 22.2%	95.7% 4.3%
		100% 0.0%	83.3% 16.7%	64.0% 36.0%	88.0% 12.0%	83.8% 16.2%

Figura 96: Clasificación sujeto P001, 4 gestos, 5 características en el dominio del tiempo.

## 13.10. Máquinas SVM - Señales EEG: Inter-sujeto

Para el estudio de las señales EEG en el enfoque inter-sujeto, se planteó analizar las diferencias en la exactitud de clasificación de características extraídas en el dominio de la frecuencia y el dominio del tiempo, tal y como fue realizado en la sección 13.5. Los resultados de esta sección fueron obtenidos según los hiper-parámetros detallados en la sección 13.8.

### 13.10.1. Clasificación de características - Dominio del tiempo

**Matriz de confusión 3 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada**

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	59 27.3%	3 1.4%	0 0.0%	95.2% 4.8%
	Clase 2	13 6.0%	66 30.6%	4 1.9%	79.5% 20.5%
	Clase 3	0 0.0%	3 1.4%	68 31.5%	95.8% 4.2%
		81.9% 18.1%	91.7% 8.3%	94.4% 5.6%	89.4% 10.6%

Figura 97: Clasificación inter-sujeto de 3 gestos, 5 características en el dominio del tiempo.

### Matriz de confusión 4 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	54 23.5%	6 2.6%	0 0.0%	0 0.0%	90.0% 10.0%
	Clase 2	2 0.9%	45 19.6%	5 2.2%	1 0.4%	84.9% 15.1%
	Clase 3	1 0.4%	1 0.4%	49 21.3%	1 0.4%	94.2% 5.8%
	Clase 4	0 0.0%	5 2.2%	4 1.7%	56 24.3%	86.2% 13.8%
		94.7% 5.3%	78.9% 21.1%	84.5% 15.5%	96.6% 3.4%	88.7% 11.3%

Figura 98: Clasificación inter-sujeto de 4 gestos, 5 características en el dominio del tiempo.

### 13.10.2. Clasificación de características - Dominio de la frecuencia

#### Matriz de confusión 3 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	72 33.3%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	72 33.3%	0 0.0%	100% 0.0%
	Clase 3	0 0.0%	0 0.0%	72 33.3%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%	100% 0.0%

Figura 99: Clasificación inter-sujeto de 3 gestos, 6 características en el dominio de la frecuencia.

**Matriz de confusión 4 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.**

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	57 24.8%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	56 24.3%	0 0.0%	0 0.0%	100% 0.0%
	Clase 3	0 0.0%	1 0.4%	58 25.2%	0 0.0%	98.3% 1.7%
	Clase 4	0 0.0%	0 0.0%	0 0.0%	58 25.2%	100% 0.0%
		100% 0.0%	98.2% 1.8%	100% 0.0%	100% 0.0%	99.6% 0.4%

Figura 100: Clasificación inter-sujeto de 4 gestos, 6 características en el dominio de la frecuencia.

### 13.11. Máquinas SVM - Señales EEG: Intra-sujeto

Los resultados del enfoque intra-sujeto en clasificadores SVM, utilizan los mismos parámetros detallados en la sección 13.6. Similarmente, en esta sección, se presenta el estudio de 2 sujetos (P000,P001).

### 13.11.1. Clasificación de características - Dominio del tiempo: Sujeto P000

**Matriz de confusión 2 gestos: Cabeza arriba, cabeza abajo**

Matriz de Confusión Confusion Matrix			
Output Class			Exactitud
	Clase 1	Clase 2	
Clase 1	31 47.7%	2 3.1%	93.9% 6.1%
Clase 2	1 1.5%	31 47.7%	96.9% 3.1%
	96.9% 3.1%	93.9% 6.1%	95.4% 4.6%

Figura 101: Clasificación sujeto P000, 2 gestos, 5 características en el dominio del tiempo.

**Matriz de confusión 3 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada**

Matriz de Confusión Confusion Matrix				
Output Class				Exactitud
	Clase 1	Clase 2	Clase 3	
Clase 1	30 30.6%	2 2.0%	0 0.0%	93.8% 6.2%
Clase 2	2 2.0%	27 27.6%	2 2.0%	87.1% 12.9%
Clase 3	1 1.0%	4 4.1%	30 30.6%	85.7% 14.3%
	90.9% 9.1%	81.8% 18.2%	93.8% 6.2%	88.8% 11.2%

Figura 102: Clasificación sujeto P000, 3 gestos, 5 características en el dominio del tiempo.

**Matriz de confusión 4 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba**

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	26 22.6%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	2 1.7%	22 19.1%	2 1.7%	4 3.5%	73.3% 26.7%
	Clase 3	0 0.0%	6 5.2%	26 22.6%	0 0.0%	81.2% 18.8%
	Clase 4	0 0.0%	1 0.9%	1 0.9%	25 21.7%	92.6% 7.4%
		92.9% 7.1%	75.9% 24.1%	89.7% 10.3%	86.2% 13.8%	86.1% 13.9%

Figura 103: Clasificación sujeto P000, 3 gestos, 5 características en el dominio del tiempo.

### 13.11.2. Clasificación de características - Dominio del tiempo: Sujeto P001

**Matriz de confusión 2 gestos: Cabeza arriba, cabeza abajo**

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exactitud
Output Class	Clase 1	35 48.6%	0 0.0%	100% 0.0%
	Clase 2	1 1.4%	36 50.0%	97.3% 2.7%
		97.2% 2.8%	100% 0.0%	98.6% 1.4%

Figura 104: Clasificación sujeto P001, 2 gestos, 5 características en el dominio del tiempo.

### Matriz de confusión 3 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	32 32.3%	2 2.0%	0 0.0%	94.1% 5.9%
	Clase 2	0 0.0%	29 29.3%	2 2.0%	93.5% 6.5%
	Clase 3	1 1.0%	2 2.0%	31 31.3%	91.2% 8.8%
		97.0% 3.0%	87.9% 12.1%	93.9% 6.1%	92.9% 7.1%

Figura 105: Clasificación sujeto P001, 3 gestos, 5 características en el dominio del tiempo.

### Matriz de confusión 4 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	27 23.7%	4 3.5%	0 0.0%	0 0.0%	87.1% 12.9%
	Clase 2	1 0.9%	17 14.9%	2 1.8%	3 2.6%	73.9% 26.1%
	Clase 3	0 0.0%	6 5.3%	24 21.1%	1 0.9%	77.4% 22.6%
	Clase 4	0 0.0%	2 1.8%	2 1.8%	25 21.9%	86.2% 13.8%
		96.4% 3.6%	58.6% 41.4%	85.7% 14.3%	86.2% 13.8%	81.6% 18.4%

Figura 106: Clasificación sujeto P001, 3 gestos, 5 características en el dominio del tiempo.

### 13.11.3. Clasificación de características - Dominio de la frecuencia: Sujeto P000

**Matriz de confusión 2 gestos: Cabeza arriba, cabeza abajo**

Matriz de Confusión Confusion Matrix			
Output Class			Exactitud
	Clase 1	Clase 2	
Clase 1	32 50.0%	0 0.0%	100% 0.0%
Clase 2	0 0.0%	32 50.0%	100% 0.0%
	100% 0.0%	100% 0.0%	100% 0.0%

Figura 107: Clasificación sujeto P000, 2 gestos, 6 características en el dominio de la frecuencia.

**Matriz de confusión 3 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada**

Matriz de Confusión Confusion Matrix				
Output Class				Exactitud
	Clase 1	Clase 2	Clase 3	
Clase 1	33 33.7%	0 0.0%	0 0.0%	100% 0.0%
Clase 2	0 0.0%	32 32.7%	1 1.0%	97.0% 3.0%
Clase 3	0 0.0%	0 0.0%	32 32.7%	100% 0.0%
	100% 0.0%	100% 0.0%	97.0% 3.0%	99.0% 1.0%

Figura 108: Clasificación sujeto P000, 3 gestos, 6 características en el dominio de la frecuencia.

**Matriz de confusión 4 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.**

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	29 25.4%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	28 24.6%	0 0.0%	0 0.0%	100% 0.0%
	Clase 3	0 0.0%	0 0.0%	29 25.4%	0 0.0%	100% 0.0%
	Clase 4	0 0.0%	0 0.0%	0 0.0%	28 24.6%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%	100% 0.0%	100% 0.0%

Figura 109: Clasificación sujeto P000, 4 gestos, 6 características en el dominio de la frecuencia.

#### 13.11.4. Clasificación de características - Dominio de la frecuencia: Sujeto P001

**Matriz de confusión 2 gestos: Cabeza arriba, cabeza abajo**

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exactitud
Output Class	Clase 1	36 50.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	36 50.0%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%

Figura 110: Clasificación sujeto P001, 2 gestos, 6 características en el dominio de la frecuencia.

**Matriz de confusión 3 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada**

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	32 33.0%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	32 33.0%	0 0.0%	100% 0.0%
	Clase 3	0 0.0%	0 0.0%	33 34.0%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%	100% 0.0%

Figura 111: Clasificación sujeto P001, 3 gestos, 6 características en el dominio de la frecuencia.

**Matriz de confusión 4 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba.**

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	32 25.2%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	31 24.4%	0 0.0%	0 0.0%	100% 0.0%
	Clase 3	0 0.0%	0 0.0%	32 25.2%	0 0.0%	100% 0.0%
	Clase 4	0 0.0%	0 0.0%	0 0.0%	32 25.2%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%	100% 0.0%	100% 0.0%

Figura 112: Clasificación sujeto P001, 4 gestos, 6 características en el dominio de la frecuencia.

## 13.12. Resumen resultados SVM

En la Figura 113 se presenta el resumen de las pruebas inter e intra-sujeto de clasificadores SVM aplicados a señales EMG. Similarmente en la Figura 114, se pueden observar los resultados de pruebas inter e intra-sujeto de clasificadores SVM aplicados a señales EEG. La totalidad de pruebas intra-sujeto en señales EMG se pueden observar en el Anexo 18.3.

Resumen resultados SVM: Señales EMG					
Dominio del tiempo - Intra-sujeto					
Características	No. Clases	P000	P001	P002	% Exactitud
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	2	100	100	98	99.33
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	3	98.6	93.2	94.6	95.47
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	4	92.9	83.8	87	87.90
Resumen resultados SVM: Señales EMG					
Dominio del tiempo - Inter-sujeto					
Características	No. Clases	% Exactitud			
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	3	91.8			
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	4	81.4			

Figura 113: Resumen resultados SVM, clasificación EMG.

Resumen resultados SVM: Señales EEG					
Dominio del tiempo - Intra-sujeto					
Características	No. Clases	P000	P001	P002	% Exactitud
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	2	95.4	98.6		97
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	3	88.8	92.9		90.85
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	4	86.1	81.6		83.85
Dominio de la frecuencia - Intra-sujeto					
Características	No. Clases	P000	P001	P002	% Exactitud
Razón 1, 2, 3, 4, 5, Desviación Estándar	2	100	100		100
Razón 1, 2, 3, 4, 5, Desviación Estándar	3	99	100		99.5
Razón 1, 2, 3, 4, 5, Desviación Estándar	4	100	100		100
Resumen resultados SVM: Señales EEG					
Dominio del tiempo - Inter-sujeto					
Características	No. Clases	% Exactitud			
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	3	89.4			
ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar	4	88.7			
Frecuencia - Inter-sujeto					
Características	No. Clases	% Exactitud			
Razón 1, 2, 3, 4, 5, Desviación Estándar	3	100			
Razón 1, 2, 3, 4, 5, Desviación Estándar	4	99.6			

Figura 114: Resumen resultados SVM, clasificación EEG.

Para el entrenamiento utilizando máquinas de vectores de soporte (SVM) se notó que los altos porcentajes de clasificación fueron más fáciles de replicar. Como consecuente, estos resultados se catalogaron como los mejores entrenamientos de clasificación, permitiendo porcentajes de clasificación del 100 % inclusive para 4 gestos utilizando características en el dominio de la frecuencia. Esto hace sentido, pues el uso de redes neuronales requiere una mayor cantidad de datos para generar clasificaciones precisas. En contraste, una SVM funciona mejor con pocas muestras, es más rápido al entrenar y su funcionamiento es aún mejor como clasificador binario, tal y como evidencian los resultados de clasificación para 2 clases.

### 13.13. Resultados de clasificación - HUMANA

En esta sección, se exponen los resultados de clasificación utilizando los algoritmos previamente desarrollados para la identificación de segmentos sanos, ictales, preictales e interictales en pacientes con epilepsia. Estos algoritmos demostraron su capacidad para realizar anotaciones automáticas en las señales EDF obtenidas en colaboración con HUMANA.

### 13.14. Redes Neuronales - 4 clases

Para entrenar los modelos de red neuronal se usó la base de datos utilizada en el trabajo de graduación [10], estos presentan datos de segmentos sanos, ictales, preictales e interictales. El mejor entrenamiento de red neuronal se alcanzó con 10 capas y la función *trainr*. La Figura 115 muestra el porcentaje de clasificación alcanzado al utilizar características en el dominio del tiempo (5 características), similarmente, en la Figura 116 se observa el porcentaje de clasificación alcanzado utilizando 6 características en el dominio de la frecuencia.

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	599 25.0%	0 0.0%	2 0.1%	0 0.0%	99.7% 0.3%
	Clase 2	1 0.0%	599 25.0%	86 3.6%	75 3.1%	78.7% 21.3%
	Clase 3	0 0.0%	1 0.0%	368 15.3%	138 5.8%	72.6% 27.4%
	Clase 4	0 0.0%	0 0.0%	144 6.0%	387 16.1%	72.9% 27.1%
		99.8% 0.2%	99.8% 0.2%	61.3% 38.7%	64.5% 35.5%	81.4% 18.6%

Figura 115: Resultados RN, clasificación de segmentos sanos, ictales, preictales e interictales.

Matriz de Confusión Confusion Matrix					
Output Class	Target Class				
	Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Clase 1	600 25.0%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
Clase 2	0 0.0%	599 25.0%	0 0.0%	14 0.6%	97.7% 2.3%
Clase 3	0 0.0%	0 0.0%	591 24.6%	7 0.3%	98.8% 1.2%
Clase 4	0 0.0%	1 0.0%	9 0.4%	579 24.1%	98.3% 1.7%
	100% 0.0%	99.8% 0.2%	98.5% 1.5%	96.5% 3.5%	98.7% 1.3%

Figura 116: Resultados RN, clasificación de segmentos sanos,ictales, preictales e interictales.

Estos resultados evidenciaron que el entrenamiento con 6 características en el dominio de la frecuencia presentó el mayor porcentaje de exactitud (98.7%), en comparación al porcentaje obtenido con características en el dominio del tiempo (81.4%)

### 13.15. SVM - 4 clases

En esta sección se presentan los porcentajes de clasificación de segmentos sanos,ictales, preictales e interictales utilizando el clasificador SVM. Los mejores resultados se obtuvieron con 10  $k$  particiones, utilizando exclusivamente el kernel *Gaussiano*.

Matriz de Confusión Confusion Matrix					
Output Class	Target Class				
	Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Clase 1	60 25.0%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
Clase 2	0 0.0%	58 24.2%	4 1.7%	1 0.4%	92.1% 7.9%
Clase 3	0 0.0%	1 0.4%	49 20.4%	5 2.1%	89.1% 10.9%
Clase 4	0 0.0%	1 0.4%	7 2.9%	54 22.5%	87.1% 12.9%
	100% 0.0%	96.7% 3.3%	81.7% 18.3%	90.0% 10.0%	92.1% 7.9%

Figura 117: Resultados SVM, clasificación de segmentos sanos,ictales, preictales e interictales.

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	60 25.0%	0 0.0%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	60 25.0%	0 0.0%	1 0.4%	98.4% 1.6%
	Clase 3	0 0.0%	0 0.0%	60 25.0%	0 0.0%	100% 0.0%
	Clase 4	0 0.0%	0 0.0%	0 0.0%	59 24.6%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%	98.3% 1.7%	99.6% 0.4%
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud

Figura 118: Resultados SVM, clasificación de segmentos sanos, ictales, preictales e interictales.

En la Figura 115 se presenta la matriz de confusión de 4 clases utilizando 5 características en el dominio del tiempo. La exactitud obtenida de 92.1 % fue substancialmente mejor que la obtenida utilizando redes neuronales y las mismas características en el dominio del tiempo, esto demostró la superioridad de las SVM en la clasificación de mayor cantidad de clases. En la Figura 118 se puede observar la matriz de confusión resultante al clasificar las 4 clases, utilizando características en el dominio de la frecuencia. En esta se puede observar un porcentaje de exactitud del 99.6 %, siendo mejor que la obtenida utilizando redes neuronales.

### 13.16. Análisis de señales

Una vez entrenados los modelos, se realizaron pruebas de anotaciones automáticas en el conjunto de datos proporcionado por HUMANA. Para este proceso se requirió la carga del EDF de estudio, la selección de canales de interés y el .mat contenido el entrenamiento utilizado. En la Figura 119, se observa la interfaz de selección para generar anotaciones automáticas. El resultado del análisis se muestra en la Figura 120, donde se traza del color seleccionado los segmentos identificados como sanos, ictales, preictales e interictales.

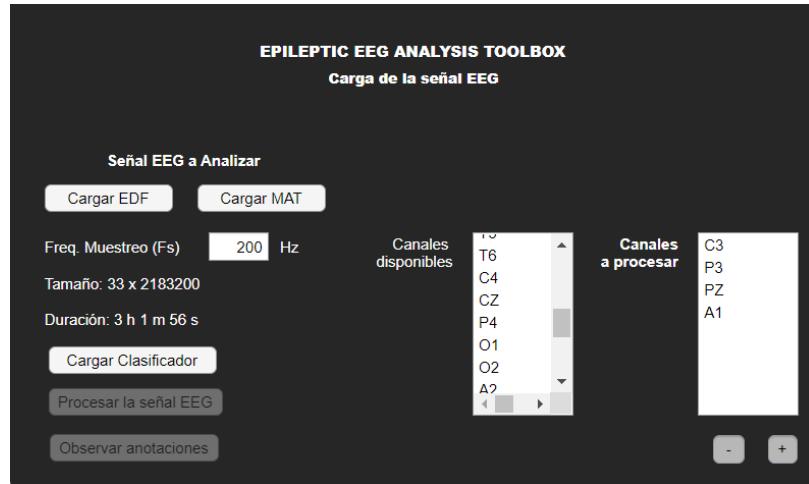


Figura 119: Configuración de interfaz para generar anotaciones automáticas.

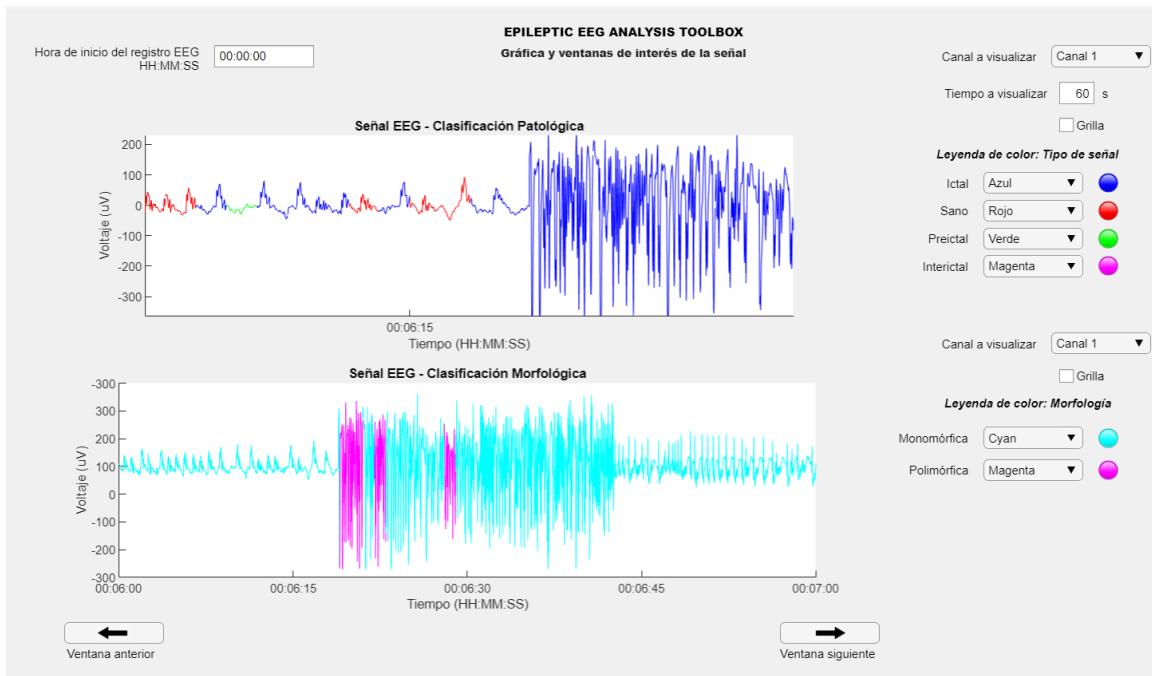


Figura 120: Anotaciones automáticas generadas para EDF proporcionado por HUMANA.

## CAPÍTULO 14

---

### Interfaces de captura y aprendizaje

---

Para el desarrollo de este capítulo, es importante destacar que los sistemas Biopac no cuentan con la capacidad de capturar y transmitir datos de las señales bioeléctricas en tiempo real, similar a una comunicación serial. Para comprender el funcionamiento de los sistemas Biopac, fue necesario consultar la documentación del Biopac MP36, esta indicó que el puerto USB de conexión trasmisiva la data de la señal. Se intentó acceder a estos datos utilizando la biblioteca *PyUsb* de Python.

A pesar de lograr el acceso al puerto USB del Biopac MP36, resultó imposible interpretar los datos que se estaban transmitiendo. Esto se debió a que la información estaba encriptada de tal manera que solo la empresa *Biopac Systems Inc.* tenía la capacidad de interpretar datos de transmisión. Ante esta situación, se procedió a contactar a los técnicos de la compañía para plantear la inquietud.

Los técnicos de la compañía ofrecieron una solución en forma de un paquete de desarrollo por un costo de \$1,300. Este paquete permitiría la interpretación en tiempo real de los datos capturados por el Biopac MP36.

Dado el alto costo previamente mencionado, este trabajo presenta una alternativa con una Tiva-C y la plataforma de programación *Energia*. Esto es una forma de validar las interfaces a partir de señales previamente capturadas. En esta implementación, el microcontrolador contiene datos preexistentes de capturas de señales bioeléctricas generadas con el Biopac MP36. Dichos datos son transmitidos a la computadora mediante comunicación serial, simulando así una transmisión en tiempo real de los mismos. La interpretación de los datos transmitidos se lleva a cabo a través de una interfaz desarrollada específicamente para este propósito. En la Figura 121 se incluye un diagrama de flujo que ilustra la implementación.

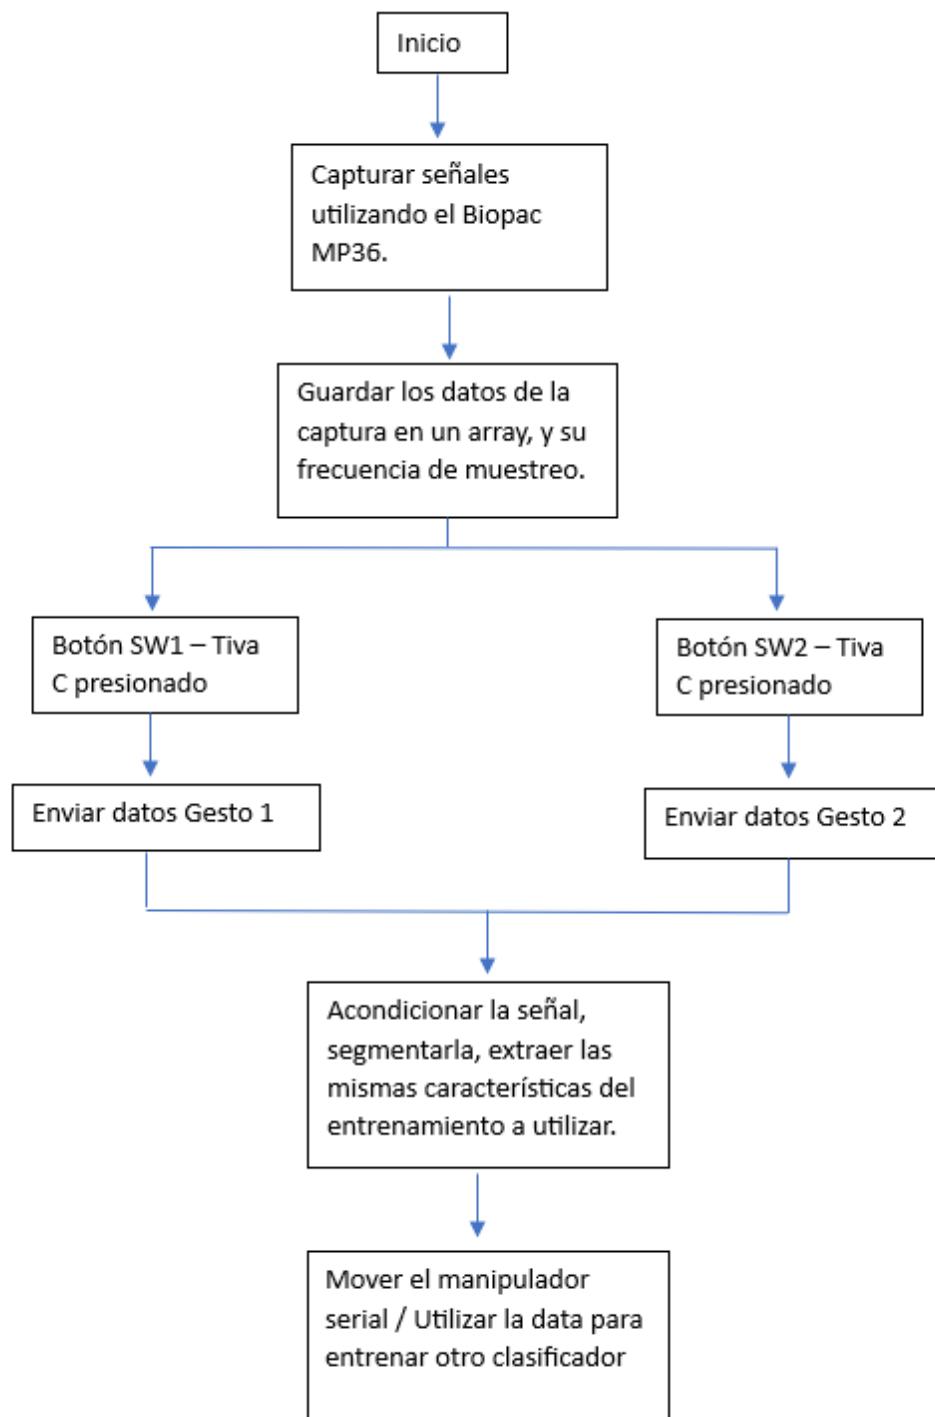


Figura 121: Diagrama de flujo comunicación serial, Tiva-C.

Para facilitar la interacción entre las distintas plataformas, se implementó el acceso directo al sistema de captura de Biopac *BSL Analysis 4.1*, a través de la interfaz de recolección de datos EMG/EEG desarrollada, como se muestra en la Figura 122. La interfaz propor-

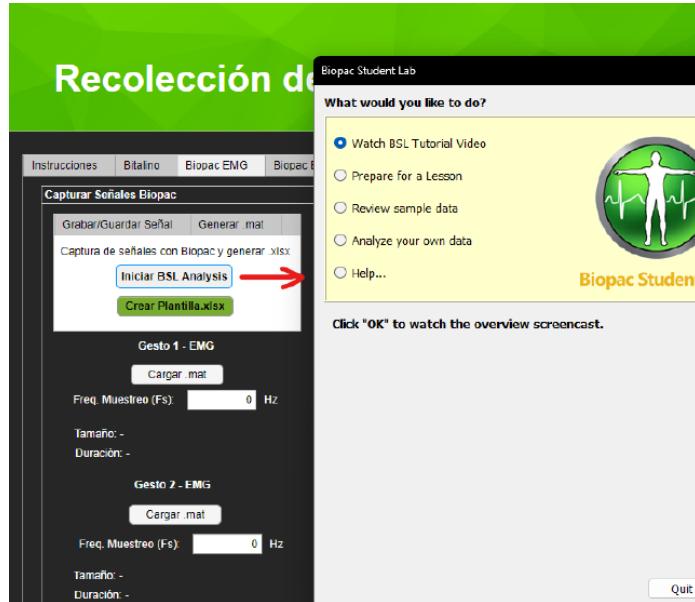


Figura 122: Interfaz de recolección EMG/EEG, acceso directo a *BSL Analysis 4.1*.

ciona la capacidad de generar una plantilla de proyecto predeterminada en formato .xlsx. En esta plantilla, los usuarios tienen la posibilidad de guardar los datos capturados y, al mismo tiempo, interactuar con el software de captura de Biopac para extraer información de la señal que se considere pertinente para el estudio, esta funcionalidad se muestra en la Figura 123.

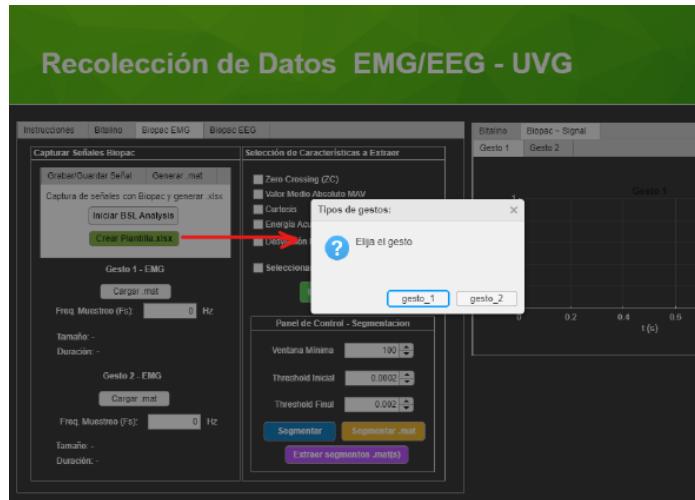


Figura 123: Interfaz de recolección EMG/EEG, generación de plantilla.

## 14.1. Interfaces desarrolladas

Para esta sección se planteó como objetivo la implementación de los algoritmos de control robótico utilizados en fases anteriores al nuevo conjunto de datos recolectados. Para ello, fue necesario implementar la *Robotics Toolbox*, desarrollada por Peter Corke, esta es una herramienta ampliamente reconocida en el campo de la robótica, esta ofrece una amplia gama de funciones destinadas al estudio y simulación de sistemas robóticos. La herramienta fue utilizada para llevar a cabo la simulación de un manipulador serial con 6 grados de libertad (GDL), se ha optado por utilizar el manipulador Puma 560 como modelo de estudio.

El proceso de implementación inició definiendo las juntas del robot Puma 560, se utilizó la convención *Denavit-Hartenberg*, esta convención define las juntas como objetos de tipo *link*. Posteriormente, fue necesario unirlas para formar un robot de tipo *SerialLink*.

```
function robot = puma560()

    % Parámetros DH del Puma 560
    L1 = Link('d', 0.675, 'a', 0, 'alpha', pi/2, 'offset', 0, 'qlim', [-160 160]*deg);
    L2 = Link('d', 0, 'a', 0.35, 'alpha', 0, 'offset', -pi/2, 'qlim', [-45 225]*deg);
    L3 = Link('d', 0, 'a', 1.25, 'alpha', 0, 'offset', 0, 'qlim', [-225 45]*deg);
    L4 = Link('d', 0, 'a', -0.054, 'alpha', pi/2, 'offset', -pi/2, 'qlim', [-110 170]*deg);
    L5 = Link('d', 0.96, 'a', 0, 'alpha', -pi/2, 'offset', 0, 'qlim', [-100 100]*deg);
    L6 = Link('d', 0.193, 'a', 0, 'alpha', 0, 'offset', 0, 'qlim', [-266 266]*deg);

    % Crear la estructura del robot
    robot = SerialLink([L1 L2 L3 L4 L5 L6], 'name', 'Puma560');

end
```

Figura 124: Definición de manipulador Puma 560, convención *Denavit-Hartenberg*.

## 14.2. Simulaciones

Con el propósito de integrar todos los conceptos abordados en los capítulos previos, la interfaz de entrenamiento EMG/EEG creada en este proyecto permite el entrenamiento de un clasificador y la asociación de configuraciones específicas del robot Puma 560 a ciertos gestos. Para este procedimiento fue fundamental realizar un proceso de homogeneización a las matrices de características, esto garantizó que los datos fueran comparables, mejorando la precisión del clasificador al tomar decisiones basadas en datos uniformes.

Para simular una interacción con el robot, es necesario cargar un segmento de señal que contenga una contracción muscular o una señal cerebral. La interfaz se desarrolló para utilizarse sin necesidad de conectar a un microcontrolador o dispositivo de captura en tiempo real, así como también para simular la transmisión de datos en tiempo real utilizando dichos dispositivos.

#### 14.2.1. Puma 560 - Resultados de control automático

En el conjunto de Figuras 125-126 se muestra la carga de segmentos utilizando un clasificador de 4 gestos y cómo la interfaz interpreta de esta información para realizar simulaciones en el manipulador Puma 560. En la interfaz, el conjunto de algoritmos se encarga de filtrar la señal y extraer sus características de manera automática, ya que estas deben pasar el mismo procesamiento del modelo entrenado. Además, la interfaz muestra el histórico de la convergencia del manipulador por medio de cinemática directa. El control automático contiene posiciones precargadas, por lo que el usuario no debe ingresar ninguna configuración.

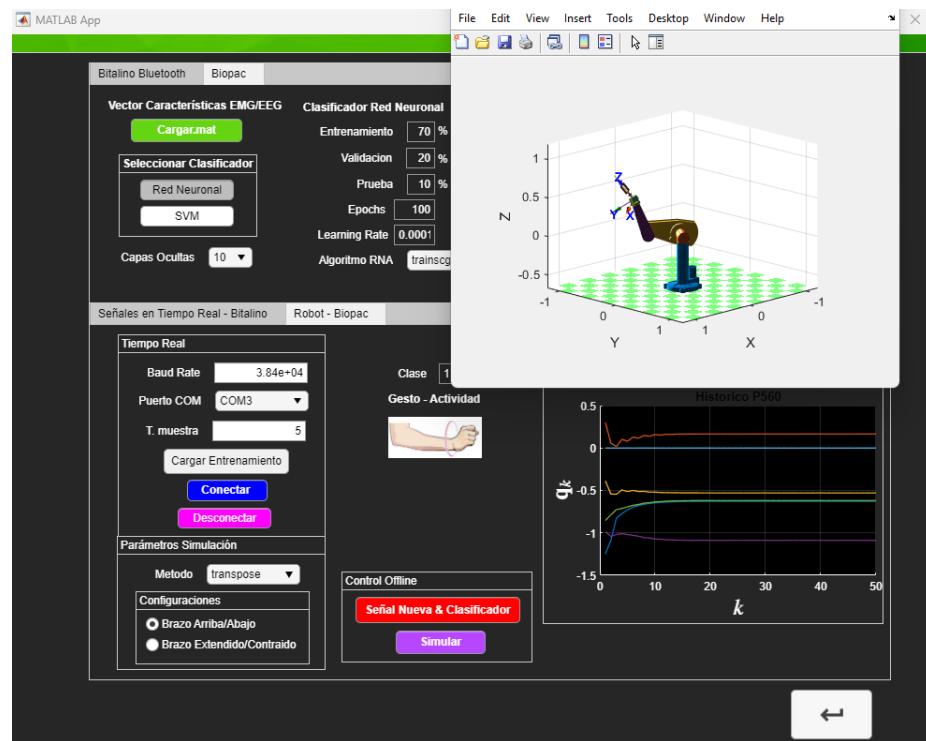


Figura 125: Carga de segmento señal EMG (puño arriba).

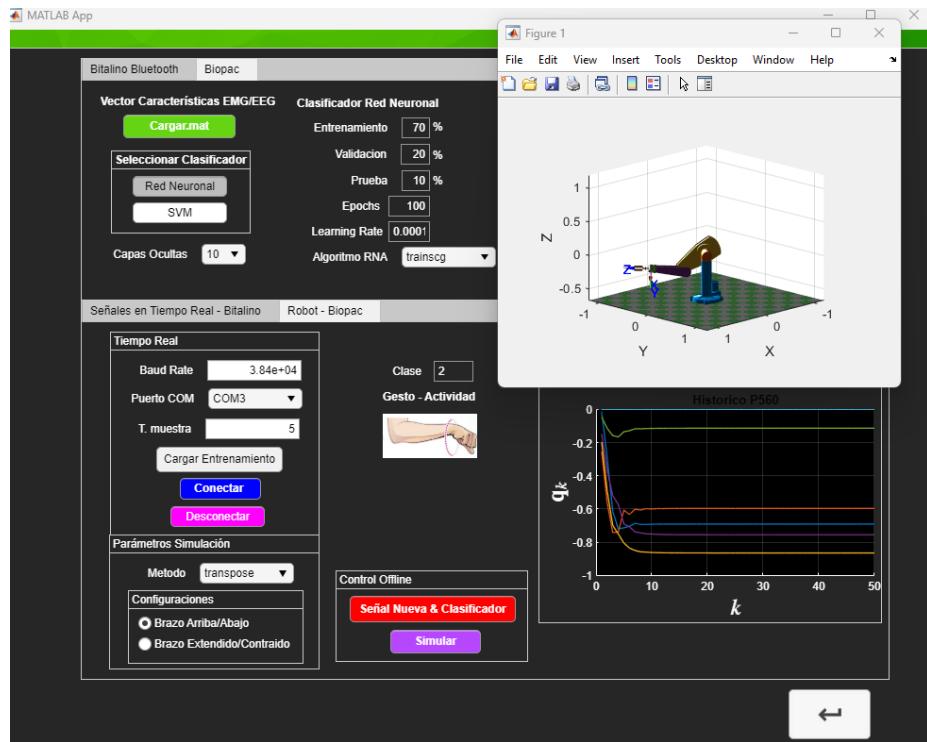


Figura 126: Carga de segmento señal EMG (puño abajo).

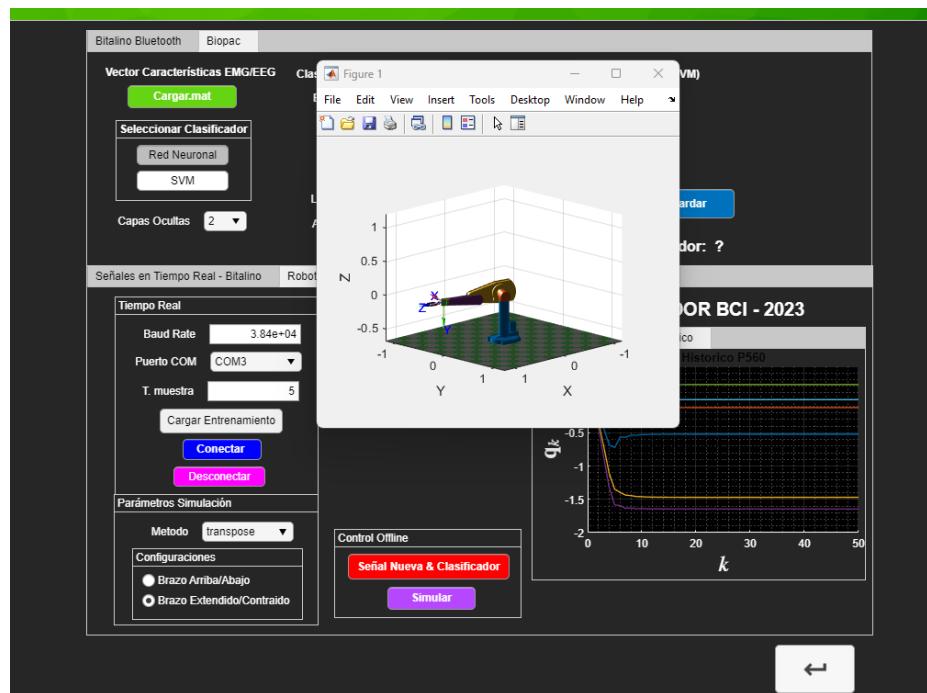


Figura 127: Carga de segmento señal EMG (palma extendida).

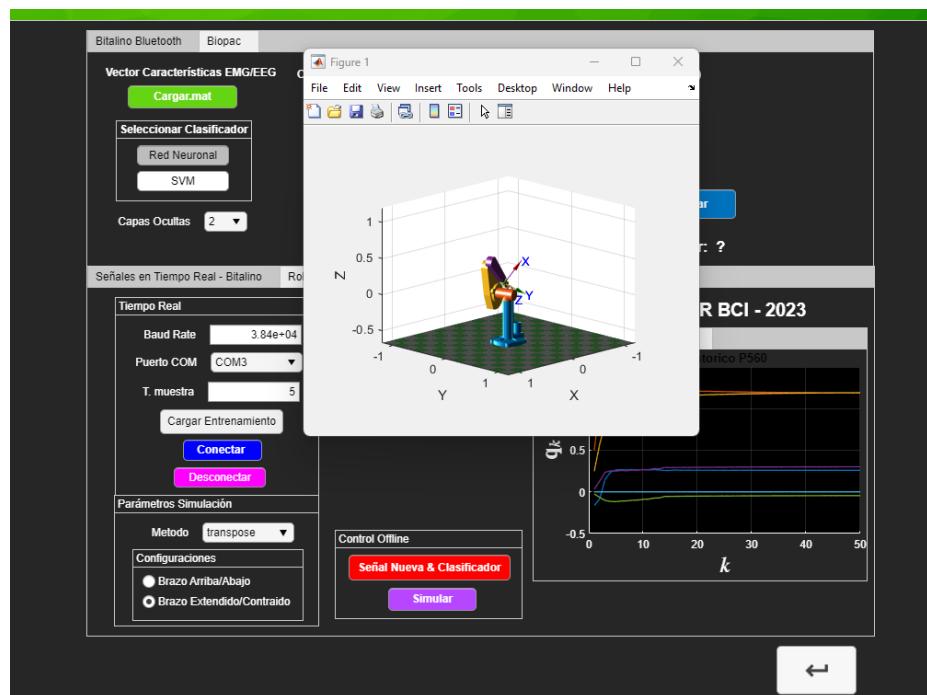


Figura 128: Carga de segmento señal EMG (puño).

# CAPÍTULO 15

---

## Conclusiones

---

- El algoritmo desarrollado para la identificación de segmentos de actividad permitió disminuir grandemente el tiempo computacional de los algoritmos de extracción y aprendizaje automático. Al identificar los parámetros necesarios, resulta una herramienta bastante poderosa para el entrenamiento de sistemas robóticos.
- Las características en el dominio del tiempo utilizadas en este trabajo, presentaron bajo requerimiento computacional y además permitieron un alto porcentaje de clasificación en estudios intra-sujeto de señales EMG, alcanzando porcentajes de clasificación correcta de 91.07 % para 4 gestos, 95.57 % para 3 gestos y 97.43 % para 2 gestos.
- Los sistemas Biopac permiten la captura de señales bioeléctricas con bastante calidad y precisión. Esto permitió flexibilidad y capacidad de crear control robótico variado y personalizable.
- Se comprobó que las características en frecuencia presentan el mayor porcentaje de exactitud y en comparación a las características en el dominio del tiempo, estas requieren de un gran poder computacional.
- El análisis intra-sujeto demostró en promedio tener un mejor porcentaje de clasificación en comparación con el análisis inter-sujeto.

# CAPÍTULO 16

---

## Recomendaciones

---

- Considerar un método de escalado para homogeneizar las señales, en lugar de utilizar una técnica de *padding* para llenar segmentos cortos. Esto reduciría por completo el error en la segmentación, creando un entrenamiento significativamente más robusto.
- Si bien el uso de la Tiva-C permite la transmisión simulada de datos capturados en tiempo real, es importante tener en cuenta que también introduce un porcentaje de error debido a posibles problemas de conexión y tiempos de transmisión. Por lo tanto, se sugiere investigar y evaluar diferentes herramientas de captura e interpretación de señales bioeléctricas en tiempo real.
- En lo que respecta a la captura de señales de un sujeto, se recomienda mantener una consistencia en la posición de los electrodos a lo largo de todo el período de captura. Esto ayudaría a mitigar los errores asociados con posiciones de electrodos variables.
- A pesar de contar con clasificadores altamente precisos y eficientes en términos de tiempo computacional, sería prudente explorar alternativas que puedan aportar una mayor robustez frente a las variabilidades entre sujetos, como por ejemplo el clasificador de patrones *K-nearest Neighbors*.

## CAPÍTULO 17

---

### Bibliografía

---

- [1] Organización Panamericana de la Salud, *Informe sobre la epilepsia en América y El Caribe*, <https://www3.paho.org/>, Accesado: 23-04-2023, 2021.
- [2] HUMANA, *Centro de Epilepsia y Neurología Funcional*, <https://humanagt.org/epilepsia/>, Accesado: 23-04-2023, 2023.
- [3] R. Sepulveda, O. Montiel y G. Díaz, “Clasificacion de Señales Encefalográficas Mediante Redes Neuronales Artificiales,” *Redalyc*, vol. 19, n.º 1, págs. 69-88, 2015.
- [4] M. F. Girón, “Interfaz Biomédica para el Control de Sistemas Robóticos Utilizando Señales EMG,” Tesis de licenciatura, Universidad Del Valle de Guatemala, 2021.
- [5] R. Ralda, “Interfaz Biomédica para el Control de Sistemas Robóticos Utilizando Señales EEG,” Tesis de licenciatura, Universidad Del Valle de Guatemala, 2020.
- [6] R. J. Cáceres, “Interfaz para el Control de Sistemas Robóticos Utilizando Combinaciones de Señales Biomédicas,” Tesis de licenciatura, Universidad Del Valle de Guatemala, 2022.
- [7] B. Abbasi y D. Goldenholz, “Machine learning applications in epilepsy,” *Epilepsia*, vol. 60, n.º 10, págs. 1528-1167, 2019.
- [8] M. J. Angulo, “Análisis y Reconocimiento de Patrones de Señales Biomédicas de Pacientes con Epilepsia,” Tesis de licenciatura, Universidad Del Valle de Guatemala, 2020.
- [9] M. F. Pineda, “Diseño e Implementación de una Base de Datos de Señales Biomédicos de Pacientes con Epilepsia,” Tesis de licenciatura, Universidad Del Valle de Guatemala, 2020.
- [10] D. A. Vela, “Automatización del Proceso de Anotación de Señales EEG de Pacientes con Epilepsia por Medio de Técnicas de Aprendizaje Automático,” Tesis de licenciatura, Universidad Del Valle de Guatemala, 2021.
- [11] C. Lemos, “Análisis y Anotación de Señales Bioeléctricas de Pacientes con Epilepsia Utilizando Técnicas de Aprendizaje Automático Supervisado y No Supervisado,” Tesis de licenciatura, Universidad Del Valle de Guatemala, 2022.

- [12] G. Pfurtscheller, G. Bauernfeind y T. Solis-Escalante, "Brain-Computer Interfaces and Signal Processing," *IEEE Signal Processing Magazine*, vol. 36, n.<sup>o</sup> 2, págs. 16-23, 2019. DOI: 10.1109/MSP.2018.2876352.
- [13] Biopac Systems Inc., *Biopac Systems, Inc.* <https://www.biopac.com>, 2021.
- [14] M. Uddin, M. Hossain, M. Ahmad, N. Ahmed y M. Rashid, "Effects of Caffeinated Beverage Consumption on Electrocardiographic Parameters among Healthy Adults," *Modern Applied Science*, vol. 8, feb. de 2014. DOI: 10.5539/mas.v8n2p69.
- [15] R. Merletti y P. Parker, *Electromyography: Physiology, Engineering, and Non-Invasive Applications*. Hoboken, NJ: Wiley-IEEE Press, 2004.
- [16] A. Goldberger y Z. Goldberger, *Clinical Electrocardiography: A Simplified Approach*. Philadelphia, PA: Elsevier, 2017.
- [17] P. Micó, "Nuevos desarrollos y aplicaciones basados en métodos estocásticos para el agrupamiento no supervisado de latidos en señales electrocardiográficas," ene. de 2005.
- [18] E. Niedermeyer y F. Lopes da Silva, *Electroencephalography: Basic Principles, Clinical Applications, and Related Fields*. New York, NY: Oxford University Press, 2018.
- [19] J. Smith y S. Johnson, "Analysis of EEG Signals for Brain Research," *Journal of Neuroscience*, vol. 25, n.<sup>o</sup> 3, págs. 45-60, 2018.
- [20] A. Oppenheim, R. Schafer y J. Buck, *Discrete-Time Signal Processing*. Upper Saddle River, NJ: Pearson, 2010.
- [21] S. Monk, *MATLAB: A Practical Introduction to Programming and Problem Solving*. Amsterdam, Netherlands: Elsevier, 2016.
- [22] A. Meneses Arévalo y D. Toloza Cano, "Unidad Modular de Frecuencia Respiratoria," ene. de 2008. DOI: 10.13140/RG.2.1.2072.1528.
- [23] K. Gopalakrishnan, K. Sivakumar y A. Khosla, "Review on Signal Filtering Techniques for Biomedical Signal Processing," *Biocybernetics and Biomedical Engineering*, vol. 39, n.<sup>o</sup> 1, págs. 23-39, 2019. DOI: 10.1016/j.bbe.2018.11.005.
- [24] J. Webster, *Medical Instrumentation: Application and Design*. Hoboken, NJ: Wiley, 2009.
- [25] R. Plonsey y R. Barr, *Bioelectricity: A Quantitative Approach*. New York, NY: Springer, 2000.
- [26] J. Engel Jr., *Epilepsy: A Comprehensive Textbook*, 2nd Edition. Philadelphia, PA: Lippincott Williams Wilkins, 2013.
- [27] R. S. Fisher, C. Acevedo y A. Arzimanoglou, "ILAE Official Report: A practical clinical definition of epilepsy," *Epilepsia*, vol. 55, n.<sup>o</sup> 4, págs. 475-482, 2014.
- [28] D. R. Fish, S. C. Schachter, W. E. Dodson y E. L. So, *Epilepsy: A Guide to Balancing Your Life*, 2nd Edition. New York, NY: Demos Medical Publishing, 2008.
- [29] Z. Obermeyer y E. Emanuel, "Predicting the Future - Big Data, Machine Learning, and Clinical Medicine," *The New England Journal of Medicine*, vol. 375, n.<sup>o</sup> 13, págs. 1216-1219, 2016. DOI: 10.1056/NEJMmp1606181.
- [30] V. François-Bongarçon, J. Lecailtel y G. Coatrieux, "Machine learning in bioelectrical signal analysis: A survey," *Biomedical Signal Processing and Control*, vol. 42, págs. 73-88, 2018.

- [31] C. M. Bishop, *Pattern Recognition and Machine Learning*, 1st Edition. New York: Springer, 2006.
- [32] S. J. Russell y P. Norvig, “Artificial Intelligence: A Modern Approach,” *Pearson*, 2010.
- [33] N. Cristianini y J. Shawe-Taylor, *An Introduction to Support Vector Machines and Other Kernel-based Learning Methods*. Cambridge, UK: Cambridge University Press, 2000, ISBN: 978-0521780193.
- [34] A. Saini, *Support Vector Machines (SVM): A Complete Guide for Beginners*, Accesado: 05-10-2023, 2021. dirección: <https://www.analyticsvidhya.com/blog/2021/10/support-vector-machinessvm-a-complete-guide-for-beginners/>.
- [35] I. Goodfellow, Y. Bengio y A. Courville, *Deep Learning*. Cambridge, MA: MIT Press, 2016, ISBN: 978-0262035613.
- [36] C. Ferro, N. Celis Mayorga y A. Casallas García, “Llenado de series de datos de 2014 a 2019 de PM2.5 por medio de una red neuronal y una regresión lineal,” ago. de 2020. DOI: 10.13140/RG.2.2.35092.53126.
- [37] I. Stancin, M. Cifrek y A. Jovic, “A Review of EEG Signal Features and their Application in Driver Drowsiness Detection Systems,” *Sensors*, vol. 21, n.º 11, 2021. DOI: 10.3390/s21113971.
- [38] U. Acharya, S. Oh, Y. Hagiwara, J. Tan y H. Adeli, “Deep Learning Applications in Healthcare Diagnosis,” *Computational and Structural Biotechnology Journal*, vol. 16, págs. 1-13, 2018. DOI: 10.1016/j.csbj.2018.01.003.
- [39] R. Kohavi, “A study of cross-validation and bootstrap for accuracy estimation and model selection,” *International joint conference on artificial intelligence*, vol. 14, págs. 1137-1143, 1995.
- [40] S. Arlot y A. Celisse, “A survey of cross-validation procedures for model selection,” *Statistics surveys*, vol. 4, págs. 40-79, 2010.
- [41] J. D. Hamilton, *Time Series Analysis*. Princeton University Press, 1994.
- [42] K. P. Burnham y D. R. Anderson, *Model Selection and Multimodel Inference: A Practical Information-Theoretic Approach*. Springer, 2002, ISBN: 978-0-387-95364-9.
- [43] M. Pourahmadi, “High-dimensional covariance matrix estimation with high-dimensional data,” *Wiley Interdisciplinary Reviews: Computational Statistics*, vol. 5, n.º 3, págs. 219-230, 2013.
- [44] T. R. Mullen, C. A. Kothe, Y. M. Chi et al., “Envelope-based detection of movement-related cortical potentials: a comparison of detection methods,” *NeuroImage*, vol. 113, págs. 279-288, 2015.
- [45] C. M. Bishop, “Pattern recognition and machine learning,” 2006.
- [46] R. P. Paul, “Robot manipulators: mathematics, programming, and control,” 1979.
- [47] J. Lavin, J. Solís-Pérez, J. Gómez-Aguilar y R. Escobar Jiménez, “Trajectory tracking control based on non-singular fractional derivatives for the PUMA 560 robot arm,” *Multibody System Dynamics*, vol. 50, nov. de 2020. DOI: 10.1007/s11044-020-09752-y.
- [48] B. Siciliano, L. Sciavicco, L. Villani y G. Oriolo, “Modelling and control of robot manipulators,” 2010.

- [49] A. Kulkarni, D. Chong y F. A. Batarseh, “Foundations of Data Imbalance and Solutions for a Data Democracy,” en *Data Democracy*, F. A. Batarseh y R. Yang, eds., Academic Press, 2020, págs. 83-106, ISBN: 978-0-12-818366-3. DOI: 10.1016/B978-0-12-818366-3.00005-8. dirección: <https://www.sciencedirect.com/science/article/pii/B9780128183663000058>.
- [50] C. Ferrin y H. Loaiza-Correa, “Interfaz cerebro-computador multimodal para procesos de neurorrehabilitación de miembros superiores en pacientes con lesiones de médula espinal: una revisión,” *Revista Ingeniería Biomédica*, vol. 12, dic. de 2018. DOI: 10.24050/19099762.n24.2018.1222.
- [51] I. Goodfellow, Y. Bengio, A. Courville e Y. Bengio, “Deep Learning,” *MIT press Cambridge*, 2016.
- [52] B. Hudgins, P. Parker y R. N. Scott, “New Strategy for Multifunction Myoelectric Control,” *IEEE Transactions on Biomedical Engineering*, vol. 40, págs. 82-94, 1993.
- [53] G. Rasool, K. Iqbal y G. A. White, “Myoelectric activity detection during a Sit-to-Stand movement using threshold methods,” *Computers Mathematics with Applications*, vol. 64, n.º 5, págs. 1473-1483, 2012, Advanced Technologies in Computer, Consumer and Control, ISSN: 0898-1221. DOI: <https://doi.org/10.1016/j.camwa.2012.03.094>. dirección: <https://www.sciencedirect.com/science/article/pii/S0898122112002994>.
- [54] D. J. McFarland, L. A. Miner, T. M. Vaughan y J. R. Wolpaw, “Mu and Beta Rhythm Topographies During Motor Imagery and Actual Movements,” *Brain Topography*, vol. 12, n.º 3, págs. 177-186, 2000. DOI: 10.1023/a:1023437823106.

# CAPÍTULO 18

---

## Anexos

---

### 18.1. Clasificadores Red Neuronal - Señales EMG

#### 18.1.1. Inter-sujeto (3 clases)

Dominio del tiempo, 2 características (ZC, MAV)

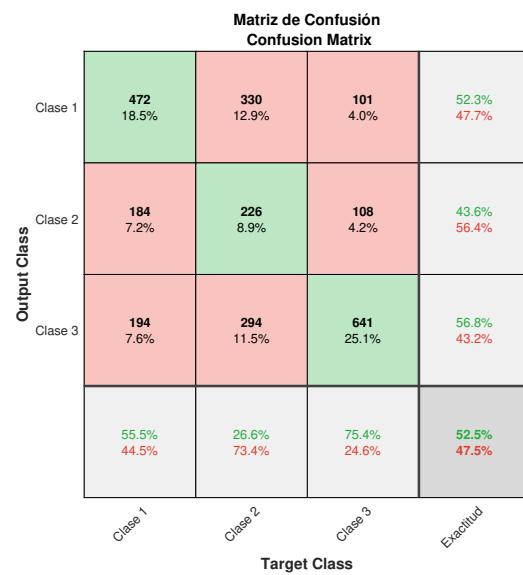


Figura 129: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

### Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	701 27.5%	264 10.4%	5 0.2%	72.3% 27.7%
	Clase 2	139 5.5%	525 20.6%	24 0.9%	76.3% 23.7%
	Clase 3	10 0.4%	61 2.4%	821 32.2%	92.0% 8.0%
		82.5% 17.5%	61.8% 38.2%	96.6% 3.4%	80.3% 19.7%

Figura 130: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

### Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	706 27.7%	206 8.1%	14 0.5%	76.2% 23.8%
	Clase 2	129 5.1%	589 23.1%	16 0.6%	80.2% 19.8%
	Clase 3	15 0.6%	55 2.2%	820 32.2%	92.1% 7.9%
		83.1% 16.9%	69.3% 30.7%	96.5% 3.5%	82.9% 17.1%

Figura 131: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

### 18.1.2. Intra-sujeto (2 clases): Sujeto de estudio - P000

Dominio del tiempo, 2 características (ZC, MAV)

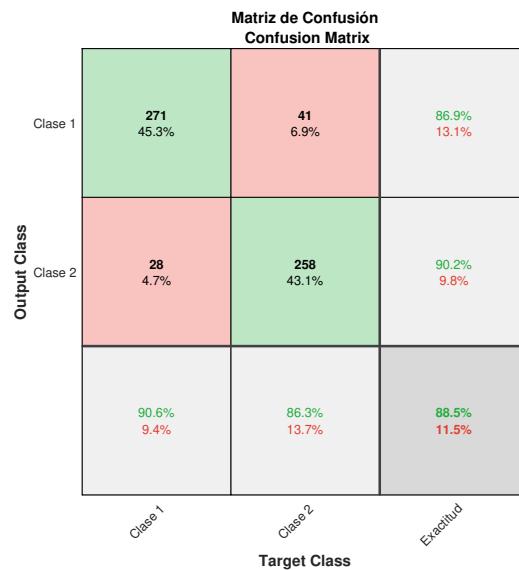


Figura 132: Matriz de confusión de 2 clases: Puño arriba, puño abajo.

Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

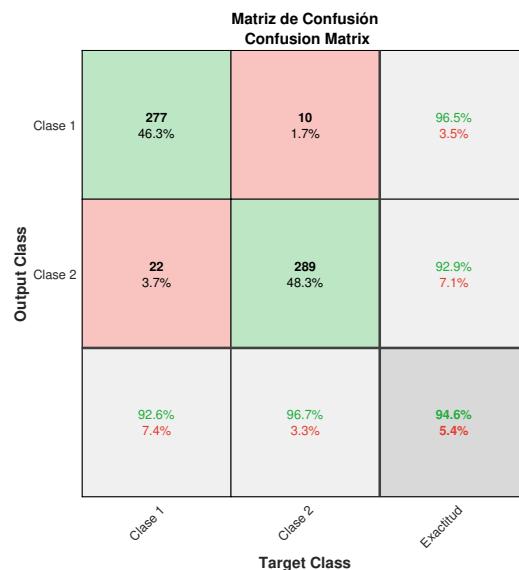


Figura 133: Matriz de confusión de 2 clases: Puño arriba, puño abajo.

**Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)**

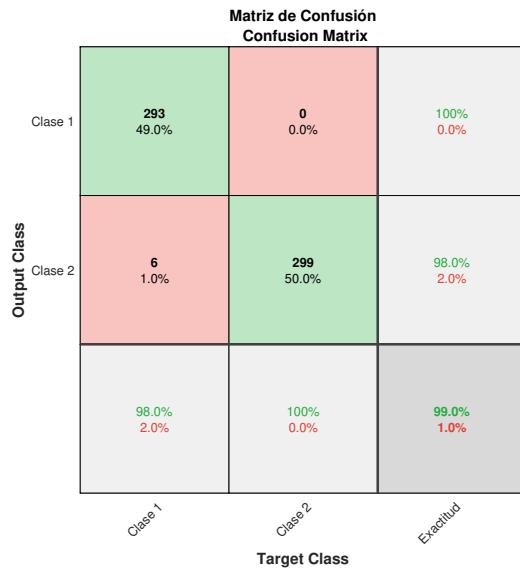


Figura 134: Matriz de confusión de 2 clases: Puño arriba, puño abajo.

### 18.1.3. Intra-sujeto (2 clases): Sujeto de estudio - P001

**Dominio del tiempo, 2 características (ZC, MAV)**

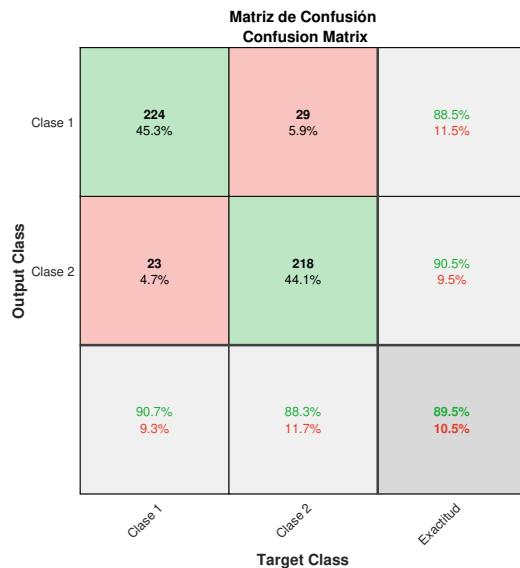


Figura 135: Matriz de confusión de 2 clases: Puño arriba, puño abajo.

### Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exclusud
Output Class	Clase 1	239 48.4%	8 1.6%	96.8% 3.2%
	Clase 2	8 1.6%	239 48.4%	96.8% 3.2%
	Exclusud	96.8% 3.2%	96.8% 3.2%	96.8% 3.2%

Figura 136: Matriz de confusión de 2 clases: Puño arriba, puño abajo.

### Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exclusud
Output Class	Clase 1	243 49.2%	4 0.8%	98.4% 1.6%
	Clase 2	4 0.8%	243 49.2%	98.4% 1.6%
	Exclusud	98.4% 1.6%	98.4% 1.6%	98.4% 1.6%

Figura 137: Matriz de confusión de 2 clases: Puño arriba, puño abajo.

#### 18.1.4. Intra-sujeto (2 clases): Sujeto de estudio - P002

Dominio del tiempo, 2 características (ZC, MAV)

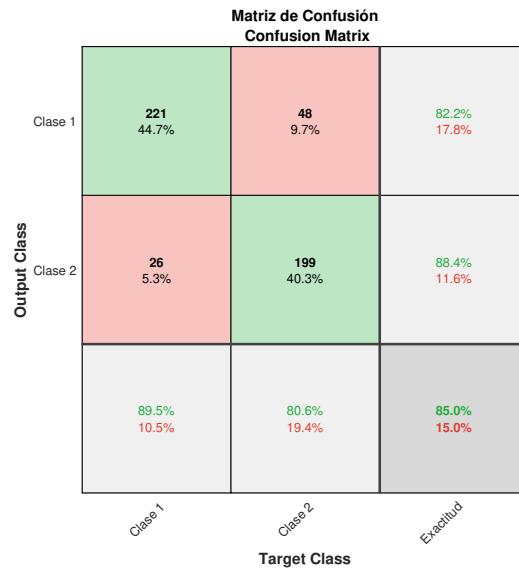


Figura 138: Matriz de confusión de 2 clases: Puño arriba, puño abajo.

Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

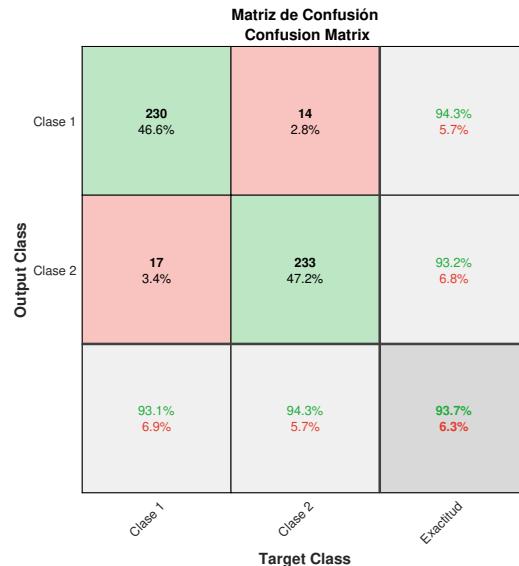


Figura 139: Matriz de confusión de 2 clases: Puño arriba, puño abajo.

**Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)**

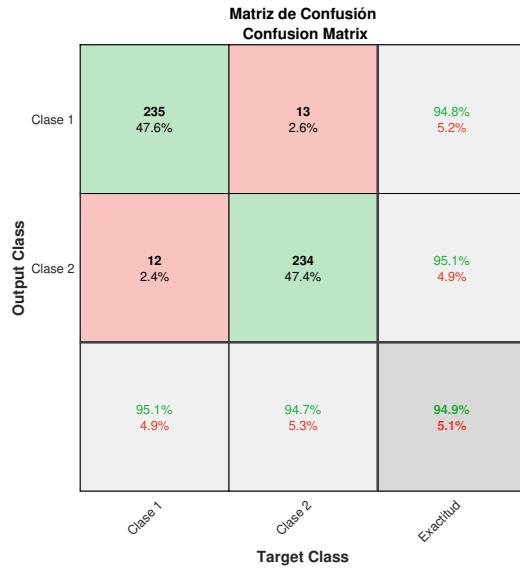


Figura 140: Matriz de confusión de 2 clases: Puño arriba, puño abajo.

### 18.1.5. Intra-sujeto (3 clases): Sujeto de estudio - P000

**Dominio del tiempo, 2 características (ZC, MAV)**

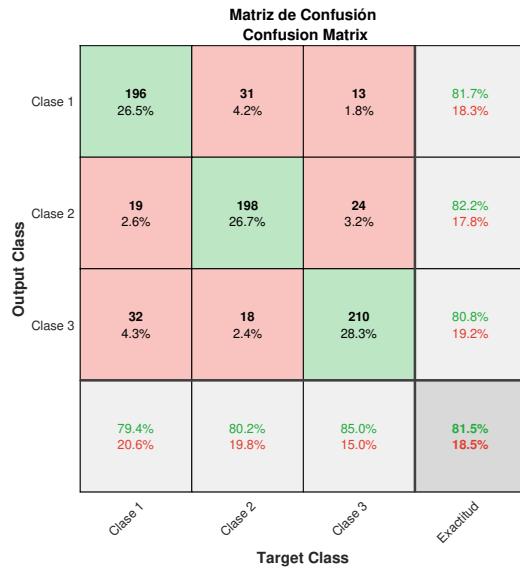


Figura 141: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

### Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	237 32.0%	11 1.5%	1 0.1%	95.2% 4.8%
	Clase 2	9 1.2%	225 30.4%	4 0.5%	94.5% 5.5%
	Clase 3	1 0.1%	11 1.5%	242 32.7%	95.3% 4.7%
		96.0% 4.0%	91.1% 8.9%	98.0% 2.0%	95.0% 5.0%

Figura 142: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

### Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	238 32.1%	6 0.8%	1 0.1%	97.1% 2.9%
	Clase 2	6 0.8%	236 31.8%	1 0.1%	97.1% 2.9%
	Clase 3	3 0.4%	5 0.7%	245 33.1%	96.8% 3.2%
		96.4% 3.6%	95.5% 4.5%	99.2% 0.8%	97.0% 3.0%

Figura 143: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

### 18.1.6. Intra-sujeto (3 clases): Sujeto de estudio - P001

Dominio del tiempo, 2 características (ZC, MAV)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	194 26.2%	21 2.8%	43 5.8%	75.2% 24.8%
	Clase 2	21 2.8%	200 27.0%	24 3.2%	81.6% 18.4%
	Clase 3	32 4.3%	26 3.5%	180 24.3%	75.6% 24.4%
		78.5% 21.5%	81.0% 19.0%	72.9% 27.1%	77.5% 22.5%
		Target Class			

Figura 144: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	231 31.2%	7 0.9%	29 3.9%	86.5% 13.5%
	Clase 2	2 0.3%	221 29.8%	18 2.4%	91.7% 8.3%
	Clase 3	14 1.9%	19 2.6%	200 27.0%	85.8% 14.2%
		93.5% 6.5%	89.5% 10.5%	81.0% 19.0%	88.0% 12.0%
		Target Class			

Figura 145: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

**Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)**

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	240 32.4%	4 0.5%	1 0.1%	98.0% 2.0%
	Clase 2	6 0.8%	240 32.4%	4 0.5%	96.0% 4.0%
	Clase 3	1 0.1%	3 0.4%	242 32.7%	98.4% 1.6%
		97.2% 2.8%	97.2% 2.8%	98.0% 2.0%	97.4% 2.6%

Figura 146: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

#### 18.1.7. Intra-sujeto (3 clases): Sujeto de estudio - P002

**Dominio del tiempo, 2 características (ZC, MAV)**

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	195 26.3%	12 1.6%	19 2.6%	86.3% 13.7%
	Clase 2	26 3.5%	156 21.1%	52 7.0%	66.7% 33.3%
	Clase 3	26 3.5%	79 10.7%	176 23.8%	62.6% 37.4%
		78.9% 21.1%	63.2% 36.8%	71.3% 28.7%	71.1% 28.9%

Figura 147: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

### Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	229 30.9%	1 0.1%	13 1.8%	94.2% 5.8%
	Clase 2	2 0.3%	240 32.4%	33 4.5%	87.3% 12.7%
	Clase 3	16 2.2%	6 0.8%	201 27.1%	90.1% 9.9%
		92.7% 7.3%	97.2% 2.8%	81.4% 18.6%	90.4% 9.6%

Figura 148: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

### Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	236 31.8%	1 0.1%	13 1.8%	94.4% 5.6%
	Clase 2	3 0.4%	239 32.3%	25 3.4%	89.5% 10.5%
	Clase 3	8 1.1%	7 0.9%	209 28.2%	93.3% 6.7%
		95.5% 4.5%	96.8% 3.2%	84.6% 15.4%	92.3% 7.7%

Figura 149: Matriz de confusión de 3 clases: Puño arriba, puño abajo, puño.

### 18.1.8. Intra-sujeto (4 clases): Sujeto de estudio - P002

Dominio del tiempo, 2 características (ZC, MAV)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	181 18.3%	11 1.1%	18 1.8%	23 2.3%	77.7% 22.3%
	Clase 2	30 3.0%	147 14.9%	44 4.5%	10 1.0%	63.6% 36.4%
	Clase 3	17 1.7%	69 7.0%	167 16.9%	47 4.8%	55.7% 44.3%
	Clase 4	19 1.9%	20 2.0%	18 1.8%	167 16.9%	74.6% 25.4%
		73.3% 26.7%	59.5% 40.5%	67.6% 32.4%	67.6% 32.4%	67.0% 33.0%
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
		Target Class				

Figura 150: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	220 22.3%	26 2.6%	0 0.0%	3 0.3%	88.4% 11.6%
	Clase 2	22 2.2%	182 18.4%	1 0.1%	13 1.3%	83.5% 16.5%
	Clase 3	3 0.3%	16 1.6%	222 22.5%	58 5.9%	74.2% 25.8%
	Clase 4	2 0.2%	23 2.3%	24 2.4%	173 17.5%	77.9% 22.1%
		89.1% 10.9%	73.7% 26.3%	89.9% 10.1%	70.0% 30.0%	80.7% 19.3%
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
		Target Class				

Figura 151: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

**Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)**

		Matriz de Confusión Confusion Matrix				
		Clase 1	Clase 2	Clase 3	Clase 4	Exactitud
Output Class	Clase 1	236 23.9%	2 0.2%	14 1.4%	7 0.7%	91.1% 8.9%
	Clase 2	0 0.0%	230 23.3%	20 2.0%	1 0.1%	91.6% 8.4%
	Clase 3	10 1.0%	10 1.0%	198 20.0%	21 2.1%	82.8% 17.2%
	Clase 4	1 0.1%	5 0.5%	15 1.5%	218 22.1%	91.2% 8.8%
	Exactitud	95.5% 4.5%	93.1% 6.9%	80.2% 19.8%	88.3% 11.7%	89.3% 10.7%

Figura 152: Matriz de confusión de 4 clases: Puño, puño arriba, puño abajo, palma extendida.

## 18.2. Clasificadores Red Neuronal - Señales EEG

### 18.2.1. Inter-sujeto (3 clases)

Dominio del tiempo, 2 características (ZC, MAV)

		Matriz de Confusión Confusion Matrix			
		Clase 1	164 7.6%	90 4.2%	56.2% 43.8%
Output Class	Clase 1	326 15.1%			
	Clase 2	157 7.3%	436 20.2%	78 3.6%	65.0% 35.0%
	Clase 3	237 11.0%	120 5.6%	552 25.6%	60.7% 39.3%
		45.3% 54.7%	60.6% 39.4%	76.7% 23.3%	60.8% 39.2%
		Clase 1	Clase 2	Clase 3	Exactitud
		Target Class			

Figura 153: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	85 3.9%	2 0.1%	86.4% 13.6%
Output Class	Clase 1	555 25.7%			
	Clase 2	117 5.4%	513 23.8%	83 3.8%	71.9% 28.1%
	Clase 3	48 2.2%	122 5.6%	635 29.4%	78.9% 21.1%
		77.1% 22.9%	71.2% 28.7%	88.2% 11.8%	78.8% 21.2%
		Clase 1	Clase 2	Clase 3	Exactitud
		Target Class			

Figura 154: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

**Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)**

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	593 27.5%	66 3.1%	2 0.1%	89.7% 10.3%
	Clase 2	77 3.6%	559 25.9%	51 2.4%	81.4% 18.6%
	Clase 3	50 2.3%	95 4.4%	667 30.9%	82.1% 17.9%
		82.4% 17.6%	77.6% 22.4%	92.6% 7.4%	84.2% 15.8%

Figura 155: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

**Dominio de la frecuencia, 2 características (razón 1, razón 2)**

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	713 33.0%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	563 26.1%	191 8.8%	74.7% 25.3%
	Clase 3	7 0.3%	157 7.3%	529 24.5%	76.3% 23.7%
		99.0% 1.0%	78.2% 21.8%	73.5% 26.5%	83.6% 16.4%

Figura 156: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

**Dominio de la frecuencia, con 4 características (razón 1, razón 2, razón 3, desviación estándar)**

		Matriz de Confusión Confusion Matrix			
		Clase 1	0	0	100%
Output Class	Clase 1	714 33.1%	0 0.0%	0 0.0%	0.0%
	Clase 2	3 0.1%	658 30.5%	246 11.4%	72.5% 27.5%
	Clase 3	3 0.1%	62 2.9%	474 21.9%	87.9% 12.1%
		99.2% 0.8%	91.4% 8.6%	65.8% 34.2%	85.5% 14.5%
		Clase 1	Clase 2	Clase 3	Exactitud
		Target Class			

Figura 157: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

**Dominio de la frecuencia, con 6 características (razón 1, razón 2, razón 3, razón 4, razón 5, Desviación estándar)**

		Matriz de Confusión Confusion Matrix			
		Clase 1	0	0	100%
Output Class	Clase 1	720 33.3%	0 0.0%	0 0.0%	0.0%
	Clase 2	0 0.0%	598 27.7%	28 1.3%	95.5% 4.5%
	Clase 3	0 0.0%	122 5.6%	692 32.0%	85.0% 15.0%
		100% 0.0%	83.1% 16.9%	96.1% 3.9%	93.1% 6.9%
		Clase 1	Clase 2	Clase 3	Exactitud
		Target Class			

Figura 158: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

### 18.2.2. Intra-sujeto (2 clases): Sujeto de estudio - P000

Dominio del tiempo, 2 características (ZC, MAV)

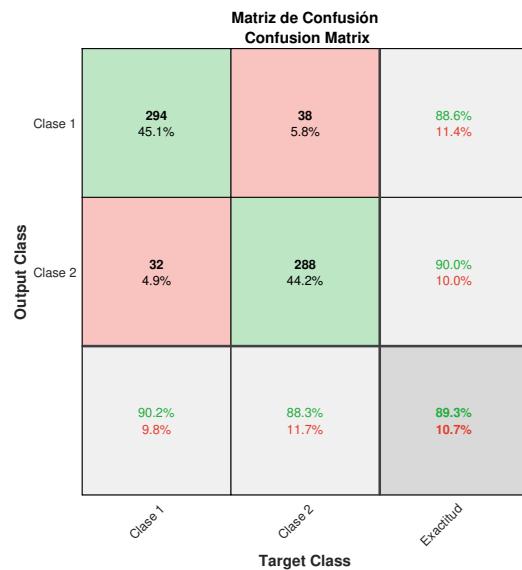


Figura 159: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

### Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exclusud
Output Class	Clase 1	306 46.9%	35 5.4%	89.7% 10.3%
	Clase 2	20 3.1%	291 44.6%	93.6% 6.4%
	Exclusud	93.9% 6.1%	89.3% 10.7%	91.6% 8.4%

Figura 160: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

### Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exclusud
Output Class	Clase 1	306 46.9%	32 4.9%	90.5% 9.5%
	Clase 2	20 3.1%	294 45.1%	93.6% 6.4%
	Exclusud	93.9% 6.1%	90.2% 9.8%	92.0% 8.0%

Figura 161: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

### Dominio de la frecuencia, 2 características (razón 1, razón 2)

Matriz de Confusión Confusion Matrix			
Output Class	Clase 1	Clase 2	
	Clase 1	Clase 2	
	Exactitud		
Clase 1	326 50.0%	0 0.0%	100% 0.0%
Clase 2	0 0.0%	326 50.0%	100% 0.0%
	100% 0.0%	100% 0.0%	100% 0.0%

Figura 162: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

### Dominio de la frecuencia, con 4 características (razón 1, razón 2, razón 3, desviación estándar)

Matriz de Confusión Confusion Matrix			
Output Class	Clase 1	Clase 2	
	Clase 1	Clase 2	
	Exactitud		
Clase 1	326 50.0%	0 0.0%	100% 0.0%
Clase 2	0 0.0%	326 50.0%	100% 0.0%
	100% 0.0%	100% 0.0%	100% 0.0%

Figura 163: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

**Dominio de la frecuencia, con 6 características (razón 1, razón 2, razón 3, razón 4, razón 5, Desviación estándar)**

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exactitud
Output Class	Clase 1	326 50.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	326 50.0%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%

Figura 164: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

### 18.2.3. Intra-sujeto (3 clases): Sujeto de estudio - P000

**Dominio del tiempo, 2 características (ZC, MAV)**

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	295 30.2%	47 4.8%	4 0.4%	85.3% 14.7%
	Clase 2	6 0.6%	158 16.2%	29 3.0%	81.9% 18.1%
	Clase 3	25 2.6%	121 12.4%	293 30.0%	66.7% 33.3%
		90.5% 9.5%	48.5% 51.5%	89.9% 10.1%	76.3% 23.7%

Figura 165: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

### Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	300 30.7%	30 3.1%	0 0.0%	90.9% 9.1%
	Clase 2	23 2.4%	226 23.1%	21 2.1%	83.7% 16.3%
	Clase 3	3 0.3%	70 7.2%	305 31.2%	80.7% 19.3%
		92.0% 8.0%	69.3% 30.7%	93.6% 6.4%	85.0% 15.0%

Figura 166: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

### Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	309 31.6%	30 3.1%	1 0.1%	90.9% 9.1%
	Clase 2	13 1.3%	239 24.4%	29 3.0%	85.1% 14.9%
	Clase 3	4 0.4%	57 5.8%	296 30.3%	82.9% 17.1%
		94.8% 5.2%	73.3% 26.7%	90.8% 9.2%	86.3% 13.7%

Figura 167: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

### Dominio de la frecuencia, 2 características (razón 1, razón 2)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	326 33.3%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	322 32.9%	1 0.1%	99.7% 0.3%
	Clase 3	0 0.0%	4 0.4%	325 33.2%	98.8% 1.2%
		100% 0.0%	98.8% 1.2%	99.7% 0.3%	99.5% 0.5%

Figura 168: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

### Dominio de la frecuencia, con 4 características (razón 1, razón 2, razón 3, desviación estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	326 33.3%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	323 33.0%	1 0.1%	99.7% 0.3%
	Clase 3	0 0.0%	3 0.3%	325 33.2%	99.1% 0.9%
		100% 0.0%	99.1% 0.9%	99.7% 0.3%	99.6% 0.4%

Figura 169: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

**Dominio de la frecuencia, con 6 características (razón 1, razón 2, razón 3, razón 4, razón 5, Desviación estándar)**

		Matriz de Confusión Confusion Matrix			
		Clase 1	0	0	100%
Output Class	Clase 1	326 33.3%	0 0.0%	0 0.0%	0.0%
	Clase 2	0 0.0%	323 33.0%	3 0.3%	99.1% 0.9%
	Clase 3	0 0.0%	3 0.3%	323 33.0%	99.1% 0.9%
		100% 0.0%	99.1% 0.9%	99.1% 0.9%	99.4% 0.6%
		Clase 1	Clase 2	Clase 3	Exactitud
		Target Class			

Figura 170: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

#### 18.2.4. Intra-sujeto (2 clases): Sujeto de estudio - P001

**Dominio del tiempo, 2 características (ZC, MAV)**

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exactitud
Output Class	Clase 1	301 41.8%	99 13.8%	75.2% 24.8%
	Clase 2	59 8.2%	261 36.2%	81.6% 18.4%
		83.6% 16.4%	72.5% 27.5%	78.1% 21.9%
		Clase 1	Clase 2	Exactitud
		Target Class		

Figura 171: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

### Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exclusud
Output Class	Clase 1	353 49.0%	35 4.9%	91.0% 9.0%
	Clase 2	7 1.0%	325 45.1%	97.9% 2.1%
	Exclusud	98.1% 1.9%	90.3% 9.7%	94.2% 5.8%

Figura 172: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

### Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exclusud
Output Class	Clase 1	358 49.7%	28 3.9%	92.7% 7.3%
	Clase 2	2 0.3%	332 46.1%	99.4% 0.6%
	Exclusud	99.4% 0.6%	92.2% 7.8%	95.8% 4.2%

Figura 173: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

### Dominio de la frecuencia, 2 características (razón 1, razón 2)

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exactitud
Output Class	Clase 1	360 50.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	360 50.0%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%

Figura 174: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

### Dominio de la frecuencia, con 4 características (razón 1, razón 2, razón 3, desviación estándar)

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exactitud
Output Class	Clase 1	360 50.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	360 50.0%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%

Figura 175: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

**Dominio de la frecuencia, con 6 características (razón 1, razón 2, razón 3, razón 4, razón 5, Desviación estándar)**

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exactitud
Output Class	Clase 1	360 50.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	360 50.0%	100% 0.0%
		100% 0.0%	100% 0.0%	100% 0.0%

Figura 176: Matriz de confusión de 2 clases: Cabeza arriba, cabeza abajo.

#### 18.2.5. Intra-sujeto (3 clases): Sujeto de estudio - P001

**Dominio del tiempo, 2 características (ZC, MAV)**

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	286 29.2%	29 3.0%	9 0.9%	88.3% 11.7%
	Clase 2	26 2.7%	197 20.1%	61 6.2%	69.4% 30.6%
	Clase 3	14 1.4%	100 10.2%	256 26.2%	69.2% 30.8%
		87.7% 12.3%	60.4% 39.6%	78.5% 21.5%	75.6% 24.4%

Figura 177: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

### Dominio del tiempo, 3 características (ZC, MAV, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	304 31.1%	49 5.0%	0 0.0%	86.1% 13.9%
	Clase 2	20 2.0%	216 22.1%	60 6.1%	73.0% 27.0%
Output Class	Clase 3	2 0.2%	61 6.2%	266 27.2%	80.9% 19.1%
		93.3% 6.7%	66.3% 33.7%	81.6% 18.4%	80.4% 19.6%

Figura 178: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

### Dominio del tiempo, 5 características (ZC, MAV, Curtosis, Energía Acumulada, Desviación Estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	309 31.6%	27 2.8%	1 0.1%	91.7% 8.3%
	Clase 2	13 1.3%	237 24.2%	15 1.5%	89.4% 10.6%
Output Class	Clase 3	4 0.4%	62 6.3%	310 31.7%	82.4% 17.6%
		94.8% 5.2%	72.7% 27.3%	95.1% 4.9%	87.5% 12.5%

Figura 179: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

### Dominio de la frecuencia, 2 características (razón 1, razón 2)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	326 33.3%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	319 32.6%	1 0.1%	99.7% 0.3%
	Clase 3	0 0.0%	7 0.7%	325 33.2%	97.9% 2.1%
		100% 0.0%	97.9% 2.1%	99.7% 0.3%	99.2% 0.8%

Figura 180: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

### Dominio de la frecuencia, con 4 características (razón 1, razón 2, razón 3, desviación estándar)

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	326 33.3%	0 0.0%	0 0.0%	100% 0.0%
	Clase 2	0 0.0%	318 32.5%	1 0.1%	99.7% 0.3%
	Clase 3	0 0.0%	8 0.8%	325 33.2%	97.6% 2.4%
		100% 0.0%	97.5% 2.5%	99.7% 0.3%	99.1% 0.9%

Figura 181: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

**Dominio de la frecuencia, con 6 características (razón 1, razón 2, razón 3, razón 4, razón 5, Desviación estándar)**

		Matriz de Confusión Confusion Matrix			
		Clase 1	0	1	99.7% 0.3%
Output Class	Clase 1	326 33.3%	0 0.0%	1 0.1%	99.7% 0.3%
	Clase 2	0 0.0%	323 33.0%	1 0.1%	99.7% 0.3%
	Clase 3	0 0.0%	3 0.3%	324 33.1%	99.1% 0.9%
		100% 0.0%	99.1% 0.9%	99.4% 0.6%	99.5% 0.5%
		Clase 1	Clase 2	Clase 3	Exactitud
		Target Class			

Figura 182: Matriz de confusión de 3 clases: Cabeza arriba, cabeza abajo, cabeza inclinada.

### 18.3. Resultados SVM - EMG: Intra-sujeto

#### 18.3.1. Clasificación de características - Dominio del tiempo: Sujeto P002

**Matriz de confusión 2 gestos: Cabeza arriba, cabeza abajo**

		Matriz de Confusión Confusion Matrix		
		Clase 1	Clase 2	Exactitud
Output Class	Clase 1	24 49.0%	1 2.0%	96.0% 4.0%
	Clase 2	0 0.0%	24 49.0%	100% 0.0%
	100% 0.0%	96.0% 4.0%	98.0% 2.0%	
Target Class	Clase 1	Clase 2	Exactitud	

Figura 183: Clasificación sujeto P002, 2 gestos, 5 características en el dominio del tiempo.

**Matriz de confusión 3 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada**

		Matriz de Confusión Confusion Matrix			
		Clase 1	Clase 2	Clase 3	Exactitud
Output Class	Clase 1	23 31.1%	1 1.4%	0 0.0%	95.8% 4.2%
	Clase 2	0 0.0%	23 31.1%	1 1.4%	95.8% 4.2%
Clase 3	1 1.4%	1 1.4%	24 32.4%	92.3% 7.7%	
	95.8% 4.2%	92.0% 8.0%	96.0% 4.0%	94.6% 5.4%	
Target Class	Clase 1	Clase 2	Clase 3	Exactitud	

Figura 184: Clasificación sujeto P002, 3 gestos, 5 características en el dominio del tiempo.

**Matriz de confusión 4 gestos: Cabeza arriba, cabeza abajo, cabeza inclinada, cejas hacia arriba**

		Matriz de Confusión Confusion Matrix					
		Clase 1	Clase 2	Clase 3	Clase 4		
Output Class	Clase 1	24 24.0%	0 0.0%	4 4.0%	1 1.0%	82.8% 17.2%	
	Clase 2	0 0.0%	23 23.0%	3 3.0%	0 0.0%	88.5% 11.5%	
	Clase 3	1 1.0%	2 2.0%	17 17.0%	1 1.0%	81.0% 19.0%	
	Clase 4	0 0.0%	0 0.0%	1 1.0%	23 23.0%	95.8% 4.2%	
	Exactitud	96.0% 4.0%	92.0% 8.0%	68.0% 32.0%	92.0% 8.0%	87.0% 13.0%	

Figura 185: Clasificación sujeto P002, 3 gestos, 5 características en el dominio del tiempo.